ANALISIS & PEMROSESAN DATA MULTIMODAL

Analisis Paper Kandidat: Klasifikasi Dokumen Multimodal Berbasis Teks OCR dan Citra

Disusun oleh:

Yulian Anggreaif Rudamaga	:	256150100011001
Zalzabila Rani	:	256150100011008
Ramadhani Al-Qadri	:	256150100011010

Dosen Pengampu:
Dr. Eng. Fitra Abdurrachman Bachtiar, S.T., M.Eng.

PROGRAM STUDI MAGISTER ILMU KOMPUTER
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA

1 Pendahuluan

Dokumen ini menganalisis tujuh paper kandidat untuk topik klasifikasi dokumen multimodal yang memadukan citra halaman dengan teks hasil OCR. Paper dipilih dengan dua kriteria:

- terbit tahun 2022 atau sesudahnya;
- terbit di konferensi atau jurnal yang disarankan.

Daftarnya pada Tabel 1.

Tabel 1 Paper kandidat yang dianalisis

No	Paper	Venue	Tahun
1	LayoutLMv3 (Huang et al., 2022)	ACM MM	2022
2	Donut (Kim et al., 2022)	ECCV	2022
3	UDOP (Tang et al., 2023)	CVPR	2023
4	DocFormerv2 (Appalaraju et al., 2024)	AAAI	2024
5	DocLLM (Wang et al., 2024)	ACL	2024
6	LiLT (Wang, Jin dan Ding, 2022)	ACL	2022
7	Review fusion klasifikasi dokumen (Mirończuk, 2026)	Information Fusion	2026

Setiap paper dianalisis dengan delapan aspek yang sama: (1) latar belakang, (2) dataset, (3) teknologi OCR, (4) pipeline, (5) model, (6) metode fusion, (7) hasil, dan (8) hambatan atau *future work*.

Isinya diambil dari teks lengkap tiap paper. Yang dibaca adalah versi arXiv, tetapi yang dikutip adalah versi terbitnya. Angka hasil disalin dari tabel paper masing-masing. Bila sebuah aspek tidak disebutkan paper, hal itu ditulis “tidak disebutkan”, bukan ditebak.

2 Analisis per Paper

2.1 LayoutLMv3 (ACM MM 2022)

Latar belakang. Model dokumen multimodal sebelumnya memakai tujuan pralatih yang berbeda untuk teks dan citra:

- teks memakai *masked language modeling* (MLM);
- citra merekonstruksi piksel (DocFormer) atau meregresi fitur wilayah (SelfDoc).

Ketidakselarasan ini menyulitkan penyelarasan lintas-modalitas. Selain itu, cabang citra bergantung pada CNN atau Faster R-CNN yang berat dan butuh anotasi wilayah (Huang et al., 2022).

Dataset.

- **Pralatih:** IIT-CDIP, 11 juta halaman.
- **Klasifikasi:** RVL-CDIP (320.000/40.000/40.000 citra, 16 kelas).
- **Ekstraksi formulir dan struk:** FUNSD dan CORD.

- **Tanya-jawab dokumen:** DocVQA.
- **Analisis tata letak:** PubLayNet.
- **Lampiran:** EPHOIE (bahasa Mandarin).

Teknologi OCR.

- Pralatih memakai "toolkit OCR siap pakai" yang tidak disebutkan namanya.
- Untuk RVL-CDIP dan DocVQA, teks dan kotaknya diekstrak dengan **Microsoft Read API** (layanan komersial).
- Untuk CORD dipakai anotasi OCR resmi dataset.
- Posisi tata letak dipakai di tingkat segmen: kata dalam satu segmen berbagi satu kotak.

Pipeline.

1. Citra diubah ke 224×224, dipecah menjadi 196 *patch* 16×16, lalu diproyeksikan linear.
2. Teks OCR ditokenisasi BPE, maksimum 512 token, dan diberi posisi 1D serta posisi tata letak 2D (x, y, lebar, tinggi).
3. Kedua urutan disambung dan dimasukkan ke satu Transformer.
4. Untuk klasifikasi, keluaran token `[CLS]` masuk ke pengklasifikasi MLP.

Model. Transformer *encoder* yang diinisialisasi dari RoBERTa:

- *base*: 12 lapis, 133 juta parameter;
- *large*: 24 lapis, 368 juta parameter.

Pralatihnya memakai tiga tujuan:

- MLM untuk teks;
- *masked image modeling* (MIM) untuk citra, dengan target token citra dari tokenizer DiT;
- *word-patch alignment* (WPA): memprediksi apakah *patch* citra dari sebuah kata ikut di-*mask*.

Metode fusion. Fusion awal dalam satu aliran (*single-stream early fusion*). Token teks dan *patch* citra disambung menjadi satu urutan, lalu saling memperhatikan lewat *self-attention* di setiap lapis. Penyelarasan antar-modalitas dilatih lewat WPA.

Hasil.

- RVL-CDIP: akurasi 95,44% (*base*) dan 95,93% (*large*).
- FUNSD: F1 90,29 dan 92,08. CORD: F1 96,56 dan 97,46.
- DocVQA: ANLS 78,76 dan 83,37.
- PubLayNet: mAP 95,1.

Ablasinya penting untuk topik kita. Pada pralatih 1 juta dokumen, model teks + tata letak **tanpa citra** sudah mencapai 95,33% di RVL-CDIP. Menambahkan *patch* citra tanpa MIM justru turun ke 95,00%. Dengan MIM dan WPA, akurasinya baru naik ke 95,53%. Jadi sumbangan citra untuk klasifikasi hanya sekitar 0,2 poin, dan baru muncul setelah ada tujuan pralatih khusus untuk citra.

Hambatan dan *future work*. Penulis berencana:

- memperbesar skala model dan data pralatih;
- mengeksplorasi *few-shot* dan *zero-shot learning*.

Hambatan yang tidak dibahas penulis:

- model bergantung pada OCR komersial (Microsoft Read API);
- pralatihnya sangat mahal: *batch* 2.048 selama 500.000 langkah.

2.2 Donut (ECCV 2022)

Latar belakang. Model pemahaman dokumen menyerahkan pembacaan teks kepada mesin OCR siap pakai. Ketergantungan ini membawa tiga masalah (Kim et al., 2022):

1. biaya komputasi OCR yang tinggi;
2. mesin OCR tidak fleksibel terhadap bahasa atau jenis dokumen baru;
3. **galat OCR merambat** ke tahap berikutnya.

Donut menghapus OCR dari pipeline.

Dataset.

- **Pralatih:** IIT-CDIP (11 juta citra) ditambah dokumen sintetis SynthDoG, 0,5 juta per bahasa (Inggris, Mandarin, Jepang, Korea).
- **Klasifikasi:** RVL-CDIP.
- **Ekstraksi informasi:** CORD, Ticket, serta dua data industri internal (kartu nama Jepang dan struk Korea).
- **Tanya-jawab:** DocVQA.

Teknologi OCR.

- **Saat inferensi tidak ada OCR.**
- OCR hanya dipakai untuk membuat label teks pralatih IIT-CDIP, dengan CLOVA OCR API (komersial).
- Model pembanding berbasis OCR memakai MS OCR dan CLOVA OCR.
- Lampiran A.1 membandingkan **empat mesin OCR**: MS OCR, CLOVA OCR, EasyOCR, dan PaddleOCR versi *mobile*.

Pipeline.

1. Citra beresolusi 2560×1920 dimasukkan ke *encoder* visual.

2. *Decoder* teks menghasilkan urutan token yang diubah menjadi JSON.
3. Untuk klasifikasi, *decoder* menuliskan `[START_class][memo][END_class]`.

Model. 143 juta parameter:

- *encoder*: Swin Transformer-B;
- *decoder*: empat lapis pertama BART multibahasa.

Pralatihnya berupa tugas "membaca", yaitu memprediksi kata berikutnya dari citra. Proses ini berjalan 200.000 langkah pada 64 GPU A100.

Metode fusion. Tidak ada fusion eksplisit, karena masukannya hanya citra. Teks tidak diambil dari OCR, tetapi "dibaca" sendiri oleh model. Hubungan visual dan bahasa terjadi lewat *cross-attention decoder* ke keluaran *encoder*.

Hasil.

- RVL-CDIP: akurasi **95,30%**, setara LayoutLMv2 (95,25%), dengan waktu 752 ms per dokumen berbanding 1.489 ms.
- CORD: F1 84,1.
- DocVQA: ANLS 67,5, masih di bawah LayoutLMv2 (78,1). Namun Donut lebih kuat pada tulisan tangan (ANLS 72,1).

Temuan paling relevan untuk topik kita ada di Gambar 9 paper. Akurasi dan kecepatan model berbasis OCR (BERT dan LayoutLMv2) di CORD **sangat bervariasi tergantung mesin OCR yang dipakai**. CLOVA OCR memberi akurasi terbaik.

Hambatan dan *future work*.

- Teks yang sangat kecil di halaman besar dapat terlewat karena batas resolusi masukan.
- Resolusi yang lebih tinggi menaikkan akurasi, tetapi biayanya membesar.
- Penulis menyebut perbaikan tujuan pralatih sebagai arah lanjutan.

2.3 UDOP (CVPR 2023)

Latar belakang. Model sebelumnya memperlakukan citra dan teks dokumen sebagai dua masukan terpisah. Tata letak hanya diwakili *embedding* posisi yang dangkal, dan setiap tugas butuh *head* khusus. Padahal teks dokumen "tertanam" di citra dengan korespondensi satu-satu (Tang et al., 2023).

Dataset.

- **Pralatih:** IIT-CDIP (11 juta dokumen), ditambah 11 dataset berlabel (1,8 juta contoh), termasuk RVL-CDIP, PubLayNet, DocVQA, dan lainnya.
- **Evaluasi:** FUNSD, CORD, RVL-CDIP, dan tujuh dataset DUE-Benchmark.

Teknologi OCR.

- IIT-CDIP dipakai beserta teks dan kotak hasil OCR yang tersedia, tanpa nama mesin.

- Untuk semua tugas evaluasi, penulis memakai **anotasi OCR asli yang disediakan dataset**.

Pipeline.

1. Citra dipecah menjadi *patch*.
2. *Embedding* setiap token teks **dijumlahkan** dengan fitur *patch* citra tempat pusat kotak token itu berada (*layout-induced vision-text embedding*).
3. Kotak tata letak diubah menjadi token diskret, misalnya <50><100><250><300>.
4. Semua tugas, termasuk klasifikasi, dirumuskan sebagai pembangkitan teks dengan prompt, misalnya "Document Classification on RVLCDIP".

Model. *Vision-Text-Layout Transformer* dengan 794 juta parameter:

- *encoder* dan *decoder* teks-tata letak berbasis T5-large;
- *decoder* visual berbasis MAE-large.

Resolusi dinaikkan bertahap $224 \rightarrow 512 \rightarrow 1024$.

Metode fusion. Fusion paling awal. Teks dan citra dijumlahkan sudah di tingkat *embedding* masukan, berdasarkan letak spasialnya, lalu diproses satu *encoder*. Varian pembanding UDOP-Dual memakai dua *encoder* terpisah untuk teks dan citra (*two-tower*).

Hasil.

- RVL-CDIP: akurasi **96,00%**; varian UDOP-Dual 96,22%.
- FUNSD: F1 91,62. CORD: F1 97,58.
- Peringkat pertama di DUE-Benchmark per November 2022.

Menghapus input citra hanya menurunkan DocVQA dari 84,7 ke 84,4, dan InfographicsVQA dari 47,4 ke 45,0. Penulis menyimpulkan citra lebih penting pada data yang kaya visual daripada pada data yang didominasi teks.

Hambatan dan *future work*. Penulis menyebut dua hal:

- kemampuan membangkitkan dokumen dapat disalahgunakan untuk pemalsuan;
- penerapan pada bahasa non-Latin memerlukan modifikasi.

Hambatan praktis yang tidak dibahas penulis: ukuran model (794 juta parameter) dan pralatihnya sangat berat.

2.4 DocFormerv2 (AAAI 2024)

Latar belakang. Menderetkan teks OCR dari kiri ke kanan lalu memberikannya ke model bahasa tidak optimal. Makna isi dokumen bergantung pada tata letaknya, dan sebagian besar tugas butuh pemahaman **lokal**: hubungan sebuah teks dengan teks di sekitarnya. Model sebelumnya kebanyakan hanya *encoder* (Appalaraju et al., 2024).

Dataset.

- **Pralatih:** Industrial Document Library (IDL), 64 juta halaman.
- **Evaluasi:** TabFact, WikiTableQuestions, DocVQA, InfographicsVQA, FUNSD, dan CORD, ditambah tiga dataset *scene-text* VQA (OCR-VQA, TextVQA, ST-VQA).
- **RVL-CDIP tidak diuji**, sehingga tidak ada hasil klasifikasi dokumen.

Teknologi OCR. Teks dan kotak IDL diekstrak dengan OCR, tetapi **nama mesin OCR-nya tidak disebutkan**. Untuk evaluasi dipakai teks OCR yang disediakan dataset.

Pipeline.

1. Citra masuk lewat lapisan sederhana `linear(conv2x2(v))`, tanpa CNN atau detektor objek.
2. Teks OCR ditokenisasi *sentence-piece*.
3. Fitur spasial (x, y, tinggi, lebar) dijumlahkan ke *embedding* teks.
4. Urutan teks dan citra disambung lalu masuk *encoder*.
5. *Decoder* membangkitkan jawaban.

Model. Transformer *encoder-decoder*, varian *small*, *base*, dan *large* (750 juta parameter). Pralatihnya dibuat asimetris:

- dua tugas di *encoder*: *token-to-line* (jarak baris antar token) dan *token-to-grid* (letak token di kisi halaman 4×4);
- satu tugas di *decoder*: *denoising language modeling*.

Metode fusion. Fusion awal dalam satu *encoder*. Token visual dan token teks disambung pada dimensi urutan, dan setiap modalitas diberi *embedding* penanda modalitas.

Hasil.

- DocVQA: ANLS 87,84 dan InfographicsVQA 48,8. Keduanya setelah pelatihan tambahan dengan 850 ribu pasangan tanya-jawab dokumen.
- FUNSD: F1 88,89. CORD: F1 97,7.
- TabFact: 4,3 poin di atas model terbaik sebelumnya.

Dua ablasi relevan:

- **Ketahanan terhadap galat OCR buatan di FUNSD.** Dengan 20% karakter salah, kinerja DocFormerv2 hanya turun 1,68%, sedangkan model *encoder*-saja turun 9,84%.
- Memakai Swinv2 sebagai *encoder* citra justru 4,3% lebih buruk di DocVQA dibanding lapisan linear sederhana.

Hambatan dan *future work*. Tidak disebutkan secara eksplisit. Dari analisis kami: klasifikasi dokumen tidak diuji, mesin OCR pralatih tidak disebutkan, dan pralatihnya memakai 64 juta halaman.

2.5 DocLLM (ACL 2024)

Latar belakang. Model bahasa besar (LLM) standar hanya menerima teks dan mengandaikan tata letak sederhana. LLM multimodal untuk dokumen bergantung pada *encoder* citra yang mahal. DocLLM menambahkan informasi tata letak ke LLM **tanpa *encoder* citra** sama sekali, hanya dari kotak teks OCR (Wang et al., 2024).

Dataset.

- **Pralatih:** IIT-CDIP dan DocBank, total 16,7 juta halaman (3,8 miliar token).
- ***Instruction tuning*:** 16 dataset untuk empat tugas, yaitu tanya-jawab, inferensi bahasa alami, ekstraksi informasi, dan klasifikasi. Untuk klasifikasi dipakai RVL-CDIP (di-*downsample*) dan BizDocs.

Teknologi OCR. Teks dan kotak berasal dari OCR yang disediakan setiap dataset; mesinnya tidak disebutkan. Penulis secara eksplisit menyatakan bahwa **pilihan mesin OCR masih terbuka untuk dieksplorasi**, dan perbandingan praktis antar-mesin OCR dijadikan *future work*. Mereka juga mencatat bahwa model keluarga LayoutLM yang memakai Microsoft Azure OCR mengungguli Tesseract di papan peringkat DocVQA.

Pipeline.

1. Setiap token teks OCR dipasangkan dengan kotaknya (kiri, atas, kanan, bawah).
2. Kotak di-*encode* menjadi vektor spasial terpisah dari vektor teks.
3. Perhatian dihitung dengan mekanisme terurai (lihat bagian fusion).
4. Tugas diberikan sebagai instruksi, misalnya “What type of document is this? Possible choices: . . . ”.

Model. Dibangun di atas LLM yang sudah ada:

- DocLLM-1B, berbasis Falcon-1B;
- DocLLM-7B, berbasis Llama2-7B.

Pralatihnya memakai tujuan *block infilling*: blok teks di-*mask* lalu direkonstruksi dari konteks sebelum dan sesudahnya.

Metode fusion. Tidak ada citra; yang dipadukan adalah teks dan tata letak. Caranya *disentangled spatial attention*: skor perhatian dipecah menjadi teks–teks, teks–spasial, spasial–teks, dan spasial–spasial, masing-masing dengan bobot λ. Konfigurasi akhirnya hanya memakai teks–teks dan spasial–spasial.

Hasil.

- RVL-CDIP: akurasi **91,8%** (7B) dan 90,9% (1B), jauh di atas GPT-4 + OCR *zero-shot* (68,2%).
- Unggul di 14 dari 16 dataset dibanding model sebanding.

Catatan: angka RVL-CDIP ini memakai format pilihan ganda dengan data latih yang di-*downsample*, sehingga tidak sebanding langsung dengan paper lain.

Hambatan dan *future work*.

- Pada dataset yang belum pernah dilihat, akurasi klasifikasinya rendah: 31,1% pada BizDocs. Menurut penulis, ini karena model hanya dilatih dengan satu dataset klasifikasi.
- Penulis berencana menambahkan modalitas citra secara ringan.
- Perbandingan antar-mesin OCR disebut sebagai pekerjaan lanjutan.

2.6 LiLT (ACL 2022)

Latar belakang. Hampir semua model pemahaman dokumen terstruktur hanya untuk satu bahasa, biasanya Inggris. Satu-satunya model multibahasa (LayoutXLM) butuh pengumpulan data 53 bahasa yang mahal. LiLT memisahkan pengetahuan tata letak dari bahasa, sehingga tata letak yang dipelajari dari dokumen Inggris dapat dipakai untuk bahasa lain (Wang, Jin dan Ding, 2022).

Dataset.

- **Pralatih:** IIT-CDIP (11 juta citra).
- **Evaluasi:** FUNSD, CORD, EPHOIE, RVL-CDIP, dan XFUND (delapan bahasa).

Teknologi OCR. Teks dan kotak IIT-CDIP diekstrak dengan **TextIn API** (komersial). Setiap token memakai kotak dari baris teks tempatnya berada, karena tidak semua mesin OCR memberikan kotak per token.

Pipeline.

1. Teks OCR diurutkan dari kiri-atas ke kanan-bawah, lalu ditokenisasi.
2. Kotak dinormalkan ke rentang 0–1000 menjadi urutan posisi 2D.
3. Aliran teks dan aliran tata letak diproses dua Transformer paralel.
4. Keluaran keduanya disambung untuk *head* tugas.

Citra tidak dipakai.

Model. Transformer dua aliran:

- aliran teks diinisialisasi dari model bahasa siap pakai (RoBERTa, XLM-R, InfoXLM);
- aliran tata letak lebih kecil, hanya 6,1 juta parameter tambahan.

Pralatihnya memakai MVLM ditambah dua tugas baru: *key point location* dan *cross-modal alignment identification*.

Metode fusion. *Bi-directional attention complementation mechanism* (BiACM): skor perhatian aliran teks dan aliran tata letak saling dijumlahkan di setiap lapis, lalu fitur keduanya disambung di keluaran.

Ablasinya relevan untuk pilihan fusion. Menyambung fitur teks dan tata letak **hanya di keluaran**, tanpa interaksi antar-aliran, **lebih buruk daripada aliran teks saja**. *Co-attention* yang lebih "dalam" juga menurunkan kinerja.

Hasil.

- RVL-CDIP: akurasi **95,68%** dengan RoBERTa Inggris.
- FUNSD: F1 88,41. CORD: F1 96,07.
- Unggul atas LayoutXLM di delapan bahasa XFUND, padahal hanya dipralatih dengan data Inggris.

Satu catatan: paper LayoutLMv3 menyebut LiLT memakai fitur citra ResNeXt101-FPN saat *fine-tuning* RVL-CDIP.

Hambatan dan *future work*. Penulis akan:

- melanjutkan pola transfer dari satu bahasa ke banyak bahasa;
- mengeksplorasi informasi visual yang tidak bergantung bahasa.

2.7 Review Fusion untuk Klasifikasi Dokumen (Information Fusion 2026)

Latar belakang. Riset fusion untuk klasifikasi dokumen belum punya kerangka bersama. Belum ada pula sintesis kuantitatif tentang seberapa besar sebenarnya keuntungan fusion (Mirończuk, 2026).

Dataset. Bukan dataset eksperimen, melainkan 139 studi primer. Studi itu dipilih dari 374 rekaman Scopus (pencarian 3 Januari 2025) dengan prosedur berbasis PRISMA. Kriterianya:

- berbahasa Inggris;
- membahas klasifikasi dokumen;
- memakai teknik fusion;
- telah ditinjau sejawat.

Teknologi OCR. Tidak dianalisis tersendiri. Penulis mengakui bahwa kualitas data, termasuk galat OCR, adalah tantangan penting. Namun kualitas OCR **tidak dapat dikontrol** dalam meta-analisis, karena studi primer jarang melaporkannya.

Pipeline.

1. Identifikasi, penyaringan, dan seleksi studi.
2. Sintesis kualitatif dan penyusunan taksonomi.
3. Meta-analisis efek acak (*random-effects*) atas selisih kinerja multimodal dibanding unimodal.

Model. Kerangka formal representasi, pola, dan model, yang menghubungkan arsitektur pembelajaran mesin dengan teori fusion klasik (Bayesian, Dempster–Shafer).

Metode fusion. Fusion dibagi menjadi tiga:

- awal (*early*), di tingkat representasi;
- akhir (*late*), di tingkat keputusan;
- hibrida, gabungan keduanya.

Pada studi multimodal, pasangan teks–citra mendominasi (67,2%).

Hasil.

- Fusion multimodal menaikkan akurasi rata-rata **5,28 poin** ($p = 0{,}0016$).
- Efeknya terhadap F1 positif tetapi tidak signifikan.
- Hanya **11,8%** studi multimodal yang memakai uji statistik.
- Keuntungan multimodal dapat mengecil bila sudah dipakai model bahasa pralatih yang kuat.

Hambatan dan *future work*.

- **Hambatan review ini:** hanya satu basis data (Scopus), dan kualitas data studi primer tidak terkontrol.
- **Hambatan di lapangan:** kelangkaan data, beban komputasi, penyelarasan lintas-modalitas, dan dokumen panjang.
- **Arah lanjutan:** integrasi dengan LLM, pembelajaran representasi kontrastif, penanganan data multimodal yang bising, dan validasi statistik yang lebih ketat.

3 Perbandingan

Tabel 2 merangkum aspek teknis keenam paper eksperimen. Tabel 3 merangkum hambatan dan *future work*-nya.

Tabel 2 Perbandingan teknis paper eksperimen

Paper	OCR	Modalitas	Fusion	RVL-CDIP
LayoutLMv3	Microsoft Read API	teks, tata letak, citra	awal, satu aliran	95,93%
Donut	tidak ada (CLOVA OCR hanya untuk label pralatih)	citra	tidak ada; teks dibaca model	95,30%
UDOP	bawaan dataset	teks, tata letak, citra	sangat awal, dijumlahkan per *patch*	96,00%
DocFormerv2	tidak disebutkan	teks, tata letak, citra	awal, satu *encoder*	tidak diuji
DocLLM	bawaan dataset	teks, tata letak	perhatian terurai teks–spasial	91,8%*
LiLT	TextIn API	teks, tata letak	dua aliran + BiACM	95,68%

Sumber: Dirangkum dari paper masing-masing. *Format pilihan ganda dengan data latih di-*downsample*; tidak sebanding langsung.

Tabel 3 Hambatan dan *future work* setiap paper

Paper	Hambatan	*Future work* dari penulis
LayoutLMv3	bergantung OCR komersial; pralatih sangat mahal	skala lebih besar; *few-shot* dan *zero-shot*
Donut	teks kecil terlewat; resolusi tinggi mahal; DocVQA masih kalah dari model berbasis OCR	perbaikan tujuan pralatih
UDOP	model sangat besar (794 juta parameter); risiko pemalsuan dokumen	adaptasi ke bahasa non-Latin
DocFormerv2	klasifikasi tidak diuji; OCR tidak disebutkan	tidak disebutkan
DocLLM	klasifikasi lemah pada dataset baru	menambah citra secara ringan; **membandingkan mesin OCR**
LiLT	citra tidak dipakai	transfer multibahasa; informasi visual
Mirończuk	satu basis data; kualitas OCR tidak terkontrol	integrasi LLM; data bising; validasi statistik

4 Sintesis dan Celah Penelitian

Dari ketujuh paper, ada empat pola yang terlihat.

1. Mesin OCR diperlakukan sebagai konstanta. Lima paper eksperimen bergantung pada OCR, tetapi masing-masing memakai satu sumber saja:

- Microsoft Read API (LayoutLMv3);
- TextIn API (LiLT);
- OCR bawaan dataset (UDOP, DocLLM);
- mesin yang tidak disebutkan (DocFormerv2).

Hanya Donut yang membandingkan beberapa mesin OCR, itu pun di lampiran dan untuk ekstraksi informasi (CORD), bukan klasifikasi. Hasilnya kinerja sangat

bergantung pada mesin OCR. DocLLM secara eksplisit menyebut perbandingan mesin OCR sebagai *future work*. Mirończuk mencatat kualitas OCR tidak terkontrol di seluruh bidang.

2. Sumbangan modalitas citra untuk klasifikasi kecil.

- Ablasi LayoutLMv3: teks dan tata letak saja sudah 95,33% di RVL-CDIP; citra hanya menambah sekitar 0,2 poin.
- UDOP: menghapus citra hanya menurunkan DocVQA 0,3 poin.
- LiLT: tanpa citra sudah mencapai 95,68%.
- Mirończuk: keuntungan multimodal mengecil bila sudah dipakai model bahasa yang kuat.

Tidak ada satu pun paper yang menguji apakah model gabungan *benar-benar memakai* setiap modalitas, misalnya lewat uji *missing modality* di tingkat model.

3. Cara fusion beragam. Pilihannya meliputi fusion awal satu aliran (LayoutLMv3, DocFormerv2), penjumlahan per *patch* (UDOP), dua aliran dengan berbagi perhatian (LiLT), perhatian terurai teks–spasial (DocLLM), sampai tanpa OCR sama sekali (Donut). Ablasi LiLT menunjukkan bahwa penggabungan hanya di akhir tanpa interaksi bisa lebih buruk daripada satu modalitas saja.

4. Semuanya bergantung pada pralatih skala besar. Data pralatihnya berkisar 11 juta sampai 64 juta halaman, dengan puluhan GPU. Replikasi pralatih tidak realistis untuk perangkat kelompok (GPU 4 GB). Jalur yang realistis adalah *fine-tuning* model *base* yang dirilis publik pada data kecil seperti Tobacco3482, misalnya LayoutLMv3-*base* (133 juta parameter) atau LiLT.

Celah yang terbuka. Pola 1 dan 2 menunjuk ke pertanyaan yang belum dijawab paper mana pun:

- seberapa besar pilihan mesin OCR open-source (Tesseract, EasyOCR, PaddleOCR) memengaruhi model klasifikasi dokumen berbasis OCR;
- apakah model gabungan benar-benar memanfaatkan modalitas teks yang dihasilkan OCR tersebut.

Donut memberi bukti awal bahwa mesin OCR berpengaruh. DocLLM menyebut pertanyaan ini sebagai pekerjaan lanjutan. Mirończuk menunjukkan bahwa celah ini terjadi di seluruh bidang.

Daftar Referensi

Appalaraju, S., Tang, P., Dong, Q., Sankaran, N., Zhou, Y. dan Manmatha, R., 2024. DocFormerv2: Local Features for Document Understanding. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(2), pp.709-718. Tersedia di: <https://doi.org/10.1609/aaai.v38i2.27828>.

Huang, Y., Lv, T., Cui, L., Lu, Y. dan Wei, F., 2022. LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking. Dalam: *Proceedings of the 30th ACM International Conference on Multimedia*. ACM, pp.4083-4091. Tersedia di: <https://doi.org/10.1145/3503161.3548112>.

Kim, G., Hong, T., Yim, M., Nam, J., Park, J., Yim, J., Hwang, W., Yun, S., Han, D. dan Park, S., 2022. OCR-Free Document Understanding Transformer. Dalam: *Computer Vision – ECCV 2022*. Springer Nature Switzerland, pp.498-517. Tersedia di: <https://doi.org/10.1007/978-3-031-19815-1_29>.

Mirończuk, M.M., 2026. Document classification pattern recognition via information fusion: A systematic review of multimodal and multiview representation approaches. *Information Fusion*, 132, p.104247. Tersedia di: <https://doi.org/10.1016/j.inffus.2026.104247>.

Tang, Z., Yang, Z., Wang, G., Fang, Y., Liu, Y., Zhu, C., Zeng, M., Zhang, C. dan Bansal, M., 2023. Unifying Vision, Text, and Layout for Universal Document Processing. Dalam: *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, pp.19254-19264. Tersedia di: <https://doi.org/10.1109/cvpr52729.2023.01845>.

Wang, D., Raman, N., Sibue, M., Ma, Z., Babkin, P., Kaur, S., Pei, Y., Nourbakhsh, A. dan Liu, X., 2024. DocLLM: A Layout-Aware Generative Language Model for Multimodal Document Understanding. Dalam: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, pp.8529-8548. Tersedia di: <https://doi.org/10.18653/v1/2024.acl-long.463>.

Wang, J., Jin, L. dan Ding, K., 2022. LiLT: A Simple yet Effective Language-Independent Layout Transformer for Structured Document Understanding. Dalam: *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, pp.7747-7757. Tersedia di: <https://doi.org/10.18653/v1/2022.acl-long.534>.