ANALISIS & PEMROSESAN DATA MULTIMODAL

Laporan Temuan EDA: Kurasi Dataset dan Karakteristik Modalitas Tobacco3482

Disusun oleh:

Yulian Anggreaif Rudamaga	:	256150100011001
Zalzabila Rani	:	256150100011008
Ramadhani Al-Qadri	:	256150100011010

Dosen Pengampu:
Dr. Eng. Fitra Abdurrachman Bachtiar, S.T., M.Eng.

PROGRAM STUDI MAGISTER ILMU KOMPUTER
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA

1 Pendahuluan

Laporan ini merangkum hasil kurasi dataset dan *exploratory data analysis* (EDA) atas Tobacco3482 (Kumar, Ye dan Doermann, 2014). Dataset ini terdiri atas dua modalitas:

- **citra halaman**, berupa versi JPG dari Kaggle (patrickaudriaz, 2026);
- **teks OCR** dari QS-OCR (QuickSign, 2026), hasil Tesseract (Smith, 2007).

Seluruh angka berasal dari eksekusi notebook `11_eda.ipynb`. Notebook itu tidak melatih model; fitur diambil dari model yang dibekukan.

Analisis yang memakai label hanya memakai bagian latih seed 42 (800 dokumen). Analisis ini mencakup kata khas per kelas, kemiripan antar-kelas, dan classifier kode ID. Data uji hanya dipakai untuk mengukur akurasi *probe*. Dengan cara ini EDA tidak "mengintip" data uji yang nanti dipakai eksperimen.

Perbandingan antar-mesin OCR belum termasuk di sini. Bagian itu menyusul setelah OCR multi-mesin dijalankan.

2 Dataset dan Kurasi

2.1 Pembagian Data

Ke-3.482 pasangan citra–teks lengkap; tidak ada citra atau teks yang hilang. Kelasnya timpang, dengan rasio kelas terbesar (Memo, 620) berbanding terkecil (Resume, 120) sebesar 5,17.

Pembagian data mengikuti Audebert et al. (2020): 800 dokumen latih dan sisanya uji. Setiap pembagian terstratifikasi per kelas, untuk tiga seed (42, 43, 44). Komposisinya identik di ketiga seed (Tabel 1); yang berbeda hanya dokumen yang terpilih.

Tabel 1 Jumlah dokumen per kelas pada setiap bagian (sama untuk seed 42, 43, 44)

	Advertisement	Email	Form	Letter	Memo	News	Note	Report	Resume	Scientific	**Total**
Train	48	124	89	117	128	39	41	55	25	54	720
Val	5	14	10	13	14	4	5	6	3	6	80
Test	177	461	332	437	478	145	155	204	92	201	2.682

2.2 Aturan Kurasi

Kurasi dilakukan dengan **menandai** dokumen, bukan membuangnya. Derau OCR adalah objek penelitian, sehingga dokumen yang bising tetap dipakai dan hanya diberi penanda.

Ambang setiap penanda diambil dari ekor distribusi: 5% terbawah, atau 5% teratas untuk OOV. Ambang ini tidak ditetapkan sebelum melihat data. Hasilnya disajikan pada Tabel 2.

Tabel 2 Penanda kurasi, ambang yang diperoleh dari data, dan jumlah dokumen tertandai

Penanda	Aturan (ambang dari data)	Dokumen
Teks kosong	tidak ada kata alfabetik sama sekali	37
Teks pendek	$\leq$ 23 kata alfabetik (di antara yang tidak kosong)	163
OOV tinggi	OOV $\geq$ 0,369	172
Resolusi rendah	perkiraan $<$ 203 dpi	68
Ketajaman rendah	variansi Laplacian $<$ 788	175
Duplikat	korelasi *thumbnail* $\geq$ 0,98 dan teks mirip	9

Duplikat diperiksa dalam dua tahap. Tahap pertama mencari pasangan halaman yang *thumbnail*-nya sangat mirip. Tahap kedua mengonfirmasi pasangan itu lewat kemiripan teks OCR-nya. Dua tahap diperlukan karena halaman dokumen sebagian besar putih: kemiripan citra saja akan menyamakan formulir yang isinya berbeda tetapi templatnya sama.

Hasilnya 12 pasangan yang melibatkan 9 dokumen. Pasangan yang melintasi bagian latih dan uji, yaitu kebocoran data, ada 1 pada seed 42, 5 pada seed 43, dan 4 pada seed 44.

Ada satu catatan. Enam dari sembilan dokumen duplikat berasal dari kelas Advertisement, kelas yang juga paling banyak teks kosongnya. Pasangan yang *keduanya* tanpa teks dikonfirmasi otomatis, karena tidak ada teks untuk dibandingkan. Karena itu duplikat ini perlu diperiksa secara visual sebelum dipakai untuk mengubah pembagian data.

Hasil kurasi disimpan sebagai `manifest_kurasi.csv`. Isinya satu baris per dokumen: label, kolom pembagian untuk ketiga seed, seluruh statistik dan penanda, serta penanda kebocoran. Berkas citra dan teks sendiri tidak disalin, karena lisensi Tobacco3482 tidak memperbolehkan redistribusi.

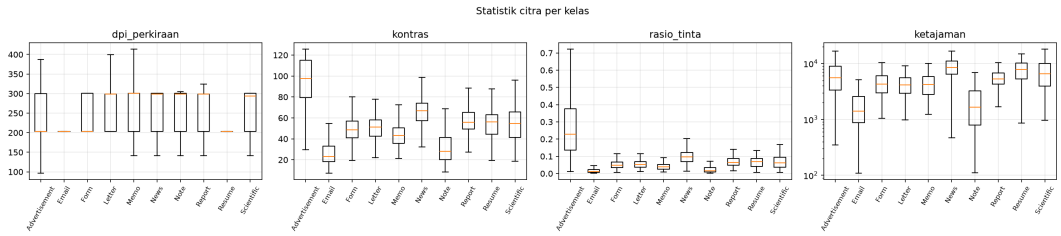
3 Modalitas Citra

3.1 Statistik Halaman

Citra JPG dari Kaggle beresolusi tinggi:

- lebar median 1.728 piksel, sekitar 203 dpi untuk kertas *letter*;
- kuartil atas 2.544 piksel, sekitar 299 dpi;
- rentangnya 96 sampai 414 dpi.

Statistiknya per kelas ditunjukkan Gambar 1.



Gambar 1 Statistik citra per kelas: perkiraan DPI, kontras, rasio tinta, dan ketajaman (skala log)

Gambar 1 memperlihatkan tiga hal.

1. **Resolusi tidak seragam antar-kelas.** Pada Email dan Resume, median dan kedua kuartilnya sama-sama 203 dpi. Kelas lain umumnya menyebar antara 203 dan 300 dpi. Resolusi asli memang hilang setelah citra diubah ke 384×384, tetapi pola ini menunjukkan bahwa kelas-kelas tersebut dipindai dengan cara berbeda. Ini sumber potensi bias.
2. **Advertisement jauh lebih gelap.** Kontras dan rasio tintanya paling tinggi, karena halaman iklan didominasi gambar, bukan tulisan.
3. **Email dan Note paling jarang tintanya**, sehingga ketajamannya juga paling rendah. Ukuran ketajaman (variansi Laplacian) bergantung pada jumlah tepi. Halaman yang hanya berisi sedikit tulisan otomatis mendapat skor rendah walaupun tidak kabur. Karena itu penanda "ketajaman rendah" harus dibaca sebagai "sedikit tulisan atau kabur", bukan semata "kabur".

3.2 Fitur CNN

Fitur 1.280 dimensi diambil dari MobileNetV2 berbobot ImageNet tanpa *fine-tune* (Sandler et al., 2018). Regresi logistik di atas fitur beku ini (*linear probe*) mencapai **OA 0,7293** dan macro F1 0,7099. Sebagai pembanding, menebak kelas mayoritas hanya mencapai 0,1782. Jadi tata letak halaman sudah sangat informatif bahkan tanpa pelatihan khusus dokumen.

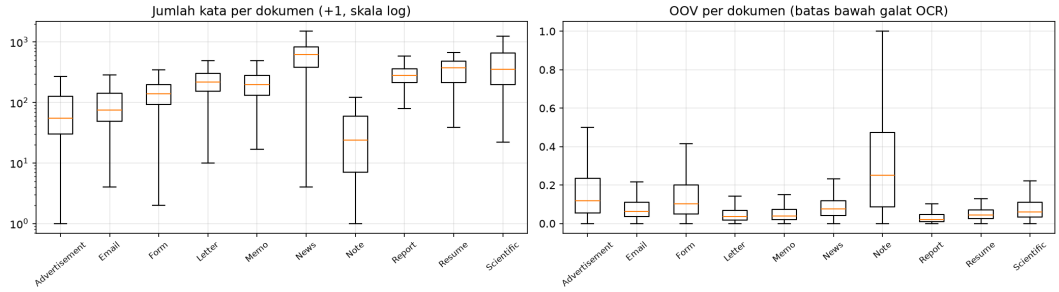
Pada proyeksi t-SNE (Gambar 3, kiri), Email, Advertisement, Form, News, Resume, dan Scientific membentuk kelompok yang jelas. Letter, Memo, dan Report bercampur di tengah. Ketiganya adalah dokumen ketikan berparagraf yang tata letaknya mirip.

4 Modalitas Teks

4.1 Statistik Teks

- **Panjang:** median 174 kata per dokumen, rata-rata 224, maksimum 1.579.
- **Teks kosong:** 37 dokumen tidak menghasilkan satu pun kata alfabetik.
- **OOV:** median 5,5%, rata-rata 9,8%. OOV di sini adalah bagian kata alfabetik minimal empat huruf yang tidak ada dalam daftar kata bahasa Inggris `wordfreq` (Speer, 2023).

Daftar kata itu longgar: salah baca yang kebetulan berupa kata yang ada, misalnya `tbe` untuk `the`, tidak terhitung. Jadi angka OOV ini adalah *batas bawah* galat OCR. Audebert et al. melaporkan sekitar 26%, tetapi dengan kamus yang lebih ketat, sehingga kedua angka tidak dapat dibandingkan langsung.



Gambar 2 Jumlah kata dan OOV per dokumen menurut kelas

4.2 Kata Khas per Kelas

Kata dengan bobot TF-IDF tertinggi per kelas (Tabel 3) menunjukkan bahwa teks OCR membawa penanda kelas yang kuat. Contohnya:

- peringatan *surgeon general* pada Advertisement;
- kepala surel pada Email;
- istilah akademik pada Resume dan Scientific.

Kelas Note berbeda. Daftarnya berisi potongan kata seperti `ore`, `ous`, dan `vay`, yang menandakan teks hasil OCR dari tulisan tangan atau catatan pendek yang rusak.

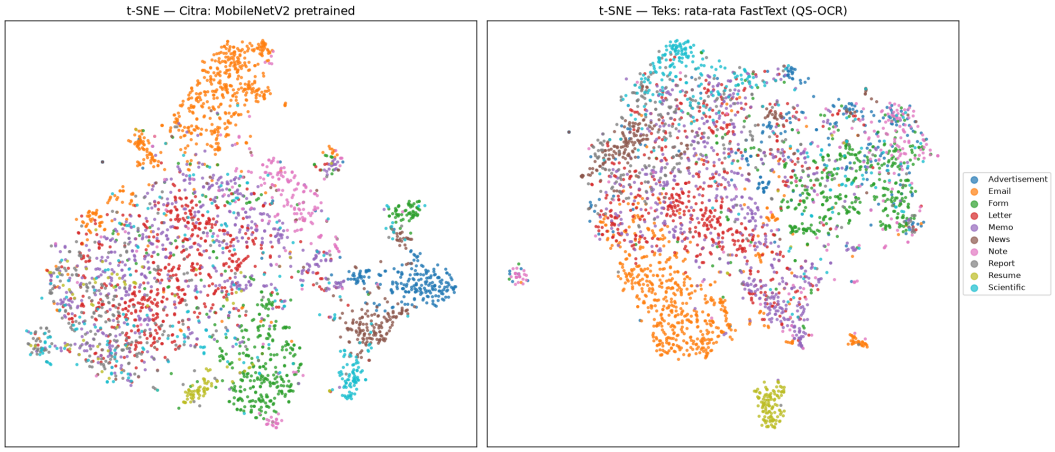
Tabel 3 Kata TF-IDF tertinggi per kelas (dihitung dari bagian latih seed 42)

Kelas	Kata khas
Advertisement	warning, surgeon, cigarette, general, advertisement, smoking, tar, nicotine
Email	sent, subject, message, original, wednesday, date, thanks, meeting
Form	date, fax, number, pages, form, total, transmission, telephone
Letter	tobacco, dear, research, new, sincerely, york, product, council
Memo	correspondence, attached, memorandum, inter, office, subject, date
News	said, smoking, health, smoke, tobacco, smokers, cancer, industry
Note	desk, information, james, ore, web, ous, christine, ran, vay, site
Report	tobacco, smoking, cigarette, products, smokers, study, test, research
Resume	university, research, biology, assistant, professor, medicine, publications
Scientific	cell, cells, research, results, study, induced, university, data

4.3 Fitur Embedding Teks

Setiap dokumen direpresentasikan sebagai rata-rata vektor FastText kata-katanya (Bojanowski et al., 2017). *Linear probe* di atas representasi ini mencapai **OA 0,6685** dan macro F1 0,6491. Angka ini lebih rendah daripada citra (0,7293), tetapi jauh di atas kelas mayoritas.

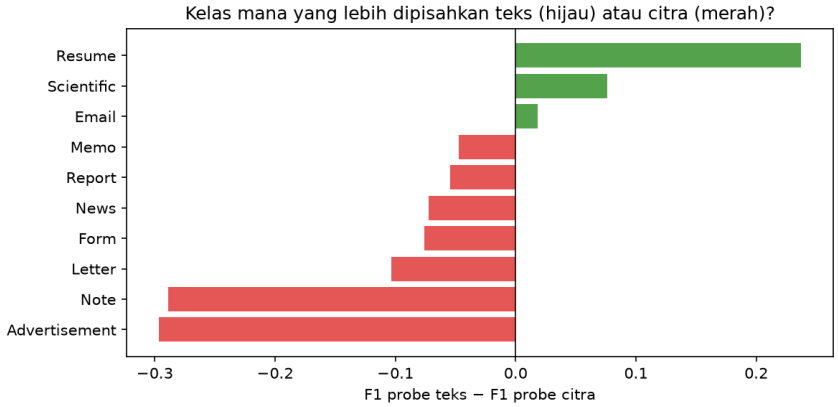
Pada t-SNE (Gambar 3, kanan), Resume dan Email membentuk kelompok yang sangat jelas, Scientific mengelompok di bagian atas, dan Form di sisi kanan. Pola pengelompokannya berbeda dari citra. Perbedaan inilah yang menjadi dasar harapan bahwa kedua modalitas saling melengkapi.



Gambar 3 Proyeksi t-SNE fitur citra (kiri) dan fitur teks (kanan), diwarnai menurut kelas

5 Komplementaritas Kedua Modalitas

Gambar 4 membandingkan F1 *probe* per kelas antara teks dan citra.



Gambar 4 Selisih F1 *probe* teks dikurangi citra per kelas

- **Teks lebih unggul** pada Resume (+0,237), Scientific (+0,076), dan Email (+0,018). Resume adalah contoh terkuat: tata letaknya beragam, tetapi kosakatanya sangat khas.
- **Citra lebih unggul** pada Advertisement (−0,297) dan Note (−0,289). Keduanya adalah kelas yang teksnya paling sering hilang atau rusak (Subbagian 6).
- **Selisihnya kecil** ($< 0{,}11$) untuk Letter, Form, News, Report, dan Memo.

Ini *probe* pada fitur beku dengan 800 dokumen latih, bukan model akhir. Namun arahnya memberi gambaran awal di kelas mana modalitas teks diharapkan menyumbang paling banyak.

6 Modalitas Hilang dan Bising

Persentase dokumen tertandai per kelas disajikan pada Tabel 4.

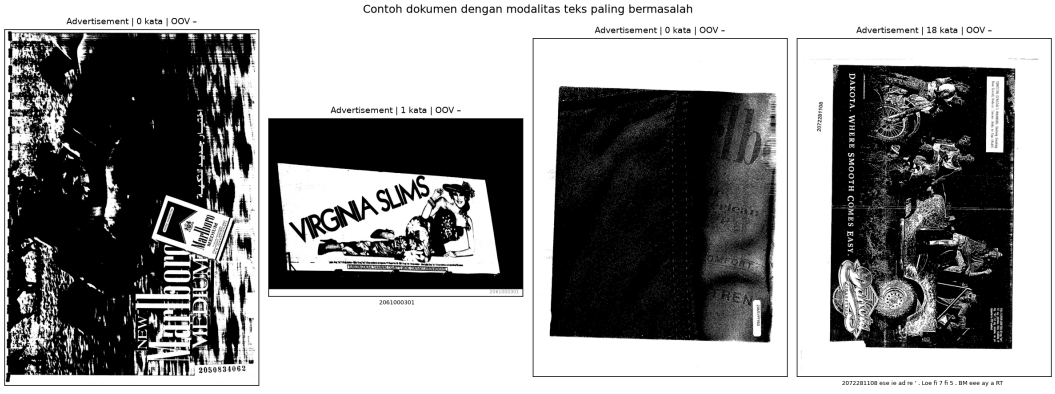
Tabel 4 Persentase dokumen tertandai per kelas

Kelas	Teks kosong	Teks pendek	OOV tinggi	Resolusi rendah	Ketajaman rendah	Duplikat
Advertisement	3,5	17,4	13,0	3,9	2,2	2,6
Email	0,0	4,2	0,2	0,0	19,9	0,3
Form	0,0	1,4	10,7	0,0	0,0	0,0
Letter	0,0	0,2	0,2	0,0	0,0	0,0
Memo	0,0	0,2	0,6	6,5	0,0	0,0
News	0,0	2,1	8,0	3,7	0,5	0,5
Note	14,4	41,3	30,8	2,0	24,9	0,0
Report	0,0	0,0	1,5	1,9	0,0	0,0
Resume	0,0	0,0	0,0	1,7	0,0	0,0
Scientific	0,0	1,1	3,4	0,4	0,0	0,0
Semua	1,1	4,7	4,9	2,0	5,0	0,3

Modalitas teks paling bermasalah pada Note. Sebanyak 14,4% dokumennya tanpa teks sama sekali, 41,3% teksnya pendek, dan 30,8% OOV-nya tinggi. Note sering berupa catatan tulisan tangan, yang memang di luar kemampuan OCR cetak.

Advertisement menyusul, dengan 17,4% teks pendek dan 13,0% OOV tinggi. Form juga banyak ber-OOV tinggi (10,7%), karena isinya angka, kode, dan singkatan.

Mengapa iklan kehilangan teksnya. Gambar 5 memperlihatkan dokumen yang teksnya paling bermasalah. Beberapa iklan dipindai dalam posisi **terputar 90°**. Tesseract pada konfigurasi QS-OCR (`--psm 3`) tidak mendeteksi orientasi, sehingga teks pada halaman terputar tidak terbaca. Temuan ini relevan untuk perbandingan mesin OCR berikutnya: mesin dengan koreksi orientasi dapat berbeda jauh justru pada kelas ini.



Gambar 5 Contoh dokumen dengan modalitas teks paling bermasalah

Dokumen yang hanya satu modalitasnya bermasalah adalah tempat fusion seharusnya paling menolong. Teks bermasalah dengan citra baik paling banyak

ditemukan pada Note (101 dokumen), Advertisement (62), dan Form (48). Citra bermasalah dengan teks baik paling banyak pada Email (94) dan Memo (38).

Angka Email perlu dibaca hati-hati. Seluruhnya berasal dari penanda ketajaman rendah, yang pada Email lebih mencerminkan sedikitnya tulisan daripada citra yang kabur (Subbagian 3).

7 Jalan Pintas Kode ID Arsip

Larson et al. (2025) menemukan bahwa kode ID arsip yang tercetak di halaman Tobacco3482 sudah cukup untuk memprediksi kelas sekitar 60%. Kode semacam itu ikut terbaca OCR. Dengan deteksi heuristik (deret minimal enam digit), kode ID ditemukan dalam teks OCR pada 20% (Memo) sampai 56% (Email) dokumen.

Ada dua uji jalan pintas, keduanya memakai classifier yang hanya diberi tiga digit awal kode:

- **dari kode ID dalam teks OCR:** OA 0,2782, hanya 10 poin di atas kelas mayoritas (0,1782);
- **dari tiga karakter awal ID berkas:** OA **0,4720**.

Jadi sistem penomoran arsip memang membawa informasi kelas. Model penelitian ini tidak melihat nama berkas, sehingga jalan pintas kedua tidak berlaku untuk model kita. Jalan pintas pertama tampak lemah, tetapi heuristik di sini lebih kasar daripada anotasi manual Larson et al., sehingga belum dapat dinyatakan tidak ada. Kontrol kode ID tetap diperlukan, terutama pada tahap yang memakai posisi teks.

8 Implikasi untuk Eksperimen

1. **Pembagian data dipertahankan.** Hanya 1 sampai 5 pasangan duplikat melintasi latih dan uji per seed. Pasangan ini akan diperiksa visual dulu, lalu dilaporkan atau dikeluarkan dari data uji, bukan dengan membuat pembagian baru.
2. **Kelas yang diharapkan paling diuntungkan teks adalah Resume, Scientific, dan Email.** Bila model gabungan tidak membaik di kelas-kelas ini, itu tanda bahwa cabang teks tidak dipakai.
3. **Note dan Advertisement adalah titik lemah teks.** Keduanya juga kelas tempat mesin OCR lain, terutama yang mengoreksi orientasi, paling mungkin membuat perbedaan. Hasil per kelas harus dilaporkan, tidak hanya akurasi total.
4. **Penanda kurasi dapat dipakai untuk analisis per kelompok,** misalnya akurasi model pada dokumen bertanda teks bermasalah dibandingkan dokumen lain.
5. **Bias resolusi antar-kelas** dicatat sebagai keterbatasan dataset.

Daftar Referensi

Audebert, N., Herold, C., Slimani, K. dan Vidal, C., 2020. Multimodal Deep Networks for Text and Image-Based Document Classification. Dalam: *Machine Learning and Knowledge Discovery in Databases: International Workshops of ECML PKDD 2019*. Vol. 1167. Communications in Computer and Information Science. Springer International Publishing, pp.427-443. Tersedia di: <https://doi.org/10.1007/978-3-030-43823-4_35>.

Bojanowski, P., Grave, E., Joulin, A. dan Mikolov, T., 2017. Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics*, 5, pp.135-146. Tersedia di: <https://doi.org/10.1162/tacl_a_00051>.

Kumar, J., Ye, P. dan Doermann, D., 2014. Structural similarity for document image classification and retrieval. *Pattern Recognition Letters*, 43, pp.119-126. Tersedia di: <https://doi.org/10.1016/j.patrec.2013.10.030>.

Larson, S., Duwal, S., Vilnrotter, B., Chakkithara, G., Padwal, V. dan Leach, K., 2025. Spurious Cues in RVL-CDIP and Tobacco3482 Document Classification: The Case of ID Codes. Dalam: *Proceedings of the 2025 ACM Symposium on Document Engineering*. ACM, pp.1-4. Tersedia di: <https://doi.org/10.1145/3704268.3748683>.

patrickaudriaz, 2026. *Tobacco3482 Dataset (JPG)*. Kaggle. Tersedia di: <https://www.kaggle.com/datasets/patrickaudriaz/tobacco3482jpg> [Diakses 28 September 2026].

QuickSign, 2026. *OCRized Text Dataset (QS-OCR)*, *rilis v1.0*. GitHub. Tersedia di: <https://github.com/QuickSign/ocrized-text-dataset> [Diakses 28 September 2026].

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. dan Chen, L.-C., 2018. MobileNetV2: Inverted Residuals and Linear Bottlenecks. Dalam: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, pp.4510-4520. Tersedia di: <https://doi.org/10.1109/cvpr.2018.00474>.

Smith, R., 2007. An Overview of the Tesseract OCR Engine. Dalam: *Ninth International Conference on Document Analysis and Recognition (ICDAR 2007) Vol 2*. IEEE, pp.629-633. Tersedia di: <https://doi.org/10.1109/icdar.2007.4376991>.

Speer, R., 2023. *wordfreq*. Version 3.1.1. Tersedia di: <https://github.com/rspeer/wordfreq>.