ANALISIS & PEMROSESAN DATA MULTIMODAL

Klasifikasi Dokumen Multimodal: Penggabungan Fitur Teks Hasil OCR dan Citra Dokumen

Disusun Oleh:

Yulian Anggreaif Rudamaga	: 256150100011001
Zalzabila Rani	: 256150100011008
Ramadhani Al-Qadri	: 256150100011010

Dosen Pengampu:
Dr. Eng. Fitra Abdurrachman Bachtiar, S.T., M.Eng.

PROGRAM STUDI MAGISTER ILMU KOMPUTER
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA

1. Pendahuluan

Klasifikasi dokumen hasil pindai pada dasarnya bersifat bimodal. Satu halaman membawa informasi pada dua lapis sekaligus, tata letak visual, berupa posisi blok, kerapatan tulisan, tabel, dan tanda tangan, serta isi tekstual, berupa kata kunci penanda jenis dokumen. Pendekatan unimodal hanya memanfaatkan salah satu lapis, sehingga bata atas kinerjanya ditentukan oleh modalitas yang dipilih.

Audebert et al. (2019) mengusulkan arsitektur dua cabang yang menggabungkan fitur citra halaman dengan fitur teks hasil OCR, dan melaporkan peningkatan akurasi diatas kedua baseline unimodal pada dataset Tobacco3482. Penelitian ini mereplikasi arsitektur tersebut beserta kedua strategi penggabungan fiturnya pada dataset yang sama.

2. Problem Statement

Pendekatan unimodal gagal pada dua titik yang dapat diprediksi. Model berbasis citra bingun pada kelas bertata letak mirip, model berbasis teks gagal saat hasil OCR-nya buruk.

a. Seberapa besar akurasi naik ketika kedua modalitas digabung, dibanding memakai satu sumber terbaik saja?
b. Dari dua cara penggabungan yang diuji, mana yang benar-benar bekerja?
c. Apakah model gabungan sungguh memakai kedua sumber, atau sebenarnya hanya mengandalkan satu saja?

3. Modalitas yang Digunakan

Ada dua modalitas yang digunakan, masing-masing diproses satu cabang terpisah yang menghasilkan vektor fitur 128 dimensi.

Aspek	Citra Dokumen	Teks Hasil OCR
Representasi masukan	Grayscale satu halaman pebuh, 384 x 384, tanpa padding (rasio aspek di warp)	Sekuens kata, zero-padded sampai 500 kata
Ekstraksi	-	Tesseract 4.0, mesin LSTM (--oem 1 –psm 3 -1eng)
Encoder Kata	-	FastText 300dimensi, pralatih Common Crawl
Arsitektur	MobileNetV2, bobot awal ImageNet, kanal grayscale diduplikasi tiga kali	CNN 1D bergaya Kim, 4 lapis, filter multi-lebar, max-pooling-through-time
Dimensi fitur keluaran	128 (dari 1280 hasil global average pooling dipetakan lapisan fully connected	128

Tiga keputusan desain dicatat sebagai pilihan sadar, bukan default. Resolusi 384 × 384 jauh di atas 224 standar karena tulisan harus tetap terbaca sebagai tekstur. MobileNetV2 dipilih bukan karena paling akurat, melainkan paling murah secara komputasi, sesuai batas perangkat

yang tersedia. FastText dipilih karena subword n-gram-nya mampu memberi vektor pada kata rusak akibat OCR yang tidak ada di kosakata mana pun.

Tidak ada praproses citra maupun pascaproses teks: salah eja dibiarkan apa adanya, karena ketahanan terhadap derau OCR justru merupakan objek pengujian.

4. Dataset

Kedua dataset digunakan berpasangan: Tobacco3482-jpg untuk modalitas citra dan QS-OCR-Small untuk modalitas teks, keduanya 3.482 dokumen dengan 10 kelas.

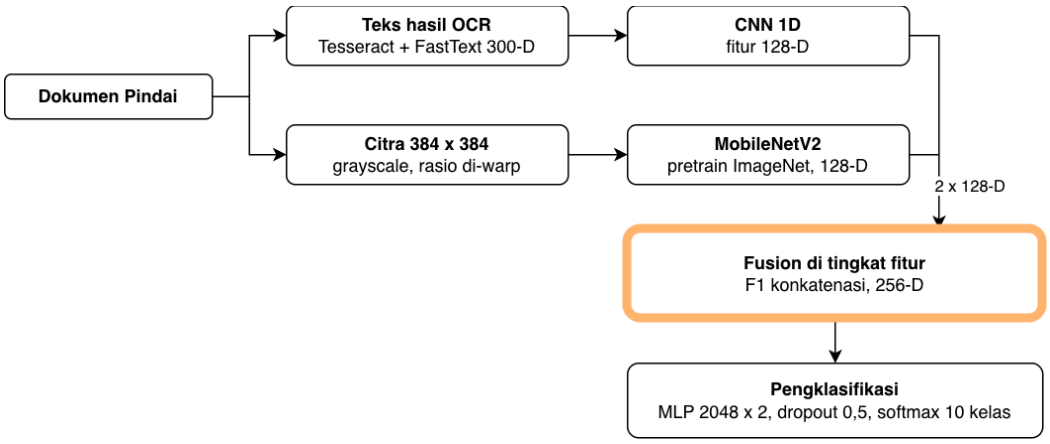
Dataset	Isi	Sumber	Lisensi / status hak
Tobacco3482-jpg	3.482 citra, 10 kelas	Kaggle `patrickaudriaz/tobacco3482jpg`	Kolom lisensi Kaggle: *Other (specified in description)*; deskripsi hanya menyatakan hak milik pemiliknya masing-masing dan merujuk Kumar et al. (2014). Tidak ada lisensi baku.
QS-OCR-Small	3.482 berkas `.txt`	GitHub `QuickSign/ocrized-text-dataset`, rilis v1.0	Apache-2.0 (lisensi repositori, terverifikasi lewat GitHub API). Teks turunan Tobacco3482, sehingga syarat hak sumber hulu tetap berlaku.

Satu limitasi dinyatakan sejak awal. Citra berasal dari versi JPG hasil re-encode, sedangkan teks QS-OCR di-OCR dari TIF asli, sehingga sumber kedua modalitas tidak identik. Hal ini dilaporkan sebagai limitasi, bukan diperlakukan sebagai bug.

Protokol pembagian data mengikuti paper: 800 dokumen latih, sisanya uji, dengan pemecahan acak terstratifikasi.

5. Metode Fusion

Penggabungan dilakukan di tingkat fitur (*intermediate fusion*): kedua cabang dilatih sampai konvergen sebagai pengklasifikasi mandiri, lapisan klasifikasinya dipotong, lalu fiturnya digabungkan dan dilatih bersama secara end-to-end.



Parameter	Konkatenasi (F1)
Operasi	[v_teks; v_citra]
Dimensi hasil	256
Classification Head	MLP dua lapis tersembunyi, lebar 2048, dropout 0,5

6. Metrik Evaluasi

Metrik	Alasan
Overal accuracy (OA)	Metrik utama paper; perlu agar perbandingan langsung dengan angka yang dilaporkan menjadi mungkin.
Macro F1	Kelas timpang (~5:1 terbesar berbanding terkecil). OA sendirian didominasi kelas besar, jadi macro F1 dilaporkan berdampingan, tidak menggantikan.
F1 per kelas + confusion matrix	Keuntungan fusion diperkirakan tidak merata; kelas mana yang membaik menunjukkan modalitas mana menyumbang apa.
Oracle (batas atas)	Benar bila cabang teks atau citra benar. Memungkinkan keuntungan fusion dinyatakan sebagai persentase potensi yang dipanen, bukan selisih mentah.
Missing-modality test	Penurunan akurasi saat satu modalitas dinolkan pada inferensi. Satu-satunya metrik yang dapat membedakan fusion sejati dari dominasi satu cabang.
Ablasi degradasi bertingkat	Rotasi, blur, derau, dan kompresi JPEG pada citra; penghapusan kata dan penyuntikan salah eja pada teks. Menguji klaim ketahanan yang tidak diuji paper.

Seluruh eksperimen dijalankan pada 3 split acak terstrafikasi (seed 42/43/44) dan dilaporkan sebagai rata-rata simpangan baku. Tanpa simpangan antar-seed, selisih beberapa persepuluh persen tidak dapat dibedakan dari derau.

Target replikasi adalah angka yang dilaporkan pada jurnal acuan Tobacco3482: OA 0,738 (teks), 0,845 (citra), 0,878 (fusion), dengan oracle 0,921. Keberhasilan replikasi dinilai dari kedekatan terhadap angka-angka ini, bukan dari apakah fusion melampaui baseline citra.