

Pengaruh Mesin OCR dan Embedding Teks terhadap Pemanfaatan Modalitas Teks pada Klasifikasi Dokumen Multimodal

Proposal Penelitian (revisi) — Analisis dan Pemrosesan Data Multimodal

Ramadhani Al-Qadri

9 Oktober 2026

Ringkasan. Model klasifikasi dokumen multimodal menggabungkan citra halaman dengan teks hasil OCR. Studi terkini memperlakukan mesin OCR sebagai konstanta. Studi acuan yang dipakai di sini [1] bahkan tidak menyebut nama mesin OCR-nya. Selain itu, studi-studi tersebut hanya melaporkan akurasi gabungan.

Replikasi yang telah kami lakukan atas Audebert *et al.* [7] menunjukkan mengapa hal ini bermasalah. Model fusion kami mencapai akurasi 0,834, lebih tinggi dari kedua baseline unimodal. Namun cabang teksnya praktis tidak terpakai: menolak seluruh teks hanya menurunkan akurasi sebesar 0,0015.

Penelitian ini menjadikan **mesin OCR** (Tesseract, EasyOCR, PaddleOCR) dan **embedding teks** (FastText, BERT) sebagai variabel. Yang diukur adalah pengaruhnya terhadap kekuatan cabang teks dan terhadap seberapa jauh model fusion *benar-benar memakai* cabang tersebut. Seluruh perbandingan disertai uji statistik. Dokumen ini memaparkan riwayat pemilihan jurnal, hasil awal yang memotivasi celah penelitian, metodologi, dan rencana implementasi.

Daftar Isi

1 Riwayat penelitian: dari replikasi ke celah penelitian	2
2 Rumusan masalah	5
3 Metodologi	6
4 Rencana implementasi	8
5 Tahap lanjutan: teks sebagai objek	10
A Catatan kritis atas Kashyap <i>et al.</i> (2026)	11

1. Riwayat penelitian: dari replikasi ke celah penelitian

Bagian ini menjelaskan bagaimana arah penelitian terbentuk. Pertanyaan penelitian di Bagian 2 tidak dirumuskan di awal. Pertanyaan itu muncul dari hasil replikasi dan dari tanggapan dosen atas progress awal.

1.1 Pemilihan jurnal awal: Audebert *et al.*

Jurnal pertama yang dipilih adalah Audebert, Herold, Slimani, dan Vidal, *Multimodal deep networks for text and image-based document classification* [7]. Ada empat alasan:

1. **Sesuai topik mata kuliah.** Paper ini menggabungkan dua modalitas yang asalnya sama tetapi sifatnya berbeda: tata letak halaman (citra) dan isi tulisan (teks hasil OCR).
2. **Datanya terbuka.** Citra Tobacco3482 tersedia di Kaggle. Teks OCR-nya dirilis penulis sebagai QS-OCR di GitHub, sehingga modalitas teks tidak perlu dibuat sendiri.
3. **Arsitekturnya ringan.** MobileNetV2 untuk citra dan FastText + CNN 1D untuk teks. Keduanya dapat dilatih pada GPU laptop 4 GB VRAM yang tersedia.
4. **Tidak ada kode resmi.** Repositori QuickSign hanya berisi skrip OCR. Seluruh arsitektur harus ditulis ulang dari spesifikasi paper. Ini latihan yang menuntut pemahaman metode, bukan sekadar menjalankan kode orang lain.

1.2 Hasil replikasi (Fase 1)

Replikasi dijalankan penuh pada Tobacco3482 dengan 3 *split* acak terstratifikasi (seed 42/43/44). Setiap *split* berisi 800 dokumen latih dan 2.682 dokumen uji.

Tabel 1: Hasil replikasi pada Tobacco3482, rata-rata $\pm$ simpangan baku 3 seed.

Model	OA kami	Macro F1 kami	OA paper	Selisih
Teks (FastText + CNN1D)	0,7266 $\pm$ 0,0059	0,7017	0,738	-0,011
Citra (MobileNetV2)	0,8086 $\pm$ 0,0210	0,7837	0,845	-0,036
Fusion konkatenasi	0,8342 $\pm$ 0,0105	0,8105	0,878	-0,044
Fusion penjumlahan berbobot	0,8275 $\pm$ 0,0164	0,7990	tidak dilaporkan	—
Oracle (teks atau citra benar)	0,8977	0,8850	0,921	-0,023

Secara angka, replikasi berhasil. Urutan Teks < Citra < Fusion < Oracle terpenuhi, dan semua angka berada 1–4% di bawah paper. Selisih itu wajar karena framework, protokol *split*, dan format citra berbeda. Korpus teksnya terkonfirmasi identik: rata-rata kata ≥ 4 huruf per dokumen 135, sedangkan paper menyebut 136.

Temuan negatif terhadap paper. Paper menyatakan fusion penjumlahan berada di bawah baseline citra, tanpa menyertakan angka. Hasil kami sebaliknya: 0,8275 berada di atas citra (0,8086), dan tidak dapat dibedakan secara statistik dari konkatenasi.

1.3 Temuan yang mengubah arah: cabang teks tidak terpakai

Paper hanya melaporkan akurasi. Kami menambahkan tiga ablasi yang tidak dilakukan penulisnya. Ketiganya memberi kesimpulan yang sama.

Tabel 2: Ablasi pada model fusion konkatenasi (seed 42, tanpa pelatihan ulang).

Perlakuan saat inferensi	OA	Arti
Utuh	0,8218	acuan
Seluruh teks dinolkan	0,8203	turun hanya 0,0015
Seluruh citra dinolkan	0,0731	runtuh total
0% → 100% kata dihapus	0,8218 → 0,8203	kurva rata
Rotasi 45°: citra saja vs fusion	0,3031 vs 0,1223	fusion lebih rapuh
<i>Blur</i> 8 px: citra saja vs fusion	0,6115 vs 0,5026	fusion lebih rapuh

Model fusion ternyata **diam-diam unimodal**. Kenaikan akurasi di atas baseline citra tidak berasal dari teks. Akibatnya, saat citra rusak, fusion justru lebih rapuh daripada model citra saja. Ini membalik hipotesis kami sendiri sebelum eksekusi, yaitu bahwa teks akan mengompensasi citra yang rusak.

Padahal komplementaritas kedua modalitas jelas ada. Oracle mencapai 0,8977, dan 239 dari 2.682 dokumen uji (8,9%) hanya benar lewat cabang teks.

Diagnosis. Penyebabnya ditelusuri dalam tiga langkah:

1. **Bukan karena pelatihan terlalu singkat.** Tanpa *early stopping*, dengan 200 epoch penuh, cabang teks tetap hanya memanen 9–12% potensi oracle.
2. **Bukan karena strategi penggabungan.** Fusion penjumlahan menunjukkan pola yang sama.
3. **Cabang teks itu sendiri kolaps.** Simpangan fiturnya $38\times$ lebih kecil daripada CNN1D yang dilatih sendirian. Sebanyak 67 dari 128 unit mati. Kemiripan kosinus antar-dokumen 0,978, padahal acuannya 0,650. Skala fiturnya juga $3,72\times$ lebih kecil daripada fitur citra.

Linear probe atas fitur teks yang dibekukan masih mencapai 0,4236, jadi informasinya belum hilang sama sekali. Masalahnya, informasi itu tertutup oleh cabang citra yang skalanya jauh lebih besar.

Perbaikan. Dua perubahan diterapkan: LayerNorm pada tiap cabang, dan inisialisasi cabang teks dari CNN1D yang sudah terlatih.

- *Probe* fitur teks naik ke 0,7468, setara CNN1D sendirian (0,7479).
- Unit mati turun dari 67 menjadi 4.
- Menolkan teks kini menurunkan akurasi 0,689 (sebelumnya 0,007).
- F1 kelas Resume naik dari 0,814 ke 0,968. Angka paper untuk kelas ini 0,96.

Ada ongkosnya: OA turun 0,019, sedangkan macro F1 tetap identik (0,8108). Akurasi berpindah dari kelas besar yang dikuasai citra ke kelas kecil yang membutuhkan teks.

Pelajaran metodologis Fase 1. Akurasi fusion yang tinggi bukan bukti bahwa fusion memakai kedua modalitas. Model yang diam-diam unimodal dapat mencetak akurasi *lebih tinggi* daripada model yang benar-benar multimodal. Tanpa uji *missing modality*, keduanya tidak dapat dibedakan dari tabel hasil.

1.4 Tanggapan dosen atas progress awal

Progress awal dipresentasikan dan menerima tanggapan berikut:

1. Alur klasifikasi dokumen dari OCR ke teks sudah dipahami: Tesseract untuk OCR, FastText untuk embedding.
2. **Eksplorasi metode OCR** dapat dilakukan, misalnya EasyOCR, PaddleOCR, dan Keras-OCR.
3. **Celah penelitian belum ditentukan.**
4. **Eksplorasi pada sisi embedding** dimungkinkan.
5. **Teks yang dideteksi sebagai objek** dipelajari pada tahap selanjutnya.

6. **Referensi jurnal masih salah:** tahun 2019 dan berbentuk arsip (arXiv). Referensi minimal tahun 2025.

Untuk poin 6 perlu dicatat satu hal. Paper Audebert sebenarnya telah terbit di ECML PKDD 2019 Workshops, Springer CCIS vol. 1167 (2020). Kesalahannya ada pada proposal sebelumnya, yang mengutip versi arXiv. Namun tahunnya tetap tidak memenuhi syarat. Karena itu Audebert dipindahkan dari posisi referensi utama menjadi **baseline yang telah direplikasi**.

1.5 Pencarian referensi baru

Pencarian dilakukan melalui Crossref dan Semantic Scholar dengan empat kriteria:

- (i) terbit di jurnal atau prosiding pada 2025 atau sesudahnya, bukan *preprint*;
- (ii) membahas klasifikasi dokumen multimodal teks–citra, perbandingan mesin OCR, atau ketahanan embedding terhadap derau OCR;
- (iii) metadata (DOI, volume, halaman) dapat diverifikasi;
- (iv) teks lengkapnya dapat dibaca, tidak hanya abstraknya.

Hasilnya dirangkum pada Tabel 3.

Tabel 3: Referensi utama dan pendukung (semuanya terbit 2025–2026).

Referensi	Terbit di	Peran dalam penelitian ini
Kashyap <i>et al.</i> [1]	Int. J. Intelligent Systems, 2026	Referensi utama. Fusion teks–citra terkini pada Tobacco3482 (92,00%)
Mironczuk [2]	Information Fusion, 2026	Pembingkai celah: meta-analisis 139 studi fusion untuk klasifikasi dokumen
Francis & Sangeetha [3]	Results in Control and Optimization, 2025	Perbandingan Tesseract, EasyOCR, PaddleOCR, Keras-OCR, dan mesin lain
Zhang <i>et al.</i> [4]	ICCV 2025	Bukti bahwa galat OCR merambat ke tugas lanjutan
Michail <i>et al.</i> [5]	Findings of ACL 2025	Ketahanan embedding terhadap derau OCR
Larson <i>et al.</i> [6]	ACM DocEng 2025	Jalan pintas kode ID di Tobacco3482, wajib dikontrol pada tahap lanjutan

1.6 Mengapa Kashyap *et al.* (2026) sebagai referensi utama

Paper ini merupakan penerus langsung Audebert. Penulisnya menggabungkan EfficientNetB3 (citra) dan BERT (teks OCR) dengan *late fusion* di tingkat keputusan. Mereka membandingkan hasilnya secara eksplisit dengan Audebert pada Tobacco3482. Pembacaan teks lengkapnya menghasilkan tiga hal yang menentukan arah penelitian ini:

1. **Mesin OCR tidak disebutkan.** Paper hanya menyebut “a commercial OCR engine” (§3.4.2). Akibatnya, klaim bahwa BERT lebih baik daripada FastText bercampur dengan efek mesin OCR yang tidak diketahui. Mesin OCR diperlakukan sebagai konstanta, bahkan konstanta tanpa nama.
2. **Fusion berupa rata-rata logit tanpa bobot.** Penulis sendiri menyebut pembobotan modalitas adaptif dan kondisi degradasi OCR yang parah sebagai arah lanjutan (§5).
3. **Ada kegagalan pada protokol evaluasi** yang membuat angkanya tidak sebanding langsung dengan Audebert (Lampiran A).

Paper ini **tidak direplikasi**. Fine-tuning-nya memakan 63 jam pada GPU 16 GB dengan RVL-CDIP (± 400.000 dokumen). Itu di luar kemampuan perangkat yang tersedia. Yang diambil dari paper ini adalah embedding BERT, aturan fusion rata-rata logit, dan arah lanjutan yang disebut penulisnya sendiri.

Audebert juga menyebut arah serupa di bagian penutupnya: embedding yang tahan derau OCR adalah arah riset yang menarik. Dua paper yang terpisah tujuh tahun menunjuk ke persoalan yang sama.

2. Rumusan masalah

2.1 Celah penelitian

Tabel 4 memetakan studi terkait berdasarkan aspek yang menjadi fokus penelitian ini.

Tabel 4: Posisi penelitian terhadap studi terkait.

Studi	Mesin OCR disebut	> 1 mesin OCR	Variasi embedding	Uji missing modality	Simpangan / uji statistik
Audebert <i>et al.</i> [7]	✓	—	MLP vs CNN	—	3 run, tanpa simpangan
Kashyap <i>et al.</i> [1]	—	—	—	—	1 run
Francis & Sangeetha [3]	✓	✓ (7)	tidak ada tugas klasifikasi lanjutan		
Penelitian ini	✓	✓ (3–4)	FastText, BERT	✓	3 seed + McNemar

Celah ini juga terlihat di tingkat lapangan. Meta-analisis Mironczuk [2] menemukan tiga hal:

- fusion multimodal menaikkan akurasi rata-rata 5,28 poin ($p = 0,0016$), tetapi efeknya terhadap F1 tidak signifikan;
- hanya 11,8% studi multimodal yang memakai uji statistik;
- kualitas OCR *tidak dapat dikontrol* dalam meta-analisis itu, karena studi primer tidak melaporkannya.

Celah penelitian. Studi fusion teks–citra untuk klasifikasi dokumen memperlakukan mesin OCR sebagai konstanta dan hanya melaporkan akurasi gabungan. Belum diukur bagaimana **pilihan mesin OCR $\times$ jenis embedding** memengaruhi kekuatan cabang teks. Belum diukur pula **seberapa jauh model fusion benar-benar memakai cabang itu**. Hasil Fase 1 menunjukkan bahwa pertanyaan kedua tidak dapat dijawab dari akurasi saja.

2.2 Pertanyaan penelitian dan hipotesis

Q1. Seberapa besar pilihan mesin OCR (Tesseract, EasyOCR, PaddleOCR) mengubah akurasi cabang teks pada Tobacco3482?

H1: perbedaannya nyata, yaitu melampaui simpangan antar-seed cabang teks ($\pm 0,006$). Mesin modern belum tentu unggul. Tobacco3482 berisi pindaian cetak hitam putih, yaitu kondisi tempat Tesseract paling kuat. Di samping itu, CNN 1D membaca kata *berurutan*, sehingga perbedaan urutan baca antar-mesin dapat berpengaruh walaupun kata yang dibaca sama.

Q2. Apakah embedding kontekstual (BERT) memperkecil selisih antar-mesin OCR dibanding embedding subword statis (FastText)? Dengan kata lain, adakah interaksi OCR $\times$ embedding?

H2: ya. Tokenisasi WordPiece dan konteks kalimat lebih toleran terhadap salah eja. Ada argumen tandingan yang harus diuji: model bahasa standar juga melemah pada teks OCR [5]. Batas 512 token BERT juga memotong dokumen panjang, sedangkan pipeline FastText memakai 500 kata.

Q3. Apakah cabang teks yang lebih kuat membuat model fusion lebih *memakai* teks? Apakah aturan rata-rata logit lebih tahan terhadap cabang yang timpang dibanding fusion fitur?

H3: pada fusion fitur, penurunan akurasi saat teks dinolkan (Δ_{teks}) membesar seiring akurasi cabang teks. Rata-rata logit menjamin kontribusi teks secara konstruksi. Akibatnya Δ_{teks} selalu positif, tetapi OA-nya dapat turun bila cabang teks lemah.

Hipotesis dituliskan *sebelum* eksekusi dan akan dilaporkan apa adanya, termasuk bila keliru. Pada Fase 1, hipotesis ketahanan kami terbukti keliru, dan temuan itu justru menjadi temuan utama.

2.3 Tujuan dan kontribusi


1. Mengukur efek mesin OCR dan embedding terhadap cabang teks dengan desain faktorial dan uji statistik. Ini menjawab kekurangan yang diidentifikasi Mironczuk [2].
2. Mengukur *pemanfaatan* modalitas teks pada setiap kondisi lewat uji *missing modality*, tidak hanya akurasi.
3. Menguji aturan fusion Kashyap [1] pada protokol data kecil (800 dokumen latih) dan membandingkannya dengan fusion fitur yang telah diperbaiki.
4. Menyimpan kotak posisi teks dari setiap mesin sebagai bahan tahap lanjutan, yaitu teks sebagai objek.

2.4 Batasan

- Hanya Tobacco3482. RVL-CDIP tidak dipakai karena ukurannya.
- Kualitas OCR diukur dengan proksi, karena Tobacco3482 tidak memiliki transkripsi acuan (Bagian 3.4).
- Cabang citra dibuat tetap (MobileNetV2) di semua kondisi, supaya perbedaan hasil hanya berasal dari sisi teks.
- Angka kami tidak sebanding langsung dengan Kashyap, yang melatih model pada RVL-CDIP.

3. Metodologi

3.1 Kerangka penelitian



Gambar 1: Kerangka penelitian. Kotak biru adalah variabel yang diuji.

3.2 Dataset dan protokol

Tobacco3482 berisi 3.482 citra dokumen dalam 10 kelas, dengan rasio kelas terbesar berbanding terkecil 5,2:1. Data diambil dari Kaggle ([patrickaudriaz/tobacco3482jpg](https://www.kaggle.com/patrickaudriaz/tobacco3482jpg)) dalam format JPG. Dataset ini tidak memiliki lisensi baku; deskripsinya hanya merujuk Kumar *et al.* [8].

QS-OCR-Small (GitHub QuickSign/ocrized-text-dataset) berlisensi Apache-2.0. Isinya teks Tesseract 4 dari TIF asli, dan dipakai sebagai **kondisi acuan Fase 1**.

Pemakaian dibatasi untuk keperluan akademik non-komersial, dan tidak ada berkas dataset yang didistribusikan. Protokolnya sama dengan Fase 1: 800 dokumen latih per *split* (10% di antaranya untuk validasi), seed 42/43/44. **Indeks split yang sama** dipakai di semua kondisi, sehingga perbedaan antar-kondisi tidak tercampur perbedaan data.

3.3 Ekstraksi OCR multi-mesin

Tabel 5: Mesin OCR dan konfigurasinya.

Mesin	Konfigurasi	Kotak teks
QS-OCR (acu-an)	Tesseract 4.0-beta, TIF asli, --oem 1 --psm 3	tidak tersedia
Tesseract	versi 5, JPG, konfigurasi sama dengan QS-OCR	per kata
EasyOCR	model bahasa Inggris, GPU	per baris
PaddleOCR	PP-OCRV5 <i>mobile</i> , CPU, tanpa koreksi orientasi	per baris
Keras-OCR	<i>bersyarat</i> , lihat risiko R3 di Bagian 4.2	per kata

Ada empat keputusan desain:

1. **Semua mesin membaca citra JPG yang sama**, termasuk Tesseract yang dijalankan ulang. Perbandingan QS-OCR dengan Tesseract-JPG lalu mengukur efek gabungan format citra dan versi Tesseract.
2. **Urutan baca** mesin berbasis kotak (EasyOCR, PaddleOCR) direkonstruksi: baris dari atas ke bawah, kata dari kiri ke kanan. Tesseract memakai urutan bawaannya. Karena CNN 1D peka urutan, perbedaan ini dicatat sebagai bagian dari efek mesin.
3. **Teks dan kotak posisi** setiap halaman disimpan, sehingga tahap lanjutan tidak memerlukan OCR ulang.
4. **Versi pustaka dan nama model dikunci serta dicatat**. PaddleOCR versi terbaru, misalnya, diam-diam mengganti model bawaannya.

3.4 Proksi kualitas OCR

Tobacco3482 tidak memiliki transkripsi acuan, sehingga *character error rate* tidak dapat dihitung. Proksi berikut menggambarkan keluaran OCR tanpa menilai benar-salahnya.

- **Kata per halaman dan persentase halaman kosong.**
- **OOV**: bagian kata alfabetik (≥ 4 huruf) yang tidak terdapat dalam daftar kata bahasa Inggris `wordfreq`:

$$\text{OOV}(d) = \frac{|\{w \in d : |w| \geq 4, w \notin V\}|}{|\{w \in d : |w| \geq 4\}|}.$$

Daftar ini longgar. Salah baca yang kebetulan berupa kata yang ada (misalnya `tbe`) tidak terhitung, sehingga nilai OOV adalah *batas bawah* galat.

- **Kesepakatan antar-mesin**: indeks Jaccard atas himpunan kata (≥ 3 huruf), $J(A, B) = |A \cap B| / |A \cup B|$. Urutan kata sengaja diabaikan.

3.5 Representasi teks

FastText + CNN 1D. Ini pipeline Fase 1 tanpa perubahan. Setiap kata dipetakan ke vektor FastText 300 dimensi [10]. *Subword n-gram* FastText memberi vektor untuk kata yang rusak akibat OCR. Sekuens 500 kata kemudian diproses oleh CNN 1D empat lapis.

BERT-base [9]. Model ini di-*fine-tune*, seperti pada Kashyap, dengan maksimum 512 token. Pelatihan memakai *mixed precision* dan akumulasi gradien agar muat di 4 GB VRAM. Bila tidak muat, model diganti DistilBERT dan penggantian itu dicatat sebagai deviasi.

Teks masuk ke kedua embedding **tanpa** praproses gaya Kashyap (membuang angka dan *stopword*). Tujuannya agar efek embedding tidak tercampur efek praproses.

3.6 Cabang citra

MobileNetV2 [11] berbobot awal ImageNet, dengan masukan 384×384 (rasio aspek di-*warp*). Cabang ini identik dengan Fase 1 dan checkpoint-nya dipakai ulang.

3.7 Strategi fusion

Misalkan $z_t, z_v \in \mathbb{R}^{10}$ adalah logit cabang teks dan citra, serta $v_t, v_v \in \mathbb{R}^{128}$ adalah fitur keduanya.

1. **Rata-rata logit** (aturan Kashyap): $\hat{y} = \arg \max \frac{1}{2}(z_t + z_v)$. Aturan ini tidak memerlukan pelatihan ulang, sehingga dapat diuji untuk *semua* kondisi.
2. **Fusion fitur** (hasil perbaikan Fase 1): $\hat{y} = \arg \max \text{MLP}([\text{LN}(v_t); \text{LN}(v_v)])$. Cabang teks diinisialisasi dari model teks yang sudah terlatih.

3.8 Desain eksperimen

Tabel 6: Matriks eksperimen.

Kelompok	Kondisi	Jumlah run
Cabang teks	4 kondisi OCR $\times$ 2 embedding $\times$ 3 seed	24
Rata-rata logit	setiap model teks di atas + citra Fase 1	24 (tanpa pelatihan)
Fusion fitur	kondisi OCR terbaik dan terburuk, FastText, seed 42	2 (+4 bila waktu cukup)
Uji <i>missing modality</i>	setiap model fusion	tanpa pelatihan

Pemeriksaan kewarasan. Sel QS-OCR $\times$ FastText harus mereproduksi CNN1D Fase 1 ($0,7266 \pm 0,0059$). Bila tidak, ada yang rusak dalam pipeline, dan eksperimen dihentikan sampai penyebabnya ditemukan.

3.9 Metrik dan uji statistik

- **Overall accuracy (OA)**, untuk perbandingan dengan literatur.
- **Macro F1 dan F1 per kelas**, karena kelasnya timpang. Pada Fase 1, OA dan macro F1 terbukti dapat bergerak terpisah.
- **Uji *missing modality***: $\Delta_{\text{teks}} = \text{OA}_{\text{utuh}} - \text{OA}_{\text{teks}}$ dinolkan, dan Δ_{citra} secara analog. Ini metrik yang menjawab Q3.
- **Oracle**: benar bila cabang teks *atau* cabang citra benar. Ini menjadi batas atas teoretis fusion.
- **Uji McNemar** berpasangan antara dua kondisi pada test set yang sama, per seed. Bila b dan c adalah jumlah dokumen yang hanya benar pada salah satu kondisi,

$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c},$$

dengan uji binomial eksak bila $b + c < 25$. Koreksi Holm diterapkan untuk perbandingan berganda. Sebuah perbedaan dinyatakan konsisten bila arahnya sama di ketiga seed.

4. Rencana implementasi

Implementasi dimulai **setelah proposal ini disetujui**. Setiap tahap diakhiri dengan catatan hasil dan pemeriksaan sebelum lanjut ke tahap berikutnya.

Tabel 7: Tahapan implementasi.

Tahap	Kegiatan	Keluaran dan kriteria selesai	Minggu
10	OCR multi-mesin	Teks dan kotak dari 3–4 mesin untuk 3.482 halaman; audit resolusi citra; tabel proksi kualitas; versi pustaka tercatat	1
11a	Grid teks, FastText	12 model ($4 \text{ OCR} \times 3 \text{ seed}$); sel acuan mereproduksi Fase 1; McNemar antar-mesin	2
11b	Grid teks, BERT	12 model; uji interaksi $\text{OCR} \times \text{embedding}$	3
12	Fusion	Rata-rata logit untuk 24 sel; fusion fitur untuk 2 kondisi; Δ_{teks} setiap model	4
13	Sintesis dan laporan	Jawaban Q1–Q3 dengan jejak ke hasil; tabel grid; kurva Δ_{teks} terhadap akurasi teks	5
14	Rancangan teks sebagai objek	Rancangan dan referensi (≥ 2025) untuk tahap lanjutan (Bagian 5)	6

4.1 Perkiraan komputasi

Seluruh komputasi dijalankan pada laptop ASUS TUF: RTX 3050 4 GB VRAM, i7 generasi 11, 24 GB RAM. Angka bertanda * berasal dari eksekusi nyata Fase 1. Angka OCR berasal dari uji kelayakan pada satu halaman sintetis dan akan diukur ulang pada 20 halaman pertama sebelum proses penuh.

Tabel 8: Perkiraan waktu komputasi.

Pekerjaan	Satuan	Total
OCR: Tesseract / PaddleOCR (CPU)	$\pm 0,3$ / ± 2 dtk per halaman	$\pm 0,3$ / ± 2 jam
OCR: EasyOCR (GPU)	diukur saat uji coba	± 1 jam
Ekstraksi fitur FastText	sekali muat model (15 GB RAM)	<1 jam
CNN1D	4,7 menit per run*	± 1 jam (12 run)
BERT-base	perkiraan 10–20 menit per run	2–4 jam (12 run)
Rata-rata logit dan uji <i>missing modality</i>	tanpa pelatihan	menit
Fusion fitur	4,04 jam per run*	± 8 jam (2 run)
Total		$\pm 15\text{--}20$ jam GPU

4.2 Risiko dan mitigasi

Tabel 9: Risiko dan mitigasinya.

	Risiko	Mitigasi
R1	PaddleOCR membawa <code>opencv-contrib-python</code> yang bentrok dengan <code>opencv</code> milik EasyOCR dan menggeser versi <code>numpy</code>	PaddleOCR dijalankan di <i>virtual environment</i> terpisah (± 1 GB); lingkungan utama tidak tersentuh
R2	Tesseract di Windows bukan paket <code>pip</code>	Dipasang lewat <code>winget</code> , dengan langkah manual sebagai cadangan
R3	Keras-OCR membutuhkan TensorFlow dengan API Keras 2, yang tidak tersedia untuk Python 3.12; dependensinya (<code>imgaug</code>) juga tidak cocok dengan <code>numpy</code> baru	Dijalankan di lingkungan Python 3.11 tersendiri bila diwajibkan; bila tidak, cukup tiga mesin untuk menjawab Q1–Q3
R4	BERT-base tidak muat di 4 GB VRAM	<i>Mixed precision</i> , akumulasi gradien, atau DistilBERT (dicatat sebagai deviasi)
R5	Menolkan masukan menghasilkan input di luar distribusi, sehingga Δ melebihi-lebihkan ketergantungan. Pada Fase 1, model yang diperbaiki jatuh ke 0,1223 tanpa teks	Δ dilaporkan bersama <i>linear probe</i> ; ditafsirkan sebagai ukuran ketergantungan, bukan kontribusi informasi
R6	Perbedaan antar-mesin lebih kecil daripada derau antar-seed	Itu tetap merupakan jawaban atas Q1: temuan negatif yang terukur, dengan uji statistik

Uji kelayakan yang telah dilakukan. Ketiga mesin OCR telah dijalankan pada satu halaman memo sintesis, dan ketiganya membaca seluruh baris dengan benar. Pengujian ini juga mengungkap risiko R1, R3, dan penggantian model bawaan PaddleOCR *sebelum* dataset disentuh. Seluruh notebook dirancang untuk dijalankan langsung (*Run All*), dengan dependensi yang dipasang dari dalam notebook.

4.3 Hasil yang diharapkan dan kriteria keberhasilan

Keberhasilan diukur dari *kelengkapan dan ketelitian jawaban*, bukan dari arah hasilnya:

1. Grid OCR $\times$ embedding lengkap, dengan simpangan antar-seed dan uji McNemar.
2. Setiap model fusion memiliki Δ_{teks} dan Δ_{citra} .
3. Setiap hipotesis dinyatakan terdukung atau tidak, dengan merujuk ke angka sumbernya.

Bila mesin OCR ternyata tidak berpengaruh, itu jawaban yang sah dan informatif. Artinya, celah yang diidentifikasi Mirończuk tidak berdampak pada dataset ini.

5. Tahap lanjutan: teks sebagai objek

Sesuai arahan dosen, tahap berikutnya memperlakukan teks bukan hanya sebagai rangkaian kata, tetapi sebagai **objek berposisi** pada halaman. Bahannya sudah tersedia dari Tahap 10, karena setiap mesin menyimpan kotak teksnya. Ada tiga kandidat representasi:

1. fitur posisi 2D di samping embedding kata, mengikuti gaya LayoutLM;
2. peta kotak teks sebagai citra, yaitu teks digambar sebagai kotak berwarna (pendekatan Noce *et al.* yang dikutip Kashyap);
3. graf antar-kotak teks.

Satu kontrol bersifat wajib. Dokumen Tobacco3482 bercap **kode ID** arsip pada posisi yang konsisten. Fitur yang diturunkan dari kode ID saja sudah memberi $\pm 60\%$ akurasi di Tobacco3482 [6].

Model berbasis posisi bisa belajar jalan pintas ini, alih-alih belajar tata letak dokumen. Karena itu setiap model diuji dengan dan tanpa kotak kode ID. Hal yang sama perlu diperiksa mundur pada cabang teks, karena OCR membaca kode ID sebagai token.

Granularitas kotak berbeda antar-mesin: Tesseract per kata, sedangkan EasyOCR dan PaddleOCR per baris. Perbedaan ini harus diperhitungkan saat merancang representasi. Rancangan rinci dan referensi ≥ 2025 untuk tahap ini akan diajukan tersendiri setelah Tahap 13.

A. Catatan kritis atas Kashyap *et al.* (2026)

1. **Angka 92,00% pada Tobacco3482 tidak konsisten dengan protokolnya sendiri.** Model dilatih pada 16 kelas RVL-CDIP. Penulis sendiri menyatakan bahwa kelas Note dan Report hanya ada di Tobacco3482 (§3.3). Kedua kelas itu berisi $201 + 265 = 466$ dokumen, yang tidak mungkin diprediksi benar oleh model 16 kelas RVL-CDIP. Bila seluruh 3.482 dokumen dievaluasi, akurasi maksimum yang mungkin adalah $3016/3482 = 86,6\%$. Tabel per kelas paper memang hanya memuat 8 kelas. Kemungkinan besar 92% dihitung pada ± 3.016 dokumen, padahal Tabel 2 paper menyebut 3.482 dokumen dan 10 kelas.
2. **Perbandingan dengan Audebert tidak setara.** Tabel 4 paper menyandingkan 92,00% (dilatih pada 320.000 dokumen RVL-CDIP) dengan 87,8% Audebert (dilatih pada 800 dokumen Tobacco3482) tanpa menyebut perbedaan protokol itu.
3. **Potensi tumpang tindih data tidak dibahas.** RVL-CDIP dan Tobacco3482 sama-sama diambil dari arsip IIT-CDIP. Hal ini belum kami verifikasi, karena verifikasinya membutuhkan RVL-CDIP.
4. **Satu kali run**, tanpa simpangan baku dan tanpa uji statistik. Metrik Tobacco3482 dilaporkan dalam bentuk *weighted*, bukan macro.
5. **Mesin OCR tidak disebutkan**, sehingga cabang teksnya tidak dapat direproduksi.

Pustaka

- [1] A. Kashyap, M. Mittal, S. Singh, “Multimodal fusion and supervised contrastive learning for robust document image classification,” *International Journal of Intelligent Systems*, vol. 2026, art. 4241437, 2026. doi:10.1155/int/4241437.
- [2] M. M. Mirończuk, “Document classification pattern recognition via information fusion: A systematic review of multimodal and multiview representation approaches,” *Information Fusion*, vol. 132, art. 104247, 2026. doi:10.1016/j.inffus.2026.104247.
- [3] S. A. Francis, M. Sangeetha, “A comparison study on optical character recognition models in mathematical equations and in any language,” *Results in Control and Optimization*, vol. 18, art. 100532, 2025. doi:10.1016/j.rico.2025.100532.
- [4] J. Zhang, Q. Zhang, B. Wang, L. Ouyang, Z. Wen, Y. Li, K.-H. Chow, C. He, W. Zhang, “OCR hinders RAG: Evaluating the cascading impact of OCR on retrieval-augmented generation,” in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2025, pp. 17443–17453. doi:10.1109/ICCV51701.2025.01620.
- [5] A. Michail, J. Opitz, Y. Wang, R. Meister, R. Sennrich, S. Clematide, “Cheap character noise for OCR-robust multilingual embeddings,” in *Findings of the Association for Computational Linguistics: ACL 2025*, 2025.
- [6] S. Larson, S. Duwal, B. Vilnrotter, G. Chakkithara, V. Padwal, K. Leach, “Spurious cues in RVL-CDIP and Tobacco3482 document classification: The case of ID codes,” in *Proc. ACM Symposium on Document Engineering (DocEng)*, 2025. doi:10.1145/3704268.3748683.
- [7] N. Audebert, C. Herold, K. Slimani, C. Vidal, “Multimodal deep networks for text and image-based document classification,” in *Machine Learning and Knowledge Discovery in Databases: ECML PKDD 2019 Workshops*, CCIS vol. 1167, Springer, 2020, pp. 427–443. doi:10.1007/978-3-030-43823-4_35.
- [8] J. Kumar, P. Ye, D. Doermann, “Structural similarity for document image classification and retrieval,” *Pattern Recognition Letters*, vol. 43, pp. 119–126, 2014.

- [9] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proc. NAACL-HLT*, 2019, pp. 4171–4186.
- [10] P. Bojanowski, E. Grave, A. Joulin, T. Mikolov, “Enriching word vectors with subword information,” *Transactions of the ACL*, vol. 5, pp. 135–146, 2017.
- [11] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L.-C. Chen, “MobileNetV2: Inverted residuals and linear bottlenecks,” in *Proc. IEEE/CVF CVPR*, 2018, pp. 4510–4520.