ANALISIS & PEMROSESAN DATA MULTIMODAL

Pengaruh Mesin OCR dan Embedding Teks terhadap Pemanfaatan Modalitas Teks pada Klasifikasi Dokumen Multimodal

Disusun oleh:

Yulian Anggreaif Rudamaga	:	256150100011001
Zalzabila Rani	:	256150100011008
Ramadhani Al-Qadri	:	256150100011010

Dosen Pengampu:
Dr. Eng. Fitra Abdurrachman Bachtiar, S.T., M.Eng.

PROGRAM STUDI MAGISTER ILMU KOMPUTER
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA

1 Pendahuluan

1.1 Latar Belakang

Dokumen hasil pindai menyimpan informasi pada dua lapis sekaligus. Lapis pertama adalah **tata letak**: posisi blok, kerapatan tulisan, tabel, kop surat, dan tanda tangan. Lapis kedua adalah **isi tekstual**: kata-kata seperti *Dear Sir*, *Memorandum*, atau *Curriculum Vitae*, yang langsung menandai jenis dokumen. Lapis pertama terlihat langsung pada citra. Lapis kedua tersembunyi di dalam piksel, sehingga harus dikeluarkan lebih dulu melalui *optical character recognition* (OCR). Karena teksnya diturunkan dari citra, **mutu modalitas teks dibatasi oleh mutu OCR-nya**.

Studi fusion teks–citra untuk klasifikasi dokumen umumnya memperlakukan mesin OCR sebagai konstanta. Contohnya Audebert et al. (2020), yang memakai Tesseract, dan Kashyap, Mittal dan Singh (2026), yang memakai sebuah "mesin OCR komersial" tanpa menyebut namanya. Hasil kedua studi itu juga hanya dilaporkan dalam bentuk akurasi gabungan.

Akurasi gabungan yang lebih tinggi daripada baseline unimodal belum membuktikan bahwa kedua modalitas benar-benar dipakai. Model gabungan dapat saja bertumpu hampir seluruhnya pada cabang yang lebih kuat. Mirończuk (2026) menyebut sulitnya mencapai interaksi lintas-modalitas yang sungguh sinergis sebagai salah satu kelemahan pendekatan multimodal.

Meta-analisis Mirończuk (2026) atas 139 studi juga menemukan dua hal lain. Pertama, kualitas OCR tidak dapat dikontrol dalam analisis tersebut, karena studi primer jarang melaporkannya. Kedua, hanya 11,8% studi multimodal yang memakai uji statistik.

Perbandingan mesin OCR yang ada, misalnya Francis dan Sangeetha (2025), mengukur ketepatan OCR itu sendiri, bukan dampaknya pada tugas yang memakai teks hasil OCR. Padahal galat OCR terbukti merambat ke tugas berikutnya (Zhang et al., 2025). Bagaimana pilihan mesin OCR memengaruhi klasifikasi dokumen multimodal, dan seberapa jauh model gabungan memakai teksnya, belum diukur.

1.2 Dari Progress 1 ke Rencana Ini

Pada Progress 1, kelompok kami mengusulkan replikasi Audebert et al. (2020). Paper ini menggabungkan MobileNetV2 untuk citra halaman dengan FastText dan CNN 1D untuk teks hasil Tesseract, dan diuji pada dataset Tobacco3482. Ada empat alasan memilihnya:

1. topiknya menggabungkan dua modalitas yang asalnya sama tetapi sifatnya berbeda;
2. datanya terbuka, yaitu citra di Kaggle dan teks OCR-nya sebagai QS-OCR;
3. arsitekturnya cukup ringan untuk GPU laptop 4 GB;
4. tidak ada kode resmi, sehingga seluruh arsitektur harus ditulis dari spesifikasi paper.

Tanggapan dosen pengampu atas Progress 1 dan tindak lanjutnya dirangkum pada Tabel 1.

Tabel 1 Tanggapan dosen pengampu atas Progress 1 dan tindak lanjutnya

Tanggapan	Tindak lanjut
Alur OCR → teks dengan Tesseract dan FastText sudah dipahami	Dipertahankan sebagai kondisi acuan
Eksplorasi metode OCR: EasyOCR, PaddleOCR, Keras-OCR	Mesin OCR dijadikan variabel penelitian (RM1)
Celah penelitian belum ditentukan	Dirumuskan pada Subbagian 1.1 dan 2.1.6
Kemungkinan eksplorasi pada embedding	Embedding dijadikan variabel kedua: FastText dan BERT (RM2)
Teks yang dideteksi sebagai objek, untuk tahap selanjutnya	Kotak posisi teks disimpan sejak langkah OCR; rancangannya pada Subbagian 4.5
Referensi masih tahun 2019 dan berbentuk arsip; minimal tahun 2025	Referensi utama diganti ke Kashyap, Mittal dan Singh (2026). Audebert dikutip dari versi terbitnya (Springer, 2020) sebagai pembanding

Soal referensi, perlu dicatat satu hal. Paper Audebert sebenarnya sudah terbit di ECML PKDD 2019 Workshops, Springer CCIS vol. 1167 (2020); Progress 1 keliru mengutip versi arXiv-nya. Namun tahun terbitnya tetap tidak memenuhi syarat, sehingga posisinya sebagai referensi utama tetap diganti.

Pencarian referensi baru dilakukan melalui Crossref dan Semantic Scholar, dengan empat kriteria:

1. terbit di jurnal atau prosiding pada 2025 atau sesudahnya, bukan *preprint*;
2. membahas klasifikasi dokumen multimodal teks–citra, perbandingan mesin OCR, atau ketahanan embedding terhadap derau OCR;
3. metadata (DOI, volume, halaman) dapat diverifikasi;
4. teks lengkapnya dapat dibaca.

Hasilnya dirangkum pada Tabel 2. Khusus Larson et al. (2025), yang dibaca baru abstraknya.

Tabel 2 Referensi utama dan pendukung yang terbit tahun 2025–2026

Referensi	Peran dalam rencana ini
Kashyap, Mittal dan Singh (2026)	Referensi utama: fusion teks–citra terkini pada Tobacco3482
Mirończuk (2026)	Pembingkai celah: meta-analisis 139 studi fusion untuk klasifikasi dokumen
Francis dan Sangeetha (2025)	Perbandingan Tesseract, EasyOCR, PaddleOCR, Keras-OCR, dan mesin lain
Zhang et al. (2025)	Bukti bahwa galat OCR merambat ke tugas lanjutan
Michail et al. (2025)	Ketahanan embedding terhadap derau OCR
Larson et al. (2025)	Jalan pintas kode ID pada Tobacco3482

Kashyap, Mittal dan Singh (2026) dipilih sebagai referensi utama karena dua alasan. Pertama, paper ini penerus langsung Audebert: keduanya menggabungkan cabang citra dan cabang teks OCR, keduanya diuji pada Tobacco3482, dan Kashyap membandingkan hasilnya secara eksplisit dengan Audebert. Kedua, celah terpentingnya, yaitu mesin OCR yang tidak disebutkan, adalah persis yang hendak diuji di sini.

Paper ini **tidak direplikasi**. *Fine-tuning*-nya memakan sekitar 63 jam pada GPU 16 GB dengan RVL-CDIP, jauh di luar perangkat yang tersedia. Yang diambil dari paper ini adalah embedding BERT, aturan fusion rata-rata logit, dan arah lanjutan yang disebut penulisnya sendiri.

1.3 Rumusan Masalah

RM1. Seberapa besar pilihan mesin OCR (Tesseract, EasyOCR, PaddleOCR) mengubah akurasi cabang teks pada klasifikasi dokumen Tobacco3482?

RM2. Apakah embedding kontekstual (BERT) memperkecil selisih antar-mesin OCR dibandingkan embedding subword statis (FastText)? Dengan kata lain, adakah interaksi antara mesin OCR dan jenis embedding?

RM3. Apakah cabang teks yang lebih kuat membuat model gabungan lebih *memakai* modalitas teks? Apakah aturan fusion rata-rata logit lebih tahan terhadap cabang yang timpang dibandingkan fusion tingkat fitur?

1.4 Tujuan

1. Mengukur pengaruh mesin OCR terhadap akurasi dan macro F1 cabang teks, disertai uji statistik antar-mesin.
2. Mengukur interaksi mesin OCR dan jenis embedding melalui desain faktorial.
3. Mengukur pemanfaatan modalitas teks pada model gabungan melalui uji *missing modality*, serta membandingkan aturan rata-rata logit (Kashyap, Mittal dan Singh, 2026) dengan fusion tingkat fitur.

1.5 Batasan

1. Dataset yang dipakai hanya Tobacco3482 (3.482 dokumen, 10 kelas). RVL-CDIP (Harley, Ufkes dan Derpanis, 2015) tidak dipakai karena ukurannya (±400.000 dokumen) di luar kemampuan perangkat. Akibatnya, hasil rencana ini **tidak sebanding langsung** dengan Kashyap, Mittal dan Singh (2026), yang melatih modelnya pada RVL-CDIP.
2. Kualitas OCR diukur melalui proksi. Tobacco3482 tidak memiliki transkripsi acuan, sehingga *character error rate* tidak dapat dihitung.
3. Cabang citra dibuat tetap (MobileNetV2) di semua kondisi, supaya perbedaan hasil hanya berasal dari sisi teks.
4. Seluruh komputasi dijalankan pada satu laptop dengan GPU 4 GB VRAM.

2 Tinjauan Pustaka

2.1 Kajian Pustaka

2.1.1 Fusion Teks dan Citra pada Tobacco3482

Audebert et al. (2020) merancang jaringan dua cabang yang dapat dilatih *end-to-end*:

- cabang citra: MobileNetV2 dengan masukan 384×384;
- cabang teks: FastText dan CNN 1D atas teks hasil Tesseract 4;
- fusion: konkatenasi vektor fitur kedua cabang.

Pada Tobacco3482, fusion mencapai akurasi 87,8%, di atas baseline citra (84,5%) dan baseline teks (73,8%). Hasilnya dirata-ratakan atas tiga run tanpa simpangan baku. Penulis juga melaporkan oracle, yaitu batas atas teoretis fusion, sebesar 92,1%. Artinya fusion baru memanen 3,3 dari 7,6 poin potensi di atas baseline citra. Penjumlahan fitur dilaporkan berada di bawah baseline citra, tetapi tanpa angka. Di bagian penutup, penulis menyebut embedding yang tahan derau OCR sebagai arah penelitian lanjutan.

Kashyap, Mittal dan Singh (2026) adalah penerus langsung pendekatan tersebut dan menjadi **referensi utama** penelitian ini. Ada empat perbedaan dari Audebert:

- cabang citra memakai EfficientNetB3 dengan masukan 300×300;
- cabang teks memakai BERT-base;
- fusion dilakukan di tingkat keputusan, berupa rata-rata logit tanpa bobot;
- kedua cabang di-*fine-tune* pada ±320.000 dokumen RVL-CDIP, lalu Tobacco3482 dipakai hanya sebagai data uji.

Akurasi yang dilaporkan 93,06% pada RVL-CDIP dan 92,00% pada Tobacco3482.

Pembacaan teks lengkap paper tersebut menghasilkan empat catatan:

1. **Mesin OCR-nya hanya disebut "mesin OCR komersial"**, tanpa nama, sehingga cabang teksnya tidak dapat direproduksi. Keunggulan BERT pun tidak dapat dipisahkan dari efek mesin OCR yang tidak diketahui itu.
2. **Angka Tobacco3482 tidak konsisten dengan protokolnya sendiri.** Kelas Note (201 dokumen) dan Report (265 dokumen) tidak ada di 16 kelas RVL-CDIP, sehingga tidak mungkin diprediksi benar. Bila seluruh 3.482 dokumen dievaluasi, akurasi maksimumnya hanya $3016/3482 = 86{,}6\%$. Tabel per kelas paper memang hanya memuat 8 kelas.
3. **Perbandingan dengan Audebert tidak setara.** Angka 92,00% (dilatih pada RVL-CDIP) disandingkan dengan 87,8% Audebert (dilatih pada 800 dokumen Tobacco3482) tanpa menyebut perbedaan protokolnya.
4. **Hasil dilaporkan dari satu run**, tanpa uji statistik.

Penulis sendiri menyebut pembobotan modalitas adaptif dan kondisi degradasi OCR yang parah sebagai arah lanjutan. Keduanya bersinggungan langsung dengan penelitian ini.

2.1.2 Gambaran Bidang: Meta-analisis Fusion untuk Klasifikasi Dokumen

Mirończuk (2026) menganalisis 139 studi primer fusion multimodal dan multiview untuk klasifikasi dokumen. Fusion multimodal menaikkan akurasi rata-rata 5,28 poin ($p = 0{,}0016$). Namun efeknya terhadap F1 tidak signifikan secara statistik.

Tiga temuan lain dari review ini relevan langsung untuk penelitian ini:

1. Hanya 11,8% studi multimodal yang memakai uji statistik.
2. Kualitas data, termasuk galat OCR, diakui sebagai sumber heterogenitas yang *tidak dapat dikontrol* dalam meta-analisis, karena studi primer tidak melaporkannya.
3. Penulis menganjurkan pelaporan baseline unimodal, F1 untuk data timpang, dan ablasi lengkap untuk setiap modalitas yang ditambahkan.

2.1.3 Perbandingan Mesin OCR dan Dampaknya pada Tugas Lanjutan

Francis dan Sangeetha (2025) membandingkan tujuh mesin OCR, termasuk Tesseract, EasyOCR, PaddleOCR, dan Keras-OCR, pada citra campuran: dokumen cetak, layar, struk, dan ekspresi matematika. PaddleOCR mencatat akurasi tertinggi (0,7136), diikuti EasyOCR (0,6953), Tesseract (0,6868), dan Keras-OCR (0,6784). Selisihnya kecil, sekitar 3,5 poin. Yang diukur di sana adalah ketepatan OCR itu sendiri, bukan dampaknya pada tugas yang memakai teks hasil OCR.

Dampak semacam itu diukur oleh Zhang et al. (2025) untuk sistem *retrieval-augmented generation*. Mereka menyusun tolok ukur OHRBench dari 8.561 citra dokumen. Galat OCR dipilah menjadi derau semantik (kata salah baca) dan derau format (struktur tabel atau rumus rusak). Keduanya terbukti menurunkan kinerja tugas lanjutan. Untuk klasifikasi dokumen, pengukuran serupa belum kami temukan.

2.1.4 Ketahanan Embedding terhadap Derau OCR

Michail et al. (2025) menunjukkan bahwa model embedding standar melemah pada teks hasil OCR, karena derau OCR jarang muncul dalam data pelatihannya. Ketahanannya dapat dipulihkan dengan cara yang murah: *fine-tuning* memakai teks yang diberi derau karakter buatan dan *loss* kontrastif, tanpa data berlabel dari domain sasaran. Temuan ini mendasari sumbu embedding dalam penelitian ini. FastText menangani derau OCR secara struktural melalui *subword*, sedangkan BERT menanganinya melalui tokenisasi WordPiece dan konteks kalimat.

2.1.5 Jalan Pintas pada Tobacco3482

Larson et al. (2025) menunjukkan bahwa dokumen RVL-CDIP dan Tobacco3482 bercap **kode ID** arsip. Model sederhana yang hanya memakai fitur dari kode ID itu

sudah mencapai ±60% akurasi di Tobacco3482. Pada RVL-CDIP, classifier mutakhir kehilangan 11 poin akurasi setelah kode ID dihapus.

Temuan ini menjadi kontrol wajib pada tahap lanjutan yang memperlakukan teks sebagai objek berposisi (Subbagian 4.5).

2.1.6 Posisi Rencana Penelitian

Tabel 3 memetakan studi-studi di atas terhadap lima aspek yang menjadi fokus penelitian ini.

Tabel 3 Posisi penelitian terhadap studi terkait

Studi	**Mesin OCR disebut**	**> 1 mesin OCR**	**Variasi embedding**	**Uji missing modality**	**Uji statistik**
Audebert et al. (2020)	✓	–	MLP vs CNN	–	–
Kashyap, Mittal dan Singh (2026)	–	–	–	–	–
Francis dan Sangeetha (2025)	✓	✓ (7)	tanpa tugas klasifikasi		
Rencana ini	✓	✓ (3)	FastText, BERT	✓	✓

2.2 Dasar Teori

2.2.1 Optical Character Recognition

OCR modern umumnya bekerja dalam dua tahap: **deteksi** wilayah teks pada citra, lalu **pengenalan** karakter di dalam setiap wilayah. Ketiga mesin yang diuji berbeda pada kedua tahap tersebut.

Tesseract (Smith, 2007) memulai dengan analisis tata letak halaman untuk menemukan blok, baris, dan kata, lalu mengenali teksnya. Sejak versi 4, pengenalannya memakai jaringan LSTM yang membaca setiap baris sebagai sekuens. Konfigurasi `--psm 3` berarti segmentasi halaman otomatis penuh tanpa deteksi orientasi. Konfigurasi inilah yang dipakai QS-OCR (QuickSign, 2026). Keluarannya mengikuti urutan baca Tesseract sendiri, yaitu blok, paragraf, baris, lalu kata.

EasyOCR (JaidedAI, 2024) mendeteksi teks dengan CRAFT (Baek et al., 2019). CRAFT memprediksi wilayah setiap karakter dan keterkaitan antar-karakter, lalu menggabungkannya menjadi kotak kata atau baris. Pengenalannya memakai CRNN (Shi, Bai dan Yao, 2017), yang terdiri atas tiga bagian:

- ekstraktor fitur konvolusi;
- LSTM dua arah untuk pelabelan sekuens;
- dekoder *connectionist temporal classification* (CTC).

PaddleOCR (PaddlePaddle Authors, 2026) menyusun pipeline dari modul-modul terpisah: klasifikasi orientasi dokumen, koreksi distorsi, deteksi baris teks, klasifikasi orientasi baris, dan pengenalan teks. Modul orientasi dan koreksi distorsi

bersifat opsional. Penelitian ini memakai pasangan model deteksi dan pengenalan PP-OCRv5 *mobile*.

Mesin berbasis kotak seperti EasyOCR dan PaddleOCR tidak menjamin urutan baca. Urutan itu harus direkonstruksi dari posisi kotak (Subbagian 3.3).

2.2.2 Representasi Kata

FastText (Bojanowski et al., 2017) merepresentasikan kata w sebagai jumlah vektor seluruh *n-gram* karakternya:

$$\mathbf{u}_w = \sum_{g \in \mathcal{G}_w} \mathbf{z}_g \tag{1}$$

dengan $\mathcal{G}_w$ himpunan *n-gram* karakter kata w beserta kata itu sendiri, dan $\mathbf{z}_g$ vektor untuk *n-gram* g. Karena itu, kata yang rusak akibat OCR, misalnya `Tospacco`, tetap mendapat vektor yang dekat dengan kata aslinya, karena keduanya berbagi banyak *n-gram*.

BERT (Devlin et al., 2019) adalah encoder Transformer dua arah yang dilatih awal dengan tugas *masked language modelling*. Teks dipecah menjadi sub-kata dengan tokenisasi WordPiece, dan vektor setiap token bergantung pada konteks kalimatnya. Panjang masukan dibatasi 512 token. Untuk klasifikasi, representasi token khusus `[CLS]` dilewatkan ke lapisan klasifikasi, dan seluruh model di-*fine-tune*.

2.2.3 Arsitektur Konvolusi

CNN 1D untuk teks (Kim, 2014) menggeser filter konvolusi di sepanjang sekuens vektor kata, lalu meringkasnya dengan *max-pooling* terhadap waktu. Filter dengan lebar k berfungsi sebagai pendeteksi frasa sepanjang k kata. Model ini peka terhadap **urutan** kata, berbeda dari rata-rata vektor kata.

MobileNetV2 (Sandler et al., 2018) adalah CNN citra berbiaya rendah. Blok penyusunnya adalah *inverted residual* dengan *linear bottleneck*: kanal diekspansi dengan konvolusi 1×1, difilter dengan konvolusi *depthwise* 3×3, lalu diproyeksikan kembali tanpa aktivasi non-linear.

2.2.4 Strategi Fusion

Fusion dapat dilakukan pada tingkat fitur atau tingkat keputusan (Baltrusaitis, Ahuja dan Morency, 2019). Misalkan $\mathbf{v}_t, \mathbf{v}_v \in \mathbb{R}^d$ adalah vektor fitur cabang teks dan citra, dan $\mathbf{z}_t, \mathbf{z}_v \in \mathbb{R}^C$ adalah logit keduanya untuk C kelas.

Fusion tingkat fitur menggabungkan vektor fitur lalu mengklasifikasikannya bersama. Pada konkatenasi (Audebert et al., 2020):

$$\hat{y} = \arg\max_c \ \mathrm{MLP}([\,\mathbf{v}_t\,;\,\mathbf{v}_v\,])_c \tag{2}$$

Fusion tingkat keputusan menggabungkan keluaran setiap cabang. Pada rata-rata logit tanpa bobot (Kashyap, Mittal dan Singh, 2026):

$$\hat{y} = \arg\max_c \ \tfrac{1}{2}\left(z_{t,c} + z_{v,c}\right) \tag{3}$$

Fusion tingkat keputusan menjamin kedua cabang ikut menentukan hasil. Akibatnya, cabang yang lemah tetap memengaruhi keputusan.

Pada fusion tingkat fitur, cabang dengan skala fitur jauh lebih besar dapat mendominasi. Masalah ini dapat diatasi dengan **Layer Normalization** (Ba, Kiros dan Hinton, 2016), yang menormalkan setiap vektor fitur terhadap rata-rata μ dan simpangan baku σ komponennya sendiri:

$$\mathrm{LN}(\mathbf{v}) = \boldsymbol{\gamma} \odot \frac{\mathbf{v} - \mu}{\sigma + \epsilon} + \boldsymbol{\beta} \tag{4}$$

dengan $\boldsymbol{\gamma}$ dan $\boldsymbol{\beta}$ parameter yang dipelajari. LN bekerja per sampel, sehingga tidak bergantung pada ukuran *batch*.

2.2.5 Metrik Evaluasi

Overall accuracy (OA) adalah proporsi dokumen uji yang diklasifikasikan dengan benar. Kelas Tobacco3482 timpang, dengan rasio kelas terbesar berbanding terkecil 5,2:1, sehingga OA cenderung didominasi kelas besar. Karena itu **macro F1** juga dilaporkan:

$$\mathrm{F1}_c = \frac{2\,P_c R_c}{P_c + R_c}, \qquad \text{macro F1} = \frac{1}{C}\sum_{c=1}^{C} \mathrm{F1}_c \tag{5}$$

dengan P_c dan R_c presisi dan *recall* kelas c.

Oracle adalah batas atas teoretis fusion: sebuah dokumen dihitung benar bila cabang teks *atau* cabang citra mengklasifikasikannya dengan benar (Audebert et al., 2020). Selisih antara oracle dan baseline terbaik adalah potensi yang dapat dipanen fusion.

Uji *missing modality* mengukur ketergantungan model gabungan pada setiap modalitas. Caranya, masukan satu modalitas dinolkan saat inferensi:

$$\Delta_{\text{teks}} = \mathrm{OA}_{\text{utuh}} - \mathrm{OA}_{\text{teks dinolkan}} \tag{6}$$

Δ_{citra} didefinisikan secara analog. Δ_{teks} yang mendekati nol berarti model tidak memakai teks, berapa pun akurasinya.

Uji McNemar (McNemar, 1947) membandingkan dua classifier pada data uji yang sama. Uji ini dianjurkan untuk perbandingan algoritme pembelajaran oleh Dietterich (1998). Bila b adalah jumlah dokumen yang hanya benar pada classifier pertama dan c jumlah dokumen yang hanya benar pada classifier kedua:

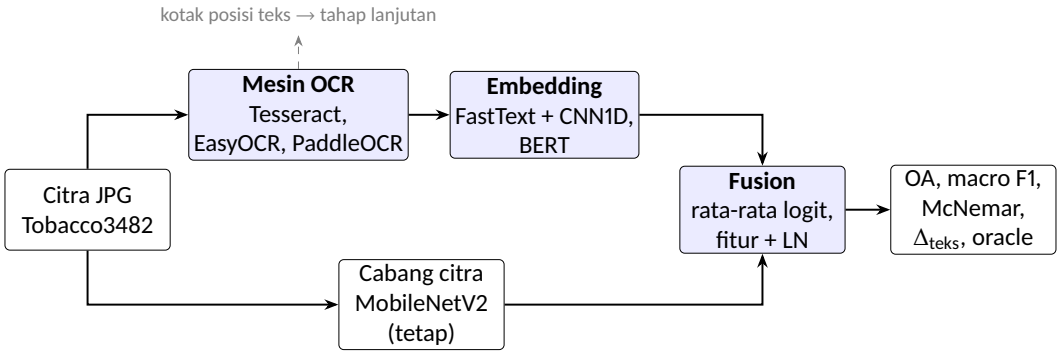
$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c} \tag{7}$$

Statistik ini berdistribusi χ^2 dengan satu derajat bebas. Bila $b + c$ kecil, dipakai uji binomial eksak. Untuk m perbandingan sekaligus, ambang signifikansi dikoreksi menjadi α/m (koreksi Bonferroni, Dunn, 1961).

3 Metode yang Direncanakan

3.1 Kerangka Penelitian

Kerangka penelitian ditunjukkan Gambar 1.



Gambar 1 Kerangka penelitian; kotak biru adalah variabel yang diuji

Penelitian terdiri atas empat langkah:

1. OCR ulang seluruh citra dengan tiga mesin.
2. Melatih cabang teks untuk setiap kombinasi mesin OCR dan embedding.
3. Menggabungkan setiap cabang teks dengan cabang citra yang sama.
4. Mengevaluasi akurasi sekaligus pemanfaatan modalitas.

Cabang citra sengaja dibuat tetap, supaya setiap perbedaan hasil hanya dapat berasal dari sisi teks.

3.2 Dataset dan Protokol

Tobacco3482 (Kumar, Ye dan Doermann, 2014) berisi 3.482 citra dokumen dalam 10 kelas: Advertisement, Email, Form, Letter, Memo, News, Note, Report, Resume, dan Scientific. Kelas terbesar adalah Memo (620 dokumen) dan terkecil Resume (120 dokumen). Citra diambil dari Kaggle dalam format JPG (patrickaudriaz, 2026), yang tidak memiliki lisensi baku.

QS-OCR-Small (QuickSign, 2026) berlisensi Apache-2.0. Isinya teks Tesseract 4 dari citra TIF asli, dan dipakai sebagai **kondisi acuan**, yaitu teks yang sama dengan yang dipakai Audebert et al. (2020).

Protokol pembagian data mengikuti Audebert et al. (2020):

- 800 dokumen latih per pembagian, 10% di antaranya dipakai untuk validasi;
- sisanya, 2.682 dokumen, menjadi data uji;
- tiga pembagian acak terstratifikasi, dengan seed 42, 43, dan 44;
- **indeks pembagian yang sama** dipakai di semua kondisi, supaya perbedaan antar-kondisi tidak tercampur perbedaan data.

Pemakaian dataset dibatasi untuk keperluan akademik non-komersial, dan tidak ada berkas dataset yang didistribusikan ulang.

3.3 Ekstraksi OCR Multi-mesin

Konfigurasi setiap mesin disajikan pada Tabel 4.

Tabel 4 Mesin OCR dan konfigurasinya

Mesin	Konfigurasi	Kotak teks
QS-OCR (acuan)	Tesseract 4.0-beta pada TIF asli, `--oem 1 --psm 3`	tidak tersedia
Tesseract	versi 5 pada JPG, konfigurasi sama dengan QS-OCR	per kata
EasyOCR	model bahasa Inggris, GPU	per baris
PaddleOCR	model PP-OCRv5 *mobile*, CPU, tanpa koreksi orientasi	per baris

Empat keputusan desain menyertai konfigurasi tersebut:

1. **Semua mesin membaca citra JPG yang sama**, termasuk Tesseract yang dijalankan ulang. Selisih antara QS-OCR dan Tesseract-JPG karena itu mengukur efek gabungan format citra dan versi Tesseract.
2. **Urutan baca mesin berbasis kotak direkonstruksi**: baris dari atas ke bawah, kata dari kiri ke kanan. Karena CNN 1D peka urutan, perbedaan urutan baca dicatat sebagai bagian dari efek mesin.
3. **Teks dan kotak posisi setiap halaman disimpan**, sehingga tahap lanjutan tidak memerlukan OCR ulang.
4. **Versi pustaka dan nama model dikunci serta dicatat**, karena model bawaan mesin OCR dapat berganti antar-versi.

Keras-OCR disarankan dosen, tetapi dimasukkan secara bersyarat. Alasannya dijelaskan pada risiko R3 (Subbagian 4.3).

3.4 Proksi Kualitas OCR

Tobacco3482 tidak memiliki transkripsi acuan, sehingga *character error rate* tidak dapat dihitung. Tiga proksi berikut menggambarkan keluaran OCR tanpa menilai benar-salahnya.

1. **Kata per halaman dan persentase halaman kosong.** Proksi ini menangkap mesin yang melewatkan blok teks.
2. **Laju OOV.** Untuk dokumen d, laju OOV adalah bagian kata alfabetik dengan panjang minimal empat huruf yang tidak terdapat dalam daftar kata bahasa Inggris V (Speer, 2023):

$$\mathrm{OOV}(d) = \frac{|\{w \in d : |w| \geq 4,\ w \notin V\}|}{|\{w \in d : |w| \geq 4\}|} \tag{8}$$

   Salah baca yang kebetulan berupa kata yang ada, misalnya `tbe` untuk `the`, tidak terhitung. Karena itu nilai ini adalah *batas bawah* galat.

3. **Kesepakatan antar-mesin.** Kesepakatan dua mesin diukur dengan indeks Jaccard atas himpunan kata (A dan B) yang keduanya baca:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{9}$$

Urutan kata sengaja diabaikan, karena mesin berbeda urutan baca walaupun kata yang dibaca sama.

3.5 Representasi Teks dan Citra

Dua representasi teks diuji.

FastText dan CNN 1D, mengikuti Audebert et al. (2020). Setiap kata dipetakan ke vektor FastText 300 dimensi (Persamaan 1). Sekuens dibatasi 500 kata, lalu diproses CNN 1D.

BERT-base, mengikuti Kashyap, Mittal dan Singh (2026). Model ini di-*fine-tune* dengan masukan maksimum 512 token. Pelatihan memakai *mixed precision* dan akumulasi gradien supaya muat di GPU 4 GB. Bila tetap tidak muat, model diganti DistilBERT, dan penggantian itu dicatat sebagai deviasi.

Teks masuk ke kedua representasi **tanpa** praproses gaya Kashyap, yaitu tanpa membuang angka dan *stopword*. Tujuannya agar efek embedding tidak tercampur efek praproses.

Cabang citra memakai MobileNetV2 berbobot awal ImageNet, dengan masukan 384×384 dan rasio aspek di-*warp*, mengikuti Audebert et al. (2020). Cabang ini sama di semua kondisi.

3.6 Strategi Fusion yang Diuji

Dua strategi fusion diuji.

Rata-rata logit (Persamaan 3), yaitu aturan Kashyap, Mittal dan Singh (2026). Strategi ini tidak memerlukan pelatihan ulang, sehingga dapat diterapkan pada *semua* kondisi.

Fusion tingkat fitur dengan normalisasi per cabang:

$$\hat{y} = \arg\max_{c} \ \mathrm{MLP}([\,\mathrm{LN}(\mathbf{v}_t)\,;\,\mathrm{LN}(\mathbf{v}_v)\,])_c \tag{10}$$

Layer Normalization (Persamaan 4) menyamakan skala kedua vektor fitur sebelum digabung, supaya head klasifikasi tidak otomatis didominasi cabang yang skala fiturnya lebih besar. Cabang teks diinisialisasi dari model teks yang sudah dilatih sendiri, supaya kedua cabang mulai dari titik yang sama-sama terlatih.

Fusion tingkat fitur memerlukan pelatihan *end-to-end* yang relatif mahal, sehingga hanya diterapkan pada kondisi OCR terbaik dan terburuk.

3.7 Desain Eksperimen dan Hipotesis

Matriks eksperimen disajikan pada Tabel 5.

Tabel 5 Matriks eksperimen

Kelompok	Kondisi	Jumlah run
Cabang teks	4 kondisi OCR $\times$ 2 embedding $\times$ 3 seed	24
Cabang citra	MobileNetV2 $\times$ 3 seed	3
Rata-rata logit	setiap model teks + cabang citra dengan seed yang sama	24 (tanpa pelatihan)
Fusion fitur	kondisi OCR terbaik dan terburuk, FastText, seed 42	2 (+4 bila waktu cukup)
Uji *missing modality*	setiap model fusion	tanpa pelatihan

Pemeriksaan kewarasan. Kondisi QS-OCR $\times$ FastText harus menghasilkan akurasi cabang teks yang dekat dengan angka Audebert et al. (2020) (0,738). Bila jauh berbeda, ada yang salah dalam pipeline, dan eksperimen dihentikan sampai penyebabnya ditemukan.

Hipotesis dirumuskan *sebelum* eksekusi, dan akan dilaporkan apa adanya, termasuk bila keliru.

H1. **(RM1)** Perbedaan akurasi cabang teks antar-mesin OCR bersifat nyata, yaitu melampaui variasi antar-seed. Mesin modern belum tentu unggul. Tobacco3482 berisi pindaian cetak hitam putih, yaitu kondisi tempat Tesseract paling kuat. Selain itu, CNN 1D peka urutan baca, yang berbeda antar-mesin.

H2. **(RM2)** BERT memperkecil selisih antar-mesin dibandingkan FastText. Argumen tandingannya: model bahasa standar juga melemah pada teks OCR (Michail et al., 2025), dan batas 512 token memotong dokumen panjang.

H3. **(RM3)** Pada fusion fitur, Δ_{teks} membesar seiring akurasi cabang teks. Rata-rata logit menjamin $\Delta_{\text{teks}} > 0$ secara konstruksi, tetapi akurasinya dapat turun bila cabang teks lemah.

3.8 Evaluasi dan Uji Statistik

Setiap model dievaluasi dengan empat ukuran: OA, macro F1 (Persamaan 5), F1 per kelas, dan oracle. Untuk setiap model fusion ditambahkan Δ_{teks} dan Δ_{citra} (Persamaan 6).

Perbandingan dua kondisi memakai uji McNemar (Persamaan 7) pada data uji yang sama, per seed. Uji binomial eksak dipakai bila $b + c < 25$. Ada enam pasangan kondisi OCR per jenis embedding, sehingga ambang signifikansinya dikoreksi menjadi $0{,}05/6$. Sebuah perbedaan dinyatakan konsisten bila signifikan dan arahnya sama di ketiga seed. Semua angka dilaporkan sebagai rata-rata $\pm$ simpangan baku tiga seed.

4 Rencana Pelaksanaan

4.1 Jadwal

Pelaksanaan dimulai setelah rencana ini disetujui dosen pengampu. Setiap tahap diakhiri dengan catatan hasil dan pemeriksaan sebelum lanjut ke tahap berikutnya. Jadwalnya disajikan pada Tabel 6.

Tabel 6 Jadwal pelaksanaan

Minggu	Kegiatan	Keluaran
1	OCR multi-mesin	Teks dan kotak dari tiga mesin untuk 3.482 halaman; proksi kualitas OCR (Subbagian 3.4); versi pustaka tercatat
2	Cabang teks: FastText	12 model (4 kondisi OCR $\times$ 3 seed); pemeriksaan kewarasan; uji McNemar antar-mesin
3	Cabang teks: BERT	12 model; uji interaksi mesin OCR $\times$ embedding
4	Cabang citra dan fusion	3 model citra; rata-rata logit untuk 24 kondisi; fusion fitur untuk dua kondisi; uji *missing modality*
5	Analisis dan laporan	Jawaban RM1–RM3 beserta jejaknya ke angka sumber; grafik Δ_{teks} terhadap akurasi cabang teks
6	Rancangan tahap lanjutan	Rancangan teks sebagai objek beserta referensinya (Subbagian 4.5)

4.2 Kebutuhan Komputasi

Seluruh komputasi dijalankan pada laptop dengan GPU RTX 3050 (4 GB VRAM), prosesor Intel Core i7 generasi 11, dan RAM 24 GB. Tiga hal menentukan kebutuhan ini.

1. **Model FastText** berukuran sekitar 7 GB di disk dan membutuhkan sekitar 15 GB RAM saat dimuat. Karena itu ekstraksi fiturnya dijalankan sekali untuk semua mesin OCR, lalu modelnya dilepas.
2. **BERT-base** perlu *mixed precision* dan akumulasi gradien supaya muat di GPU 4 GB.
3. **Fusion tingkat fitur** dilatih *end-to-end* dan merupakan bagian paling mahal, sehingga dibatasi pada dua kondisi OCR.

Kecepatan setiap mesin OCR akan diukur pada 20 halaman pertama sebelum proses penuh, supaya perkiraan waktu totalnya diketahui di awal.

4.3 Risiko dan Mitigasi

Risiko yang sudah teridentifikasi dan mitigasinya disajikan pada Tabel 7.

Tabel 7 Risiko dan mitigasi

	Risiko	**Mitigasi**
R1	PaddleOCR membawa `opencv-contrib-python`, yang bentrok dengan opencv milik EasyOCR dan dapat menggeser versi numpy	PaddleOCR dijalankan di *virtual environment* terpisah, sehingga lingkungan utama tidak tersentuh
R2	Tesseract di Windows bukan paket pip	Dipasang lewat `winget`, dengan langkah manual sebagai cadangan
R3	Keras-OCR membutuhkan TensorFlow dengan API Keras 2, yang tidak tersedia untuk Python 3.12. Dependensinya, `imgaug`, juga tidak cocok dengan numpy versi baru	Dijalankan di lingkungan Python 3.11 tersendiri bila diwajibkan. Bila tidak, tiga mesin sudah cukup untuk menjawab RM1–RM3
R4	BERT-base tidak muat di GPU 4 GB	*Mixed precision*, akumulasi gradien, atau DistilBERT (dicatat sebagai deviasi)
R5	Menolkan masukan menghasilkan input di luar distribusi, sehingga Δ dapat melebih-lebihkan ketergantungan	Δ ditafsirkan sebagai ukuran ketergantungan, bukan sumbangan informasi
R6	Perbedaan antar-mesin lebih kecil daripada variasi antar-seed	Itu tetap jawaban RM1: temuan negatif yang terukur, disertai uji statistik

4.4 Luaran

1. Teks dan kotak posisi teks Tobacco3482 dari tiga mesin OCR, beserta proksi kualitasnya.
2. Grid akurasi cabang teks untuk empat kondisi OCR $\times$ dua embedding $\times$ tiga seed, beserta uji McNemar.
3. Nilai Δ_{teks} dan Δ_{citra} untuk setiap model fusion.
4. Laporan yang menyatakan setiap hipotesis terdukung atau tidak, dengan rujukan ke angka sumbernya.

Keberhasilan diukur dari kelengkapan dan ketelitian jawaban, *bukan* dari arah hasilnya. Bila mesin OCR ternyata tidak berpengaruh, itu jawaban yang sah dan informatif: artinya, celah pelaporan kualitas OCR yang diidentifikasi Mirończuk (2026) tidak berdampak pada dataset ini.

4.5 Tahap Lanjutan: Teks sebagai Objek

Sesuai arahan dosen pengampu, tahap berikutnya memperlakukan teks bukan hanya sebagai rangkaian kata, tetapi sebagai **objek berposisi** pada halaman. Bahannya sudah tersedia dari langkah OCR, karena setiap mesin menyimpan kotak teksnya. Ada tiga kandidat representasi:

1. fitur posisi dua dimensi di samping embedding kata;
2. peta kotak teks sebagai citra, yaitu setiap kotak digambar pada kanvas seukuran halaman;

3. graf yang simpulnya kotak teks dan sisinya kedekatan spasial.

Satu kontrol bersifat wajib. Kode ID arsip pada Tobacco3482 adalah objek teks berposisi konsisten, dan fitur dari kode ID saja sudah memberi ±60% akurasi (Larson et al., 2025). Model berbasis posisi dapat belajar jalan pintas ini alih-alih belajar tata letak dokumen. Karena itu setiap model akan diuji dengan dan tanpa kotak kode ID.

Granularitas kotak juga berbeda antar-mesin: Tesseract per kata, sedangkan EasyOCR dan PaddleOCR per baris. Rancangan rinci beserta referensi (minimal tahun 2025) untuk tahap ini akan diajukan tersendiri.

Daftar Referensi

Audebert, N., Herold, C., Slimani, K. dan Vidal, C., 2020. Multimodal Deep Networks for Text and Image-Based Document Classification. Dalam: *Machine Learning and Knowledge Discovery in Databases: International Workshops of ECML PKDD 2019*. Vol. 1167. Communications in Computer and Information Science. Springer International Publishing, pp.427-443. Tersedia di: <https://doi.org/10.1007/978-3-030-43823-4_35>.

Ba, J.L., Kiros, J.R. dan Hinton, G.E., 2016. *Layer Normalization*. Tersedia di: <https://doi.org/10.48550/ARXIV.1607.06450>.

Baek, Y., Lee, B., Han, D., Yun, S. dan Lee, H., 2019. Character Region Awareness for Text Detection. Dalam: *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, pp.9357-9366. Tersedia di: <https://doi.org/10.1109/cvpr.2019.00959>.

Baltrusaitis, T., Ahuja, C. dan Morency, L.-P., 2019. Multimodal Machine Learning: A Survey and Taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), pp.423-443. Tersedia di: <https://doi.org/10.1109/tpami.2018.2798607>.

Bojanowski, P., Grave, E., Joulin, A. dan Mikolov, T., 2017. Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics*, 5, pp.135-146. Tersedia di: <https://doi.org/10.1162/tacl_a_00051>.

Devlin, J., Chang, M.-W., Lee, K. dan Toutanova, K., 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Dalam: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Association for Computational Linguistics, pp.4171-4186. Tersedia di: <https://doi.org/10.18653/v1/n19-1423>.

Dietterich, T.G., 1998. Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms. *Neural Computation*, 10(7), pp.1895-1923. Tersedia di: <https://doi.org/10.1162/089976698300017197>.

Dunn, O.J., 1961. Multiple Comparisons among Means. *Journal of the American Statistical Association*, 56(293), pp.52-64. Tersedia di: <https://doi.org/10.1080/01621459.1961.10482090>.

Francis, S. dan Sangeetha, M., 2025. A comparison study on optical character recognition models in mathematical equations and in any language. *Results in Control and Optimization*, 18, p.100532. Tersedia di: <https://doi.org/10.1016/j.rico.2025.100532>.

Harley, A.W., Ufkes, A. dan Derpanis, K.G., 2015. Evaluation of deep convolutional nets for document image classification and retrieval. Dalam: *2015 13th International Conference on Document Analysis and Recognition (ICDAR)*. IEEE, pp.991-995. Tersedia di: <https://doi.org/10.1109/icdar.2015.7333910>.

JaidedAI, 2024. *EasyOCR*. Version 1.7.2. Tersedia di: <https://github.com/JaidedAI/EasyOCR>.

Kashyap, A., Mittal, M. dan Singh, S., 2026. Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification. *International Journal of Intelligent Systems*, 2026(1), 4241437. Tersedia di: <https://doi.org/10.1155/int/4241437>.

Kim, Y., 2014. Convolutional Neural Networks for Sentence Classification. Dalam: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, pp.1746-1751. Tersedia di: <https://doi.org/10.3115/v1/d14-1181>.

Kumar, J., Ye, P. dan Doermann, D., 2014. Structural similarity for document image classification and retrieval. *Pattern Recognition Letters*, 43, pp.119-126. Tersedia di: <https://doi.org/10.1016/j.patrec.2013.10.030>.

Larson, S., Duwal, S., Vilnrotter, B., Chakkithara, G., Padwal, V. dan Leach, K., 2025. Spurious Cues in RVL-CDIP and Tobacco3482 Document Classification: The Case of ID Codes. Dalam: *Proceedings of the 2025 ACM Symposium on Document Engineering*. ACM, pp.1-4. Tersedia di: <https://doi.org/10.1145/3704268.3748683>.

McNemar, Q., 1947. Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages. *Psychometrika*, 12(2), pp.153-157. Tersedia di: <https://doi.org/10.1007/bf02295996>.

Michail, A., Opitz, J., Wang, Y., Meister, R., Sennrich, R. dan Clematide, S., 2025. Cheap Character Noise for OCR-Robust Multilingual Embeddings. Dalam: *Findings of the Association for Computational Linguistics: ACL 2025*. Association for Computational Linguistics, pp.11705-11716. Tersedia di: <https://doi.org/10.18653/v1/2025.findings-acl.609>.

Mirończuk, M.M., 2026. Document classification pattern recognition via information fusion: A systematic review of multimodal and multiview representation approaches. *Information Fusion*, 132, p.104247. Tersedia di: <https://doi.org/10.1016/j.inffus.2026.104247>.

PaddlePaddle Authors, 2026. *PaddleOCR*. Version 3.7.0. Tersedia di: <https://github.com/PaddlePaddle/PaddleOCR>.

patrickaudriaz, 2026. *Tobacco3482 Dataset (JPG)*. Kaggle. Tersedia di: <https://www.kaggle.com/datasets/patrickaudriaz/tobacco3482jpg> [Diakses 28 September 2026].

QuickSign, 2026. *OCRized Text Dataset (QS-OCR)*, *rilis v1.0*. GitHub. Tersedia di: <https://github.com/QuickSign/ocrized-text-dataset> [Diakses 28 September 2026].

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. dan Chen, L.-C., 2018. MobileNetV2: Inverted Residuals and Linear Bottlenecks. Dalam: *2018*

IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, pp.4510-4520. Tersedia di: <https://doi.org/10.1109/cvpr.2018.00474>.

Shi, B., Bai, X. dan Yao, C., 2017. An End-to-End Trainable Neural Network for Image-Based Sequence Recognition and Its Application to Scene Text Recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(11), pp.2298-2304. Tersedia di: <https://doi.org/10.1109/tpami.2016.2646371>.

Smith, R., 2007. An Overview of the Tesseract OCR Engine. Dalam: *Ninth International Conference on Document Analysis and Recognition (ICDAR 2007) Vol 2*. IEEE, pp.629-633. Tersedia di: <https://doi.org/10.1109/icdar.2007.4376991>.

Speer, R., 2023. *wordfreq*. Version 3.1.1. Tersedia di: <https://github.com/rspeer/wordfreq>.

Zhang, J., Zhang, Q., Wang, B., Ouyang, L., Wen, Z., Li, Y., Chow, K.-H., He, C. dan Zhang, W., 2025. OCR Hinders RAG: Evaluating the Cascading Impact of OCR on Retrieval-Augmented Generation. Dalam: *2025 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, pp.17443-17453. Tersedia di: <https://doi.org/10.1109/iccv51701.2025.01620>.