

Pengaruh Mesin OCR dan Embedding Teks terhadap Pemanfaatan Modalitas Teks pada Klasifikasi Dokumen Multimodal

Proposal Tugas Akhir (revisi) — Analisis dan Pemrosesan Data Multimodal

Ramadhani Al-Qadri · 9 Oktober 2026

1. Latar belakang dan celah penelitian

Dokumen hasil pindai membawa informasi di dua lapis: **tata letak** yang terlihat pada citra, dan **isi tekstual** yang hanya bisa diambil lewat OCR. Karena teksnya diturunkan dari citra, **mutu cabang teks dibatasi oleh mutu OCR-nya**.

Acuan terkini. Kashyap *et al.* [1] menggabungkan EfficientNetB3 (citra) dan BERT (teks OCR) dengan rata-rata logit tanpa bobot, dan melaporkan akurasi 92,00% pada Tobacco3482. Ada empat catatan kritis:

- Mesin OCR-nya hanya disebut “mesin OCR komersial” tanpa nama, sehingga cabang teksnya tidak bisa direproduksi.
- Model dilatih pada 16 kelas RVL-CDIP, padahal Note dan Report (466 dokumen) tidak ada di RVL-CDIP. Bila 3.482 dokumen dievaluasi, akurasi maksimum yang mungkin hanya 86,6%. Jadi angka 92% hampir pasti dihitung pada sebagian kelas saja.
- Hasil itu dibandingkan dengan Audebert *et al.* [7], yang dilatih hanya pada 800 dokumen Tobacco3482, tanpa catatan bahwa protokolnya berbeda.
- Satu kali *run*, tanpa uji statistik.

Penulisnya sendiri menyebut degradasi OCR yang parah dan pembobotan modalitas adaptif sebagai arah lanjutan.

Gambaran lapangan. Meta-analisis atas 139 studi [2] menemukan fusion multimodal menaikkan akurasi rata-rata 5,28 poin. Namun hanya 11,8% studi multimodal yang memakai uji statistik, dan kualitas OCR *tidak dapat dikontrol* dalam meta-analisis itu karena studi primer jarang melaporkannya. Perbandingan mesin OCR [3] mengukur ketepatan OCR itu sendiri, bukan dampaknya pada tugas lanjutan. Padahal galat OCR terbukti merambat ke tugas hilir [4].

Hasil awal proyek ini. Replikasi Audebert pada Tobacco3482 (Tesseract + FastText, 3 *split* acak, 800 dokumen latih) mencapai angka berikut:

Model	Akurasi kami	Akurasi paper
Teks (FastText + CNN1D)	$0,727 \pm 0,006$	0,738
Citra (MobileNetV2)	$0,809 \pm 0,021$	0,845
Fusion (konkatenasi)	$0,834 \pm 0,011$	0,878
Oracle (teks atau citra benar)	0,898	0,921

Fusion tampak unggul. Tetapi **menolkan seluruh masukan teks hanya menurunkan akurasi fusion sebesar 0,0015**: cabang teksnya praktis tidak terpakai. Diagnostik kami menelusuri penyebabnya sampai ke mekanisme: fitur teks kolaps (67 dari 128 unit mati) dan skalanya $3,7\times$ lebih kecil daripada fitur citra. Setelah diperbaiki (LayerNorm per cabang dan inisialisasi dari model teks; seed 42), menolkan teks menurunkan akurasi 0,689 (sebelumnya 0,007), dan F1 kelas Resume naik dari 0,81 ke 0,97. Akurasinya turun 0,019, tetapi macro F1 tetap identik. Pelajarannya: **akurasi fusion yang tinggi bukan bukti bahwa fusion memakai kedua modalitas**.

Celah penelitian. Studi fusion teks–citra memperlakukan mesin OCR sebagai konstanta, bahkan tanpa menyebut namanya, dan hanya melaporkan akurasi gabungan. Belum diukur bagaimana **pilihan mesin OCR $\times$ jenis embedding** memengaruhi kekuatan cabang teks, dan **seberapa jauh model fusion benar-benar memakai cabang itu**.

2. Pertanyaan penelitian

- Q1.** Seberapa besar pilihan mesin OCR (Tesseract, EasyOCR, PaddleOCR, Keras-OCR) mengubah akurasi cabang teks pada Tobacco3482?
- Q2.** Apakah embedding kontekstual (BERT) memperkecil selisih antar-mesin OCR dibanding embedding subword statis (FastText)? Dengan kata lain, adakah interaksi OCR $\times$ embedding?
- Q3.** Apakah cabang teks yang lebih kuat membuat model fusion lebih *memakai* teks, diukur dengan uji *missing modality*? Dan apakah aturan rata-rata logit Kashyap lebih tahan terhadap cabang yang timpang daripada fusion fitur?

3. Desain eksperimen

Faktor	Level
Mesin OCR	Tesseract 4 (--oem 1 --psm 3), EasyOCR, PaddleOCR; Keras-OCR bila dapat dijalankan. Semua dijalankan pada citra JPG yang sama. QS-OCR (Tesseract pada TIF asli) dipakai sebagai acuan untuk mengukur efek JPG vs TIF.
Embedding teks	FastText 300-d + CNN 1D [10] (pipeline hasil awal); BERT-base [9] di- <i>fine-tune</i> , seperti Kashyap. Ketahanan embedding terhadap derau OCR masih merupakan persoalan terbuka [5].
Cabang citra	MobileNetV2 [11], 384×384 , tetap di semua kondisi, supaya perbedaan hanya berasal dari teks.
Fusion	(i) rata-rata logit tanpa bobot, aturan Kashyap, tanpa pelatihan ulang; (ii) fusion fitur dengan LayerNorm per cabang, hasil perbaikan pada tahap awal.

Teks masuk ke kedua embedding **tanpa** praproses gaya Kashyap (membuang angka dan *stopword*), agar efek embedding tidak tercampur efek praproses. Selain teks, setiap mesin OCR menghasilkan **kotak posisi teks**. Kotak ini disimpan sejak awal untuk tahap lanjutan (Bagian 6), sehingga OCR tidak perlu dijalankan ulang.

4. Dataset dan lisensi

Tobacco3482-jpg (3.482 citra, 10 kelas; Kaggle patrickaudriaz/tobacco3482jpg) tidak memiliki lisensi baku; deskripsinya hanya merujuk Kumar *et al.* [8]. **QS-OCR-Small** (GitHub QuickSign/ocrized-text-dataset, rilis v1.0) berlisensi Apache-2.0, tetapi teksnya turunan Tobacco3482 sehingga hak sumber hulu tetap berlaku. Pemakaian dibatasi pada konteks akademik non-komersial. Tidak ada berkas dataset yang didistribusikan: notebook mengunduh langsung dari sumber aslinya. RVL-CDIP tidak dipakai karena ukurannya (~ 400.000 dokumen) di luar anggaran komputasi. Konsekuensinya, angka kami **tidak sebanding langsung** dengan Kashyap, yang dilatih pada RVL-CDIP.

Protokolnya mengikuti hasil awal: 800 dokumen latih per *split*, terstratifikasi, dengan seed 42/43/44, dan indeks *split* yang sama untuk semua kondisi.

5. Metrik evaluasi

Metrik	Alasan
Akurasi (OA), macro F1, F1 per kelas	OA untuk perbandingan dengan literatur. Macro F1 karena kelasnya timpang (5,2:1). Pada hasil awal, OA dan macro F1 terbukti bisa bergerak terpisah.
Proksi kualitas OCR	Tobacco3482 tidak punya transkripsi acuan, jadi <i>character error rate</i> tidak dapat dihitung. Yang diukur: jumlah token, laju kata di luar kosakata (OOV), dan kesepakatan antar-mesin. Dilaporkan sebagai proksi, bukan akurasi OCR.
Uji <i>missing modality</i>	Penurunan akurasi saat teks atau citra dinolkan. Inilah metrik yang menjawab Q3.
Oracle	Batas atas teoretis: benar bila salah satu cabang benar.
Uji statistik	McNemar berpasangan antar-kondisi pada test set yang sama, ditambah rata-rata $\pm$ simpangan baku 3 seed. Menjawab kritik metodologis [2].

6. Tahap lanjutan: teks sebagai objek

Kotak teks dari Bagian 3 memungkinkan teks diperlakukan sebagai **objek berposisi**, bukan hanya rangkaian kata. Representasinya bisa berupa fitur posisi 2D di samping embedding kata, peta kotak teks sebagai citra, atau graf antar-kotak. Satu kontrol bersifat wajib: dokumen Tobacco3482 bercap **kode ID** arsip yang posisinya konsisten, dan fitur dari kode ID saja sudah memberi $\pm 60\%$ akurasi di Tobacco3482 [6]. Model berbasis posisi harus diuji dengan dan tanpa kotak kode ID. Tanpa kontrol itu, akurasi tinggi tidak dapat ditafsirkan.

7. Kelayakan dan risiko

Komputasi memakai laptop RTX 3050 4 GB VRAM. OCR diperkirakan memakan $\pm 1\text{--}3$ jam per mesin untuk 3.482 halaman. BERT-base dilatih dengan *mixed precision* dan akumulasi gradien; bila tidak muat, diganti DistilBERT dan dicatat sebagai deviasi. Rata-rata logit tidak membutuhkan pelatihan, sehingga dapat diuji untuk semua kondisi. Fusion fitur hanya dilatih untuk kondisi OCR terbaik dan terburuk.

Risiko teknisnya:

- Tesseract di Windows bukan paket pip.
- paddlepaddle-gpu** berukuran > 700 MB.
- Keras-OCR berbasis TensorFlow, yang sejak versi 2.11 tidak mendukung GPU di Windows native, dan rilis terakhirnya November 2023.

Bila Keras-OCR tidak dapat dijalankan, ia dilewati dengan alasan tertulis. Tiga mesin lainnya tetap menjawab Q1–Q3.

References

- [1] A. Kashyap, M. Mittal, S. Singh, “Multimodal fusion and supervised contrastive learning for robust document image classification,” *International Journal of Intelligent Systems*, vol. 2026, art. 4241437, 2026. doi:10.1155/int/4241437.

- [2] M. M. Mirończuk, “Document classification pattern recognition via information fusion: A systematic review of multimodal and multiview representation approaches,” *Information Fusion*, vol. 132, art. 104247, 2026. doi:10.1016/j.inffus.2026.104247.
- [3] S. A. Francis, M. Sangeetha, “A comparison study on optical character recognition models in mathematical equations and in any language,” *Results in Control and Optimization*, vol. 18, art. 100532, 2025. doi:10.1016/j.rico.2025.100532.
- [4] J. Zhang *et al.*, “OCR hinders RAG: Evaluating the cascading impact of OCR on retrieval-augmented generation,” in *Proc. IEEE/CVF ICCV*, 2025, pp. 17443–17453. doi:10.1109/ICCV51701.2025.01620.
- [5] A. Michail, J. Opitz, Y. Wang, R. Meister, R. Sennrich, S. Clematide, “Cheap character noise for OCR-robust multilingual embeddings,” in *Findings of ACL*, 2025.
- [6] S. Larson, S. Duwal, B. Vilnrotter, G. Chakkithara, V. Padwal, K. Leach, “Spurious cues in RVL-CDIP and Tobacco3482 document classification: The case of ID codes,” in *Proc. ACM DocEng*, 2025. doi:10.1145/3704268.3748683.
- [7] N. Audebert, C. Herold, K. Slimani, C. Vidal, “Multimodal deep networks for text and image-based document classification,” in *ECML PKDD 2019 Workshops*, CCIS vol. 1167, Springer, 2020, pp. 427–443. doi:10.1007/978-3-030-43823-4_35.
- [8] J. Kumar, P. Ye, D. Doermann, “Structural similarity for document image classification and retrieval,” *Pattern Recognition Letters*, vol. 43, 2014.
- [9] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proc. NAACL-HLT*, 2019.
- [10] P. Bojanowski, E. Grave, A. Joulin, T. Mikolov, “Enriching word vectors with subword information,” *TACL*, vol. 5, 2017.
- [11] M. Sandler *et al.*, “MobileNetV2: Inverted residuals and linear bottlenecks,” in *Proc. CVPR*, 2018.