ANALISIS & PEMROSESAN DATA MULTIMODAL

Pengaruh Mesin OCR dan Embedding Teks terhadap Pemanfaatan Modalitas Teks pada Klasifikasi Dokumen Multimodal

PROPOSAL PENELITIAN

Disusun oleh:

Yulian Anggreaif Rudamaga	:	256150100011001
Zalzabila Rani	:	256150100011008
Ramadhani Al-Qadri	:	256150100011010

Dosen Pengampu:
Dr. Eng. Fitra Abdurrachman Bachtiar, S.T., M.Eng.

PROGRAM STUDI MAGISTER ILMU KOMPUTER
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
MALANG

2026

DAFTAR ISI

DAFTAR ISI ii
DAFTAR TABEL iv
DAFTAR GAMBAR v
DAFTAR LAMPIRAN vi
BAB 1 PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Tujuan Penelitian 2
1.4 Manfaat Penelitian 2
1.5 Batasan Masalah 3
BAB 2 LANDASAN KEPUSTAKAAN 4
2.1 Kajian Pustaka 4
2.1.1 Fusion Teks dan Citra pada Tobacco3482 4
2.1.2 Gambaran Bidang: Meta-analisis Fusion untuk Klasifikasi Dokumen 4
2.1.3 Perbandingan Mesin OCR dan Dampaknya pada Tugas Lanjutan .. 5
2.1.4 Ketahanan Embedding terhadap Derau OCR 5
2.1.5 Jalan Pintas pada Tobacco3482 5
2.1.6 Posisi Penelitian 6
2.2 Dasar Teori 6
2.2.1 Optical Character Recognition 6
2.2.2 Representasi Kata 7
2.2.3 Arsitektur Konvolusi 7
2.2.4 Strategi Fusion 7
2.2.5 Metrik Evaluasi 8
BAB 3 METODOLOGI PENELITIAN 9
3.1 Tahapan Penelitian 9
3.2 Studi Pendahuluan: Replikasi Audebert et al. 9
3.2.1 Hasil Replikasi 9
3.2.2 Uji Missing Modality dan Degradasi 10
3.2.3 Diagnosis: Cabang Teks yang Kolaps 11

3.2.4 Perbaikan dan Implikasinya 12
3.3 Dataset dan Protokol 13
3.4 Ekstraksi OCR Multi-mesin 14
3.5 Proksi Kualitas OCR 15
3.6 Representasi Teks dan Citra 15
3.7 Strategi Fusion yang Diuji 16
3.8 Desain Eksperimen dan Hipotesis 16
3.9 Evaluasi dan Uji Statistik 17
BAB 4 RENCANA PELAKSANAAN 18
4.1 Jadwal 18
4.2 Kebutuhan Komputasi 18
4.3 Risiko dan Mitigasi 19
4.4 Luaran dan Kriteria Keberhasilan 19
4.5 Tahap Lanjutan: Teks sebagai Objek 20
DAFTAR REFERENSI 21
LAMPIRAN A RIWAYAT PEMILIHAN REFERENSI DAN TANGGAPAN DOSEN 24
LAMPIRAN B CATATAN KRITIS ATAS KASHYAP ET AL. (2026) 26
LAMPIRAN C HASIL LENGKAP STUDI PENDAHULUAN 27

DAFTAR TABEL

Tabel 2.1 Posisi penelitian terhadap studi terkait 6

Tabel 3.1 Hasil replikasi pada Tobacco3482 (rata-rata ± simpangan baku tiga seed) 10

Tabel 3.2 Uji pada model fusion konkatenasi saat inferensi (seed 42) 10

Tabel 3.3 Model fusion sebelum dan sesudah perbaikan (seed 42) 12

Tabel 3.4 Mesin OCR dan konfigurasinya 14

Tabel 3.5 Matriks eksperimen 16

Tabel 4.1 Jadwal pelaksanaan Fase 2 18

Tabel 4.2 Perkiraan waktu komputasi 18

Tabel 4.3 Risiko dan mitigasi 19

Tabel A.1 Tanggapan dosen pengampu dan tindak lanjutnya 24

Tabel A.2 Referensi utama dan pendukung yang terbit tahun 2025–2026 25

Tabel C.1 F1 per kelas: replikasi kelompok (K) dan paper (P)..... 27

DAFTAR GAMBAR

Gambar 3.1 Kerangka penelitian Fase 2; kotak biru adalah variabel yang diuji 9

Gambar 3.2 Akurasi model citra dan fusion terhadap tingkat degradasi citra 11

Gambar 3.3 Diagnostik fitur teks di dalam model fusion: varians per dimensi, skala kedua cabang, dan akurasi *linear probe* 12

Gambar 3.4 *Confusion matrix* model fusion sebelum dan sesudah perbaikan.....13

Gambar 3.5 Contoh pasangan citra dokumen dan teks QS-OCR-nya 14

DAFTAR LAMPIRAN

LAMPIRAN A RIWAYAT PEMILIHAN REFERENSI DAN TANGGAPAN DOSEN 24
LAMPIRAN B CATATAN KRITIS ATAS KASHYAP ET AL. (2026) 26
LAMPIRAN C HASIL LENGKAP STUDI PENDAHULUAN 27

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Dokumen hasil pindai menyimpan informasi pada dua lapis sekaligus. Lapis pertama adalah **tata letak**: posisi blok, kerapatan tulisan, tabel, kop surat, dan tanda tangan. Lapis kedua adalah **isi tekstual**: kata-kata seperti *Dear Sir*, *Memorandum*, atau *Curriculum Vitae* yang langsung menandai jenis dokumen. Lapis pertama terlihat langsung pada citra. Lapis kedua tersembunyi di dalam piksel dan harus dikeluarkan lebih dulu melalui *optical character recognition* (OCR). Karena teksnya diturunkan dari citra, **mutu modalitas teks dibatasi oleh mutu OCR-nya**.

Pada laporan Progress 1, kelompok kami mengusulkan replikasi model dua cabang Audebert et al. (2020). Model ini menggabungkan MobileNetV2 untuk citra halaman dengan FastText dan CNN 1D untuk teks hasil Tesseract. Replikasi diuji pada dataset Tobacco3482, dan Progress 1 mengajukan tiga pertanyaan: (a) seberapa besar akurasi naik bila kedua modalitas digabung; (b) strategi penggabungan mana yang bekerja; dan (c) apakah model gabungan sungguh memakai kedua sumber.

Sejak Progress 1, replikasi tersebut telah dijalankan penuh, dan ketiga pertanyaan itu telah terjawab (Subbab 3.2). Jawaban pertanyaan (c) yang paling menentukan arah penelitian ini. Secara angka, replikasi berhasil: model gabungan mencapai akurasi 0,834, di atas baseline citra (0,809) dan baseline teks (0,727). Namun ketika seluruh masukan teks dinolkan saat inferensi, akurasinya hanya turun **0,0015**. Model gabungan itu ternyata **diam-diam unimodal**: kenaikan akurasinya tidak berasal dari teks. Padahal komplementaritas kedua modalitas jelas ada, karena 8,9% dokumen uji hanya dapat diklasifikasikan dengan benar melalui teks.

Temuan ini menyingkap kelemahan cara bidang ini melaporkan hasil. Studi fusion teks–citra umumnya hanya melaporkan akurasi gabungan. Padahal, seperti ditunjukkan replikasi kami, akurasi gabungan yang tinggi tidak membuktikan bahwa kedua modalitas benar-benar dipakai.

Studi terkini mewarisi kelemahan yang sama dan menambah satu kelemahan lain. Kashyap, Mittal dan Singh (2026) menggabungkan EfficientNetB3 dan BERT, dan melaporkan akurasi 92,00% pada Tobacco3482. Akan tetapi, mesin OCR yang menghasilkan teksnya hanya disebut “mesin OCR komersial”, tanpa nama. Akibatnya, keunggulan cabang teks mereka tidak dapat dipisahkan dari mesin OCR yang tidak diketahui itu.

Di tingkat bidang, meta-analisis atas 139 studi oleh Mirończuk (2026) menemukan bahwa fusion multimodal menaikkan akurasi rata-rata 5,28 poin. Namun meta-analisis itu *tidak dapat* mengontrol kualitas OCR, karena studi primer jarang melaporkannya. Hanya 11,8% studi multimodal yang memakai uji statistik. Perbandingan mesin OCR yang ada, misalnya Francis dan Sangeetha (2025), mengukur ketepatan OCR itu sendiri, bukan dampaknya pada tugas lanjutan. Padahal galat OCR terbukti merambat ke tugas berikutnya (Zhang et al., 2025).

Tanggapan dosen pengampu atas Progress 1 mengarahkan penelitian ini ke celah tersebut. Arahan itu meliputi eksplorasi mesin OCR selain Tesseract (EasyOCR, PaddleOCR, Keras-OCR), eksplorasi pada sisi embedding, perumusan celah penelitian yang eksplisit, dan referensi utama yang terbit paling awal tahun 2025. Riwayat lengkap pemilihan referensi dan tanggapan dosen dicatat pada Lampiran A.

Penelitian ini karena itu menjadikan **mesin OCR** dan **embedding teks** sebagai variabel. Pengaruh keduanya diukur bukan hanya terhadap akurasi, tetapi juga terhadap *seberapa jauh model gabungan benar-benar memakai* modalitas teks.

1.2 Rumusan Masalah

RM1. Seberapa besar pilihan mesin OCR (Tesseract, EasyOCR, PaddleOCR) mengubah akurasi cabang teks pada klasifikasi dokumen Tobacco3482?

RM2. Apakah embedding kontekstual (BERT) memperkecil selisih antar-mesin OCR dibandingkan embedding subword statis (FastText)? Dengan kata lain, adakah interaksi antara mesin OCR dan jenis embedding?

RM3. Apakah cabang teks yang lebih kuat membuat model gabungan lebih *memakai* modalitas teks? Apakah aturan fusion rata-rata logit lebih tahan terhadap cabang yang timpang dibandingkan fusion tingkat fitur?

1.3 Tujuan Penelitian

T1. Mengukur pengaruh mesin OCR terhadap akurasi dan macro F1 cabang teks, disertai uji statistik antar-mesin.

T2. Mengukur interaksi mesin OCR dan jenis embedding melalui desain faktorial.

T3. Mengukur pemanfaatan modalitas teks pada model gabungan melalui uji *missing modality*, serta membandingkan aturan rata-rata logit (Kashyap, Mittal dan Singh, 2026) dengan fusion tingkat fitur.

1.4 Manfaat Penelitian

1. **Manfaat akademik.** Penelitian ini menyediakan protokol evaluasi fusion yang melampaui akurasi gabungan: uji *missing modality*, beberapa seed, dan uji statistik. Protokol ini menjawab kekurangan pelaporan yang diidentifikasi Mirończuk (2026).
2. **Manfaat praktis.** Penelitian ini memberi dasar empiris untuk memilih mesin OCR open-source pada sistem klasifikasi dokumen. Dasar ini diukur dari dampaknya pada klasifikasi, bukan dari ketepatan OCR semata.
3. **Bahan tahap lanjutan.** Kotak posisi teks dari setiap mesin OCR disimpan sejak awal sebagai bahan tahap berikutnya, yaitu teks sebagai objek (Subbab 4.5).

1.5 Batasan Masalah

1. Dataset yang dipakai hanya Tobacco3482 (3.482 dokumen, 10 kelas). RVL-CDIP (Harley, Ufkes dan Derpanis, 2015) tidak dipakai karena ukurannya (±400.000 dokumen) di luar kemampuan perangkat yang tersedia. Akibatnya, angka penelitian ini **tidak sebanding langsung** dengan Kashyap, Mittal dan Singh (2026), yang melatih modelnya pada RVL-CDIP.
2. Kualitas OCR diukur melalui proksi. Tobacco3482 tidak memiliki transkripsi acuan, sehingga *character error rate* tidak dapat dihitung.
3. Cabang citra dibuat tetap (MobileNetV2) di semua kondisi, supaya perbedaan hasil hanya berasal dari sisi teks.
4. Seluruh komputasi dijalankan pada satu laptop dengan GPU 4 GB VRAM.

BAB 2 LANDASAN KEPUSTAKAAN

2.1 Kajian Pustaka

2.1.1 Fusion Teks dan Citra pada Tobacco3482

Audebert et al. (2020) merancang jaringan dua cabang yang dapat dilatih *end-to-end*:

- cabang citra: MobileNetV2 dengan masukan 384×384;
- cabang teks: FastText dan CNN 1D atas teks hasil Tesseract 4;
- fusion: konkatenasi vektor fitur kedua cabang.

Pada Tobacco3482, fusion mencapai akurasi 87,8%, di atas baseline citra (84,5%) dan baseline teks (73,8%). Hasilnya dirata-ratakan atas tiga run tanpa simpangan baku. Penulis juga melaporkan bahwa penjumlahan fitur berada di bawah baseline citra, tetapi tanpa menyertakan angkanya. Di bagian penutup, penulis menyebut embedding yang tahan derau OCR sebagai arah penelitian lanjutan. Paper inilah yang direplikasi pada studi pendahuluan kami (Subbab 3.2).

Kashyap, Mittal dan Singh (2026) adalah penerus langsung pendekatan tersebut dan menjadi **referensi utama** penelitian ini. Ada empat perbedaan dari Audebert:

- cabang citra memakai EfficientNetB3 dengan masukan 300×300;
- cabang teks memakai BERT-base;
- fusion dilakukan di tingkat keputusan, berupa rata-rata logit tanpa bobot;
- kedua cabang di-*fine-tune* pada ±320.000 dokumen RVL-CDIP, lalu Tobacco3482 dipakai hanya sebagai data uji.

Akurasi yang dilaporkan 93,06% pada RVL-CDIP dan 92,00% pada Tobacco3482.

Pembacaan teks lengkap paper tersebut menghasilkan tiga catatan:

1. Mesin OCR-nya hanya disebut “mesin OCR komersial”, tanpa nama.
2. Angka Tobacco3482 tidak konsisten dengan protokolnya sendiri. Kelas Note dan Report tidak ada di RVL-CDIP, sehingga akurasi maksimum pada 10 kelas hanya 86,6%. Perhitungannya ada di Lampiran B.
3. Hasil dilaporkan dari satu run tanpa uji statistik.

Penulis sendiri menyebut pembobotan modalitas adaptif dan kondisi degradasi OCR yang parah sebagai arah lanjutan. Keduanya bersinggungan langsung dengan penelitian ini.

2.1.2 Gambaran Bidang: Meta-analisis Fusion untuk Klasifikasi Dokumen

Mirończuk (2026) menganalisis 139 studi primer fusion multimodal dan multiview untuk klasifikasi dokumen. Fusion multimodal menaikkan akurasi rata-

rata 5,28 poin ($p = 0{,}0016$). Namun efeknya terhadap F1 tidak signifikan secara statistik.

Tiga temuan lain dari review ini relevan langsung untuk penelitian ini:

1. Hanya 11,8% studi multimodal yang memakai uji statistik.
2. Kualitas data, termasuk galat OCR, diakui sebagai sumber heterogenitas yang *tidak dapat dikontrol* dalam meta-analisis, karena studi primer tidak melaporkannya.
3. Penulis menganjurkan pelaporan baseline unimodal, F1 untuk data timpang, dan ablasi lengkap untuk setiap modalitas yang ditambahkan.

2.1.3 Perbandingan Mesin OCR dan Dampaknya pada Tugas Lanjutan

Francis dan Sangeetha (2025) membandingkan tujuh mesin OCR, termasuk Tesseract, EasyOCR, PaddleOCR, dan Keras-OCR, pada citra campuran: dokumen cetak, layar, struk, dan ekspresi matematika. PaddleOCR mencatat akurasi tertinggi (0,7136), diikuti EasyOCR (0,6953), Tesseract (0,6868), dan Keras-OCR (0,6784). Selisihnya kecil, sekitar 3,5 poin. Yang diukur di sana adalah ketepatan OCR itu sendiri, bukan dampaknya pada tugas yang memakai teks hasil OCR.

Dampak semacam itu diukur oleh Zhang et al. (2025) untuk sistem *retrieval-augmented generation*. Mereka menyusun tolok ukur OHRBench dari 8.561 citra dokumen. Galat OCR dipilah menjadi derau semantik (kata salah baca) dan derau format (struktur tabel atau rumus rusak). Keduanya terbukti menurunkan kinerja tugas lanjutan. Untuk klasifikasi dokumen, pengukuran serupa belum kami temukan.

2.1.4 Ketahanan Embedding terhadap Derau OCR

Michail et al. (2025) menunjukkan bahwa model embedding standar melemah pada teks hasil OCR, karena derau OCR jarang muncul dalam data pelatihannya. Ketahanannya dapat dipulihkan dengan cara yang murah: *fine-tuning* memakai teks yang diberi derau karakter buatan dan *loss* kontrastif, tanpa data berlabel dari domain sasaran. Temuan ini mendasari sumbu embedding dalam penelitian ini. FastText menangani derau OCR secara struktural melalui *subword*, sedangkan BERT menanganinya melalui tokenisasi WordPiece dan konteks kalimat.

2.1.5 Jalan Pintas pada Tobacco3482

Larson et al. (2025) menunjukkan bahwa dokumen RVL-CDIP dan Tobacco3482 bercap **kode ID** arsip. Model sederhana yang hanya memakai fitur dari kode ID itu sudah mencapai ±60% akurasi di Tobacco3482. Pada RVL-CDIP, classifier mutakhir kehilangan 11 poin akurasi setelah kode ID dihapus.

Kode ID ini terlihat pada contoh dokumen di Gambar 3.5, misalnya `00625137` dan `CTR CONTRACTS 023247`. Temuan ini menjadi kontrol wajib pada tahap lanjutan yang memperlakukan teks sebagai objek berposisi (Subbab 4.5).

2.1.6 Posisi Penelitian

Tabel 2.1 memetakan studi-studi di atas terhadap lima aspek yang menjadi fokus penelitian ini.

Tabel 2.1 Posisi penelitian terhadap studi terkait

Studi	Mesin OCR disebut	> 1 mesin OCR	Variasi embedding	Uji missing modality	Uji statistik
Audebert et al. (2020)	✓	–	MLP vs CNN	–	–
Kashyap, Mittal dan Singh (2026)	–	–	–	–	–
Francis dan Sangeetha (2025)	✓	✓ (7)	tanpa tugas klasifikasi		
Penelitian ini	✓	✓ (3)	FastText, BERT	✓	✓

Sumber: Dirangkum dari studi yang dirujuk.

2.2 Dasar Teori

2.2.1 Optical Character Recognition

OCR modern umumnya bekerja dalam dua tahap: **deteksi** wilayah teks pada citra, lalu **pengenalan** karakter di dalam setiap wilayah. Ketiga mesin yang diuji berbeda pada kedua tahap tersebut.

Tesseract (Smith, 2007) memulai dengan analisis tata letak halaman untuk menemukan blok, baris, dan kata, lalu mengenali teksnya. Sejak versi 4, pengenalannya memakai jaringan LSTM yang membaca setiap baris sebagai sekuens. Konfigurasi `--psm 3` berarti segmentasi halaman otomatis penuh tanpa deteksi orientasi. Konfigurasi inilah yang dipakai QS-OCR (QuickSign, 2026). Keluarannya mengikuti urutan baca Tesseract sendiri, yaitu blok, paragraf, baris, lalu kata.

EasyOCR (JaidedAI, 2024) mendeteksi teks dengan CRAFT (Baek et al., 2019). CRAFT memprediksi wilayah setiap karakter dan keterkaitan antar-karakter, lalu menggabungkannya menjadi kotak kata atau baris. Pengenalannya memakai CRNN (Shi, Bai dan Yao, 2017), yang terdiri atas tiga bagian:

- ekstraktor fitur konvolusi;
- LSTM dua arah untuk pelabelan sekuens;
- dekoder *connectionist temporal classification* (CTC).

PaddleOCR (PaddlePaddle Authors, 2026) menyusun pipeline dari modul-modul terpisah: klasifikasi orientasi dokumen, koreksi distorsi, deteksi baris teks, klasifikasi orientasi baris, dan pengenalan teks. Modul orientasi dan koreksi distorsi bersifat opsional. Penelitian ini memakai pasangan model deteksi dan pengenalan PP-OCRv5 *mobile*.

Mesin berbasis kotak seperti EasyOCR dan PaddleOCR tidak menjamin urutan baca. Urutan itu harus direkonstruksi dari posisi kotak (Subbab 3.4).

2.2.2 Representasi Kata

FastText (Bojanowski et al., 2017) merepresentasikan kata w sebagai jumlah vektor seluruh *n-gram* karakternya:

$$\mathbf{u}_w = \sum_{g \in \mathcal{G}_w} \mathbf{z}_g \tag{2.1}$$

dengan $\mathcal{G}_w$ himpunan *n-gram* karakter kata w beserta kata itu sendiri, dan $\mathbf{z}_g$ vektor untuk *n-gram* g. Karena itu, kata yang rusak akibat OCR, misalnya `Tospacco`, tetap mendapat vektor yang dekat dengan kata aslinya, karena keduanya berbagi banyak *n-gram*.

BERT (Devlin et al., 2019) adalah encoder Transformer dua arah yang dilatih awal dengan tugas *masked language modelling*. Teks dipecah menjadi sub-kata dengan tokenisasi WordPiece, dan vektor setiap token bergantung pada konteks kalimatnya. Panjang masukan dibatasi 512 token. Untuk klasifikasi, representasi token khusus `[CLS]` dilewatkan ke lapisan klasifikasi, dan seluruh model di-*fine-tune*.

2.2.3 Arsitektur Konvolusi

CNN 1D untuk teks (Kim, 2014) menggeser filter konvolusi di sepanjang sekuens vektor kata, lalu meringkasnya dengan *max-pooling* terhadap waktu. Filter dengan lebar k berfungsi sebagai pendeteksi frasa sepanjang k kata. Model ini peka terhadap **urutan** kata, berbeda dari rata-rata vektor kata.

MobileNetV2 (Sandler et al., 2018) adalah CNN citra berbiaya rendah. Blok penyusunnya adalah *inverted residual* dengan *linear bottleneck*: kanal diekspansi dengan konvolusi 1×1, difilter dengan konvolusi *depthwise* 3×3, lalu diproyeksikan kembali tanpa aktivasi non-linear.

2.2.4 Strategi Fusion

Fusion dapat dilakukan pada tingkat fitur atau tingkat keputusan (Baltrusaitis, Ahuja dan Morency, 2019). Misalkan $\mathbf{v}_t, \mathbf{v}_v \in \mathbb{R}^d$ adalah vektor fitur cabang teks dan citra, dan $\mathbf{z}_t, \mathbf{z}_v \in \mathbb{R}^C$ adalah logit keduanya untuk C kelas.

Fusion tingkat fitur menggabungkan vektor fitur lalu mengklasifikasikannya bersama. Pada konkatenasi (Audebert et al., 2020):

$$\hat{y} = \arg\max_c \ \mathrm{MLP}([\,\mathbf{v}_t\,;\,\mathbf{v}_v\,])_c \tag{2.2}$$

Fusion tingkat keputusan menggabungkan keluaran setiap cabang. Pada rata-rata logit tanpa bobot (Kashyap, Mittal dan Singh, 2026):

$$\hat{y} = \arg\max_c \ \tfrac{1}{2}\left(z_{t,c} + z_{v,c}\right) \tag{2.3}$$

Fusion tingkat keputusan menjamin kedua cabang ikut menentukan hasil. Akibatnya, cabang yang lemah tetap memengaruhi keputusan.

Pada fusion tingkat fitur, cabang dengan skala fitur jauh lebih besar dapat mendominasi. Masalah ini dapat diatasi dengan **Layer Normalization** (Ba, Kiros

dan Hinton, 2016), yang menormalkan setiap vektor fitur terhadap rata-rata μ dan simpangan baku σ komponennya sendiri:

$$\mathrm{LN}(\mathbf{v}) = \boldsymbol{\gamma} \odot \frac{\mathbf{v} - \mu}{\sigma + \epsilon} + \boldsymbol{\beta} \tag{2.4}$$

dengan $\boldsymbol{\gamma}$ dan $\boldsymbol{\beta}$ parameter yang dipelajari. LN bekerja per sampel, sehingga tidak bergantung pada ukuran *batch*.

2.2.5 Metrik Evaluasi

Overall accuracy (OA) adalah proporsi dokumen uji yang diklasifikasikan dengan benar. Kelas Tobacco3482 timpang, dengan rasio kelas terbesar berbanding terkecil 5,2:1, sehingga OA cenderung didominasi kelas besar. Karena itu **macro F1** juga dilaporkan:

$$\mathrm{F1}_c = \frac{2\,P_c R_c}{P_c + R_c}, \qquad \text{macro F1} = \frac{1}{C}\sum_{c=1}^{C} \mathrm{F1}_c \tag{2.5}$$

dengan P_c dan R_c presisi dan *recall* kelas c.

Oracle adalah batas atas teoretis fusion: sebuah dokumen dihitung benar bila cabang teks *atau* cabang citra mengklasifikasikannya dengan benar (Audebert et al., 2020). Selisih antara oracle dan baseline terbaik adalah potensi yang dapat dipanen fusion.

Uji *missing modality* mengukur ketergantungan model gabungan pada setiap modalitas. Caranya, masukan satu modalitas dinolkan saat inferensi:

$$\Delta_{\text{teks}} = \mathrm{OA}_{\text{utuh}} - \mathrm{OA}_{\text{teks dinolkan}} \tag{2.6}$$

Δ_{citra} didefinisikan secara analog. Δ_{teks} yang mendekati nol berarti model tidak memakai teks, berapa pun akurasinya.

Uji McNemar (McNemar, 1947) membandingkan dua classifier pada data uji yang sama. Uji ini dianjurkan untuk perbandingan algoritme pembelajaran oleh Dietterich (1998). Bila b adalah jumlah dokumen yang hanya benar pada classifier pertama dan c jumlah dokumen yang hanya benar pada classifier kedua:

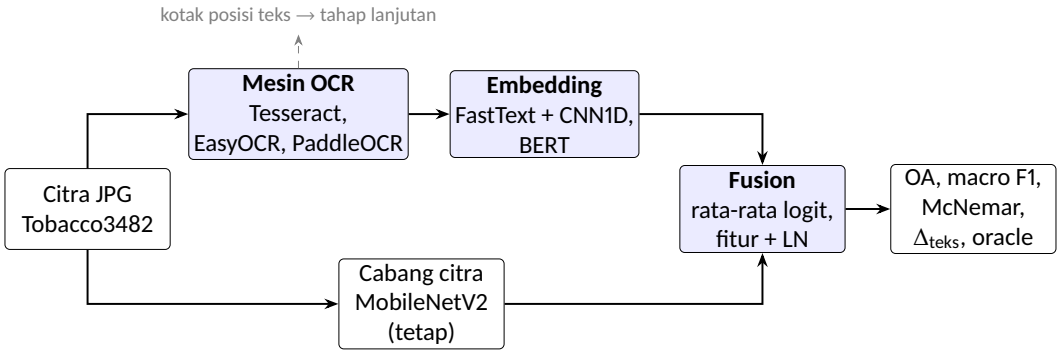
$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c} \tag{2.7}$$

Statistik ini berdistribusi χ^2 dengan satu derajat bebas. Bila $b + c$ kecil, dipakai uji binomial eksak. Untuk m perbandingan sekaligus, ambang signifikansi dikoreksi menjadi α/m (koreksi Bonferroni, Dunn, 1961).

BAB 3 METODOLOGI PENELITIAN

3.1 Tahapan Penelitian

Penelitian dibagi menjadi dua fase. **Fase 1** adalah studi pendahuluan, yaitu replikasi Audebert et al. (2020) yang diusulkan pada Progress 1. Fase ini telah selesai dijalankan, dan hasilnya dipaparkan pada Subbab 3.2. **Fase 2** adalah penelitian yang diusulkan dalam proposal ini. Kerangkanya ditunjukkan Gambar 3.1.



Gambar 3.1 Kerangka penelitian Fase 2; kotak biru adalah variabel yang diuji

Fase 2 terdiri atas empat langkah:

1. OCR ulang seluruh citra dengan tiga mesin.
2. Melatih cabang teks untuk setiap kombinasi mesin OCR dan embedding.
3. Menggabungkan setiap cabang teks dengan cabang citra yang sama.
4. Mengevaluasi akurasi sekaligus pemanfaatan modalitas.

Cabang citra sengaja dibuat tetap, supaya setiap perbedaan hasil hanya dapat berasal dari sisi teks.

3.2 Studi Pendahuluan: Replikasi Audebert et al.

3.2.1 Hasil Replikasi

Replikasi dijalankan penuh pada Tobacco3482 dengan tiga pembagian acak terstratifikasi (seed 42, 43, 44). Setiap pembagian terdiri atas 800 dokumen latih dan 2.682 dokumen uji. Seluruh arsitektur ditulis ulang dari spesifikasi paper, karena tidak tersedia kode resmi. Hasilnya disajikan pada Tabel 3.1.

Tabel 3.1 Hasil replikasi pada Tobacco3482 (rata-rata ± simpangan baku tiga seed)

Model	OA kami	Macro F1 kami	OA paper
Teks (FastText + CNN 1D)	$0{,}7266 \pm 0{,}0059$	0,7017	0,738
Citra (MobileNetV2)	$0{,}8086 \pm 0{,}0210$	0,7837	0,845
Fusion konkatenasi	$0{,}8342 \pm 0{,}0105$	0,8105	0,878
Fusion penjumlahan berbobot	$0{,}8275 \pm 0{,}0164$	0,7990	tidak dilaporkan
Oracle	0,8977	0,8850	0,921

Sumber: Eksekusi kelompok; angka paper dari Audebert et al. (2020).

Ketiga pertanyaan Progress 1 terjawab sebagai berikut.

(a) Kenaikan akurasi. Urutan Teks < Citra < Fusion < Oracle terpenuhi. Semua angka berada 1–4% di bawah paper, yang wajar mengingat framework, protokol pembagian data, dan format citra berbeda. Korpus teksnya terkonfirmasi identik: rata-rata kata dengan panjang minimal empat huruf per dokumen adalah 135, sedangkan paper menyebut 136.

Fusion menaikkan akurasi 2,56 poin di atas baseline citra. Padahal potensi yang tersedia, yaitu selisih oracle dengan baseline citra, adalah 8,91 poin. Jadi hanya 29% potensi yang dipanen; paper memanen 43%.

(b) Strategi penggabungan. Konkatenasi dan penjumlahan berbobot berselisih 0,0067, masih di dalam satu simpangan baku. Pada tiga seed keduanya tidak terbedakan, walaupun belum diuji secara formal. Ini bertentangan dengan klaim paper bahwa penjumlahan berada di bawah baseline citra; hasil kami justru 0,8275, di atas citra.

(c) Pemanfaatan kedua modalitas. Pertanyaan ini dijawab dengan uji tambahan yang tidak dilakukan paper (Subbab 3.2.2). Jawabannya: **tidak**.

3.2.2 Uji Missing Modality dan Degradasi

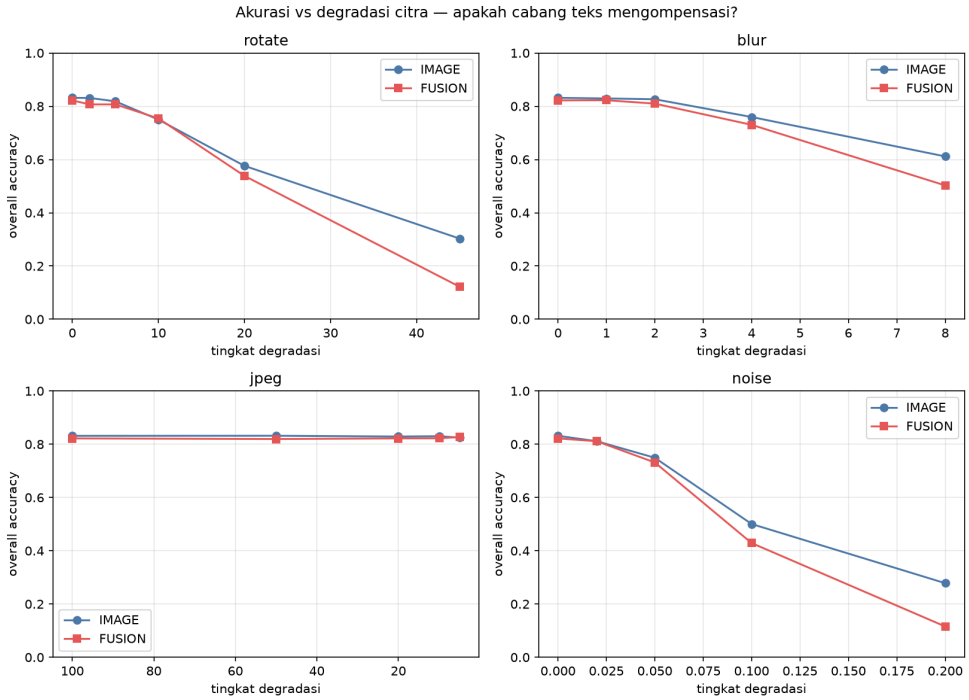
Tabel 3.2 Uji pada model fusion konkatenasi saat inferensi (seed 42)

Perlakuan	OA	Arti
Utuh	0,8218	acuan
Seluruh masukan teks dinolkan	0,8203	turun hanya 0,0015
Seluruh masukan citra dinolkan	0,0731	runtuh total
0% sampai 100% kata dihapus	0,8218 → 0,8203	kurva rata

Sumber: Eksekusi kelompok.

Tabel 3.2 menunjukkan bahwa model fusion praktis tidak memakai teks. Akibatnya, ketika citra didegradasi, fusion justru lebih rapuh daripada model citra saja (Gambar 3.2). Pada rotasi $45°$, akurasi model citra 0,3031, sedangkan fusion 0,1223. Pada *blur* 8 piksel, model citra 0,6115 dan fusion 0,5026.

Hasil ini membalik hipotesis kami sendiri sebelum eksekusi, yaitu bahwa teks akan mengompensasi citra yang rusak.



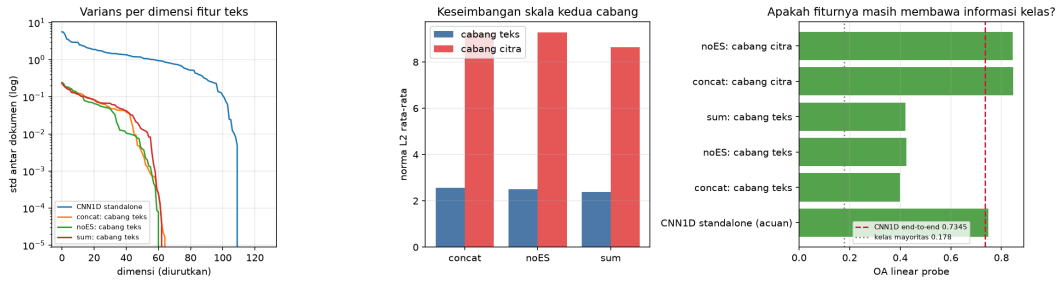
Gambar 3.2 Akurasi model citra dan fusion terhadap tingkat degradasi citra
Sumber: Eksekusi kelompok (seed 42).

3.2.3 Diagnosis: Cabang Teks yang Kolaps

Penyebabnya ditelusuri dalam tiga langkah:

1. **Bukan karena pelatihan terlalu singkat.** Tanpa *early stopping*, dengan 200 epoch penuh, cabang teks tetap hanya memanen 9–12% potensi oracle.
2. **Bukan karena strategi penggabungan.** Fusion penjumlahan menunjukkan pola yang sama.
3. **Cabang teks itu sendiri kolaps** (Gambar 3.3). Simpangan fiturnya 38 kali lebih kecil daripada CNN 1D yang dilatih sendiri. Sebanyak 67 dari 128 unit mati. Kemiripan kosinus antar-dokumen 0,978, padahal acuannya 0,650. Skala fiturnya juga 3,72 kali lebih kecil daripada fitur citra.

Informasinya belum hilang sepenuhnya. *Linear probe*, yaitu regresi logistik di atas fitur teks yang dibekukan, masih mencapai OA 0,4236. Namun informasi itu tertutup oleh cabang citra yang skalanya jauh lebih besar.



Gambar 3.3 Diagnostik fitur teks di dalam model fusion: varians per dimensi, skala kedua cabang, dan akurasi *linear probe*

Sumber: Eksekusi kelompok (seed 42).

3.2.4 Perbaikan dan Implikasinya

Dua perubahan diterapkan bersamaan: Layer Normalization pada tiap cabang (Persamaan 2.4), dan inisialisasi cabang teks dari CNN 1D yang sudah terlatih. Hasilnya disajikan pada Tabel 3.3.

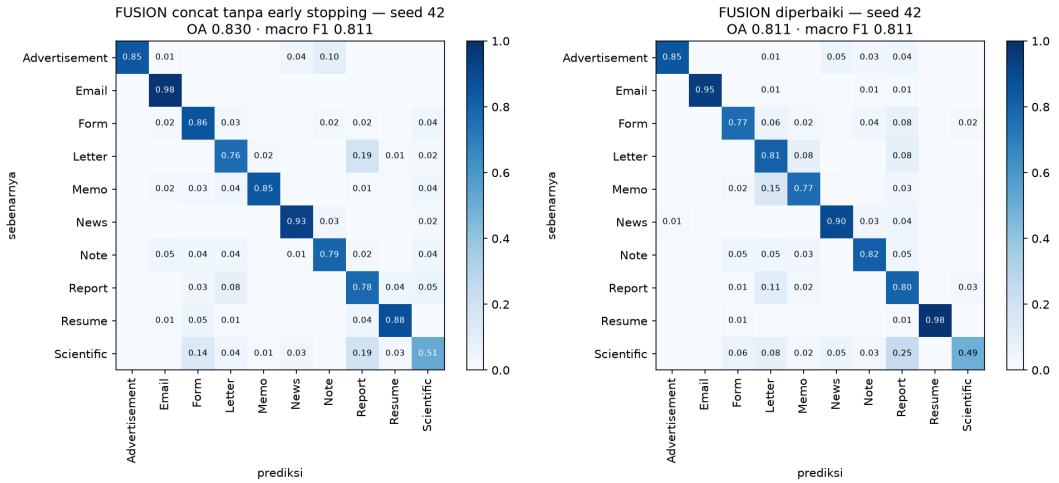
Tabel 3.3 Model fusion sebelum dan sesudah perbaikan (seed 42)

Pengukuran	Sebelum	Sesudah	Acuan CNN 1D
Linear probe fitur teks	0,4236	0,7468	0,7479
Unit mati	67/128	4/128	18/128
Δ_{teks}	0,0071	0,6887	–
F1 kelas Resume	0,814	0,968	0,969
OA	0,8304	0,8110	–
Macro F1	0,8108	0,8108	–

Sumber: Eksekusi kelompok. Model “sebelum” adalah fusion konkatenasi tanpa *early stopping*.

Sesudah perbaikan, cabang teks sama informatifnya dengan CNN 1D yang dilatih sendiri, dan F1 kelas Resume menyamai paper (0,96). Ada ongkosnya: OA turun 0,019, sedangkan macro F1 tetap persis sama. Akurasi berpindah dari kelas besar yang dikuasai citra ke kelas kecil yang membutuhkan teks (Gambar 3.4).

Model yang diperbaiki ini kini sangat bergantung pada teks: tanpa teks, akurasinya jatuh ke 0,1223. Fenomena ini dibahas sebagai risiko pengukuran R5 pada Subbab 4.3.



(a) sebelum perbaikan (b) sesudah perbaikan

Gambar 3.4 *Confusion matrix* model fusion sebelum dan sesudah perbaikan

Sumber: Eksekusi kelompok (seed 42).

Studi pendahuluan ini memberi tiga implikasi bagi Fase 2:

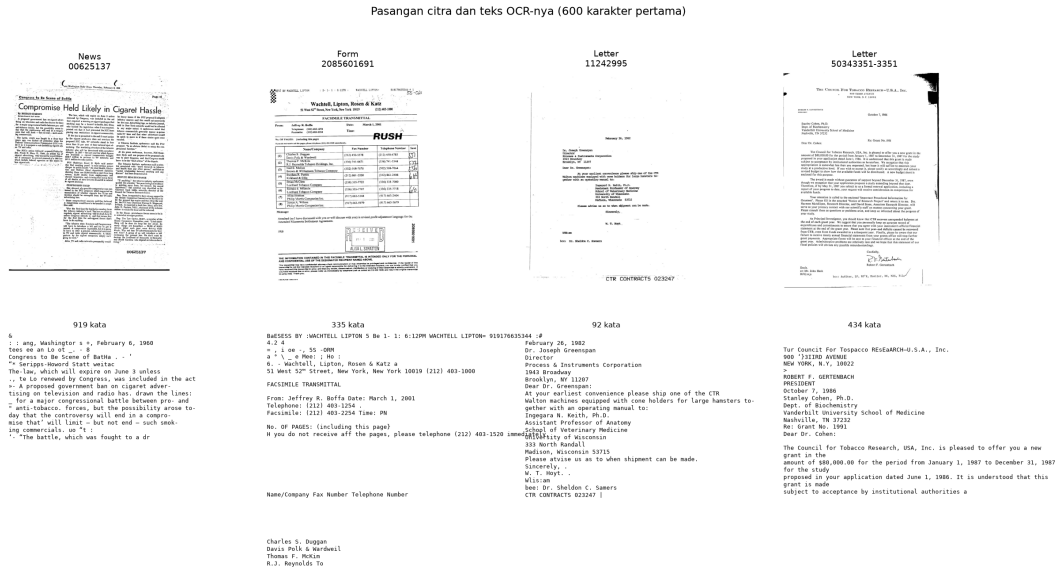
1. **Akurasi gabungan tidak cukup.** Model yang diam-diam unimodal dapat mencetak OA *lebih tinggi* daripada model yang benar-benar multimodal. Karena itu uji *missing modality* wajib untuk setiap model fusion.
2. **Kekuatan cabang teks menentukan apakah teks dipakai.** Kekuatan itu bergantung pada OCR dan embedding, dan kedua hal inilah yang menjadi variabel Fase 2.
3. **Fusion fitur yang dipakai di Fase 2 adalah versi yang sudah diperbaiki.** Dengan begitu, kegagalan yang sudah diketahui tidak dicampuradukkan dengan efek mesin OCR.

3.3 Dataset dan Protokol

Tobacco3482 (Kumar, Ye dan Doermann, 2014) berisi 3.482 citra dokumen dalam 10 kelas: Advertisement, Email, Form, Letter, Memo, News, Note, Report, Resume, dan Scientific. Kelas terbesar adalah Memo (620 dokumen) dan terkecil Resume (120 dokumen). Citra diambil dari Kaggle dalam format JPG (patrickaudriaz, 2026), yang tidak memiliki lisensi baku.

QS-OCR-Small (QuickSign, 2026) berlisensi Apache-2.0. Isinya teks Tesseract 4 dari citra TIF asli. Dataset ini dipakai sebagai **kondisi acuan** dari Fase 1.

Contoh pasangan citra dan teksnya ditunjukkan Gambar 3.5. Derau OCR terlihat jelas pada contoh itu, misalnya `Tur Council For Tospacco REsEaARCH`.



Gambar 3.5 Contoh pasangan citra dokumen dan teks QS-OCR-nya

Sumber: Tobacco3482 dan QS-OCR; diolah kelompok.

Protokol pembagian data sama dengan Fase 1:

- 800 dokumen latih per pembagian, 10% di antaranya dipakai untuk validasi;
- seed 42, 43, dan 44;
- **indeks pembagian yang sama** di semua kondisi, supaya perbedaan antar-kondisi tidak tercampur perbedaan data.

Pemakaian dataset dibatasi untuk keperluan akademik non-komersial, dan tidak ada berkas dataset yang didistribusikan ulang.

3.4 Ekstraksi OCR Multi-mesin

Konfigurasi setiap mesin disajikan pada Tabel 3.4.

Tabel 3.4 Mesin OCR dan konfigurasinya

Mesin	Konfigurasi	Kotak teks
QS-OCR (acuan)	Tesseract 4.0-beta pada TIF asli, `--oem 1 --psm 3`	tidak tersedia
Tesseract	versi 5 pada JPG, konfigurasi sama dengan QS-OCR	per kata
EasyOCR	versi 1.7.2, model bahasa Inggris, GPU	per baris
PaddleOCR	versi 3.7.0, PP-OCRv5 *mobile*, CPU, tanpa koreksi orientasi	per baris

Sumber: Rancangan kelompok.

Empat keputusan desain menyertai konfigurasi tersebut:

1. **Semua mesin membaca citra JPG yang sama**, termasuk Tesseract yang dijalankan ulang. Selisih antara QS-OCR dan Tesseract-JPG karena itu mengukur efek gabungan format citra dan versi Tesseract.

2. **Urutan baca mesin berbasis kotak direkonstruksi**: baris dari atas ke bawah, kata dari kiri ke kanan. Karena CNN 1D peka urutan, perbedaan urutan baca dicatat sebagai bagian dari efek mesin.
3. **Teks dan kotak posisi setiap halaman disimpan**, sehingga tahap lanjutan tidak memerlukan OCR ulang.
4. **Versi pustaka dan nama model dikunci serta dicatat.** PaddleOCR versi terbaru, misalnya, diam-diam mengganti model bawaannya ke PP-OCRv6, yang sekitar tiga kali lebih lambat di CPU pada uji kelayakan.

Keras-OCR disarankan dosen, tetapi belum dimasukkan. Alasannya dijelaskan pada risiko R3 (Subbab 4.3).

3.5 Proksi Kualitas OCR

Tobacco3482 tidak memiliki transkripsi acuan, sehingga *character error rate* tidak dapat dihitung. Tiga proksi berikut menggambarkan keluaran OCR tanpa menilai benar-salahnya.

1. **Kata per halaman dan persentase halaman kosong.** Proksi ini menangkap mesin yang melewatkan blok teks.
2. **Laju OOV.** Untuk dokumen d, laju OOV adalah bagian kata alfabetik dengan panjang minimal empat huruf yang tidak terdapat dalam daftar kata bahasa Inggris V (Speer, 2023):

$$\mathrm{OOV}(d) = \frac{|\{w \in d : |w| \geq 4,\ w \notin V\}|}{|\{w \in d : |w| \geq 4\}|} \tag{3.1}$$

   Salah baca yang kebetulan berupa kata yang ada, misalnya `tbe` untuk `the`, tidak terhitung. Karena itu nilai ini adalah *batas bawah* galat.
3. **Kesepakatan antar-mesin.** Kesepakatan dua mesin diukur dengan indeks Jaccard atas himpunan kata (A dan B) yang keduanya baca:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \tag{3.2}$$

   Urutan kata sengaja diabaikan, karena mesin berbeda urutan baca walaupun kata yang dibaca sama.

3.6 Representasi Teks dan Citra

Dua representasi teks diuji.

FastText dan CNN 1D. Ini pipeline Fase 1 tanpa perubahan. Setiap kata dipetakan ke vektor FastText 300 dimensi (Persamaan 2.1). Sekuens dibatasi 500 kata, lalu diproses CNN 1D empat lapis.

BERT-base. Model ini di-*fine-tune*, seperti pada Kashyap, Mittal dan Singh (2026), dengan masukan maksimum 512 token. Pelatihan memakai *mixed precision* dan akumulasi gradien supaya muat di GPU 4 GB. Bila tetap tidak muat, model diganti DistilBERT, dan penggantian itu dicatat sebagai deviasi.

Teks masuk ke kedua representasi **tanpa** praproses gaya Kashyap, yaitu tanpa membuang angka dan *stopword*. Tujuannya agar efek embedding tidak tercampur efek praproses.

Cabang citra memakai MobileNetV2 berbobot awal ImageNet, dengan masukan 384×384 dan rasio aspek di-*warp*. Cabang ini identik dengan Fase 1, dan *checkpoint*-nya dipakai ulang.

3.7 Strategi Fusion yang Diuji

Dua strategi fusion diuji.

1. **Rata-rata logit** (Persamaan 2.3), yaitu aturan Kashyap, Mittal dan Singh (2026). Strategi ini tidak memerlukan pelatihan ulang, sehingga dapat diterapkan pada *semua* kondisi.
2. **Fusion tingkat fitur yang sudah diperbaiki**:

$$\hat{y} = \arg\max_{c} \ \mathrm{MLP}([\,\mathrm{LN}(\mathbf{v}_t)\,;\,\mathrm{LN}(\mathbf{v}_v)\,])_c \tag{3.3}$$

   Cabang teks diinisialisasi dari model teks yang sudah terlatih. Biayanya sekitar empat jam per run, sehingga strategi ini hanya diterapkan pada kondisi OCR terbaik dan terburuk.

3.8 Desain Eksperimen dan Hipotesis

Matriks eksperimen disajikan pada Tabel 3.5.

Tabel 3.5 Matriks eksperimen

Kelompok	Kondisi	Jumlah run
Cabang teks	4 kondisi OCR $\times$ 2 embedding $\times$ 3 seed	24
Rata-rata logit	setiap model teks di atas + cabang citra Fase 1	24 (tanpa pelatihan)
Fusion fitur	kondisi OCR terbaik dan terburuk, FastText, seed 42	2 (+4 bila waktu cukup)
Uji *missing modality*	setiap model fusion	tanpa pelatihan

Sumber: Rancangan kelompok.

Pemeriksaan kewarasan. Sel QS-OCR $\times$ FastText harus mereproduksi CNN 1D Fase 1 ($0{,}7266 \pm 0{,}0059$). Bila tidak, ada yang rusak dalam pipeline, dan eksperimen dihentikan sampai penyebabnya ditemukan.

Hipotesis dirumuskan *sebelum* eksekusi, dan akan dilaporkan apa adanya, termasuk bila keliru. Pada Fase 1, hipotesis ketahanan kami terbukti keliru, dan temuan itu justru menjadi temuan utama.

H1. **(RM1)** Perbedaan akurasi cabang teks antar-mesin OCR bersifat nyata, yaitu melampaui simpangan antar-seed (±0,006). Mesin modern belum tentu unggul. Tobacco3482 berisi pindaian cetak hitam putih, yaitu kondisi tempat Tesseract paling kuat. Selain itu, CNN 1D peka urutan baca, yang berbeda antar-mesin.

H2. **(RM2)** BERT memperkecil selisih antar-mesin dibandingkan FastText. Argumen tandingannya: model bahasa standar juga melemah pada teks OCR (Michail et al., 2025), dan batas 512 token memotong dokumen panjang.

H3. **(RM3)** Pada fusion fitur, Δ_{teks} membesar seiring akurasi cabang teks. Rata-rata logit menjamin $\Delta_{\text{teks}} > 0$ secara konstruksi, tetapi OA-nya dapat turun bila cabang teks lemah.

3.9 Evaluasi dan Uji Statistik

Setiap model dievaluasi dengan lima ukuran: OA, macro F1 (Persamaan 2.5), F1 per kelas, dan oracle, ditambah Δ_{teks} serta Δ_{citra} (Persamaan 2.6) untuk setiap model fusion.

Perbandingan dua kondisi memakai uji McNemar (Persamaan 2.7) pada data uji yang sama, per seed. Uji binomial eksak dipakai bila $b + c < 25$. Ada enam pasangan mesin OCR per jenis embedding, sehingga ambang signifikansinya dikoreksi menjadi $0{,}05/6$. Sebuah perbedaan dinyatakan konsisten bila signifikan dan arahnya sama di ketiga seed. Semua angka dilaporkan sebagai rata-rata $\pm$ simpangan baku tiga seed.

BAB 4 RENCANA PELAKSANAAN

4.1 Jadwal

Implementasi Fase 2 dimulai **setelah proposal ini disetujui**. Setiap tahap diakhiri dengan catatan hasil dan pemeriksaan sebelum lanjut ke tahap berikutnya. Jadwalnya disajikan pada Tabel 4.1.

Tabel 4.1 Jadwal pelaksanaan Fase 2

Minggu	Kegiatan	Keluaran dan kriteria selesai
1	OCR multi-mesin	Teks dan kotak dari tiga mesin untuk 3.482 halaman; audit resolusi citra; tabel proksi kualitas (Subbab 3.5); versi pustaka tercatat
2	Cabang teks: FastText	12 model; sel acuan mereproduksi Fase 1; uji McNemar antar-mesin
3	Cabang teks: BERT	12 model; uji interaksi mesin OCR $\times$ embedding
4	Fusion	Rata-rata logit untuk 24 sel; fusion fitur untuk dua kondisi; Δ_{teks} dan Δ_{citra} setiap model
5	Analisis dan laporan	Jawaban RM1–RM3 beserta jejaknya ke angka sumber; tabel grid; grafik Δ_{teks} terhadap akurasi cabang teks
6	Rancangan tahap lanjutan	Rancangan teks sebagai objek beserta referensinya (Subbab 4.5)

Sumber: Rancangan kelompok.

4.2 Kebutuhan Komputasi

Seluruh komputasi dijalankan pada laptop dengan spesifikasi RTX 3050 (4 GB VRAM), Intel Core i7 generasi 11, dan RAM 24 GB. Perkiraan waktunya disajikan pada Tabel 4.2.

Angka bertanda * berasal dari eksekusi nyata Fase 1. Angka OCR berasal dari uji kelayakan pada satu halaman sintetis, dan akan diukur ulang pada 20 halaman pertama sebelum proses penuh dijalankan. Angka BERT masih berupa perkiraan.

Tabel 4.2 Perkiraan waktu komputasi

Pekerjaan	Satuan	Total
OCR Tesseract (CPU)	±0,3 detik/halaman	±0,3 jam
OCR PaddleOCR (CPU)	±2 detik/halaman	±2 jam
OCR EasyOCR (GPU)	diukur saat uji coba	±1 jam
Ekstraksi fitur FastText	sekali muat model (15 GB RAM)	<1 jam
CNN 1D	4,7 menit/run*	±1 jam (12 run)
BERT-base	perkiraan 10–20 menit/run	2–4 jam (12 run)
Rata-rata logit dan uji *missing modality*	tanpa pelatihan	hitungan menit
Fusion fitur	4,04 jam/run*	±8 jam (2 run)
Total		**±15–20 jam**

Sumber: Eksekusi Fase 1 dan uji kelayakan kelompok.

4.3 Risiko dan Mitigasi

Risiko yang sudah teridentifikasi dan mitigasinya disajikan pada Tabel 4.3.

Tabel 4.3 Risiko dan mitigasi

	Risiko	**Mitigasi**
R1	PaddleOCR membawa `opencv-contrib-python`, yang bentrok dengan opencv milik EasyOCR dan menggeser versi numpy	PaddleOCR dijalankan di *virtual environment* terpisah (±1 GB), sehingga lingkungan utama tidak tersentuh
R2	Tesseract di Windows bukan paket pip	Dipasang lewat `winget`, dengan langkah manual sebagai cadangan
R3	Keras-OCR membutuhkan TensorFlow dengan API Keras 2, yang tidak tersedia untuk Python 3.12. Dependensinya, `imgaug`, juga tidak cocok dengan numpy versi baru	Dijalankan di lingkungan Python 3.11 tersendiri bila diwajibkan. Bila tidak, tiga mesin sudah cukup untuk menjawab RM1–RM3
R4	BERT-base tidak muat di GPU 4 GB	*Mixed precision*, akumulasi gradien, atau DistilBERT (dicatat sebagai deviasi)
R5	Menolkan masukan menghasilkan input di luar distribusi, sehingga Δ dapat melebih-lebihkan ketergantungan. Pada Fase 1, model yang diperbaiki jatuh ke 0,1223 tanpa teks	Δ dilaporkan bersama *linear probe*, dan ditafsirkan sebagai ukuran ketergantungan, bukan sumbangan informasi
R6	Perbedaan antar-mesin lebih kecil daripada derau antar-seed	Itu tetap merupakan jawaban RM1: temuan negatif yang terukur, disertai uji statistik

Sumber: Analisis kelompok.

Uji kelayakan yang telah dilakukan. Ketiga mesin OCR telah dijalankan pada satu halaman memo sintetis, dan ketiganya membaca seluruh baris dengan benar. Pengujian ini juga mengungkap risiko R1 dan R3 serta penggantian model bawaan PaddleOCR, semuanya *sebelum* dataset disentuh.

4.4 Luaran dan Kriteria Keberhasilan

Luaran penelitian ini adalah:

1. teks dan kotak posisi teks Tobacco3482 dari tiga mesin OCR, beserta proksi kualitasnya;
2. grid akurasi cabang teks untuk empat kondisi OCR $\times$ dua embedding $\times$ tiga seed, beserta uji McNemar;
3. nilai Δ_{teks} dan Δ_{citra} untuk setiap model fusion;
4. laporan yang menyatakan setiap hipotesis terdukung atau tidak, dengan rujukan ke angka sumbernya.

Keberhasilan diukur dari kelengkapan dan ketelitian jawaban, *bukan* dari arah hasilnya. Bila mesin OCR ternyata tidak berpengaruh, itu jawaban yang sah dan

informatif: artinya, celah pelaporan kualitas OCR yang diidentifikasi Mirończuk (2026) tidak berdampak pada dataset ini.

4.5 Tahap Lanjutan: Teks sebagai Objek

Sesuai arahan dosen pengampu, tahap berikutnya memperlakukan teks bukan hanya sebagai rangkaian kata, tetapi sebagai **objek berposisi** pada halaman. Bahannya sudah tersedia dari langkah OCR, karena setiap mesin menyimpan kotak teksnya. Ada tiga kandidat representasi:

1. fitur posisi dua dimensi di samping embedding kata;
2. peta kotak teks sebagai citra, yaitu setiap kotak digambar pada kanvas seukuran halaman;
3. graf yang simpulnya kotak teks dan sisinya kedekatan spasial.

Satu kontrol bersifat wajib. Kode ID arsip pada Tobacco3482 adalah objek teks berposisi konsisten, dan fitur dari kode ID saja sudah memberi ±60% akurasi (Larson et al., 2025). Model berbasis posisi dapat belajar jalan pintas ini alih-alih belajar tata letak dokumen. Karena itu setiap model akan diuji dengan dan tanpa kotak kode ID.

Granularitas kotak juga berbeda antar-mesin: Tesseract per kata, sedangkan EasyOCR dan PaddleOCR per baris. Rancangan rinci beserta referensi (minimal tahun 2025) untuk tahap ini akan diajukan tersendiri setelah analisis Fase 2 selesai.

DAFTAR REFERENSI

Audebert, N., Herold, C., Slimani, K. dan Vidal, C., 2020. Multimodal Deep Networks for Text and Image-Based Document Classification. Dalam: *Machine Learning and Knowledge Discovery in Databases: International Workshops of ECML PKDD 2019*. Vol. 1167. Communications in Computer and Information Science. Springer International Publishing, pp.427-443. Tersedia di: <https://doi.org/10.1007/978-3-030-43823-4_35>.

Ba, J.L., Kiros, J.R. dan Hinton, G.E., 2016. *Layer Normalization*. Tersedia di: <https://doi.org/10.48550/ARXIV.1607.06450>.

Baek, Y., Lee, B., Han, D., Yun, S. dan Lee, H., 2019. Character Region Awareness for Text Detection. Dalam: *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, pp.9357-9366. Tersedia di: <https://doi.org/10.1109/cvpr.2019.00959>.

Baltrusaitis, T., Ahuja, C. dan Morency, L.-P., 2019. Multimodal Machine Learning: A Survey and Taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), pp.423-443. Tersedia di: <https://doi.org/10.1109/tpami.2018.2798607>.

Bojanowski, P., Grave, E., Joulin, A. dan Mikolov, T., 2017. Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics*, 5, pp.135-146. Tersedia di: <https://doi.org/10.1162/tacl_a_00051>.

Devlin, J., Chang, M.-W., Lee, K. dan Toutanova, K., 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Dalam: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Association for Computational Linguistics, pp.4171-4186. Tersedia di: <https://doi.org/10.18653/v1/n19-1423>.

Dietterich, T.G., 1998. Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms. *Neural Computation*, 10(7), pp.1895-1923. Tersedia di: <https://doi.org/10.1162/089976698300017197>.

Dunn, O.J., 1961. Multiple Comparisons among Means. *Journal of the American Statistical Association*, 56(293), pp.52-64. Tersedia di: <https://doi.org/10.1080/01621459.1961.10482090>.

Francis, S. dan Sangeetha, M., 2025. A comparison study on optical character recognition models in mathematical equations and in any language. *Results in Control and Optimization*, 18, p.100532. Tersedia di: <https://doi.org/10.1016/j.rico.2025.100532>.

Harley, A.W., Ufkes, A. dan Derpanis, K.G., 2015. Evaluation of deep convolutional nets for document image classification and retrieval. Dalam: *2015 13th International Conference on Document Analysis and Recognition (ICDAR)*. IEEE, pp.991-995. Tersedia di: <https://doi.org/10.1109/icdar.2015.7333910>.

JaidedAI, 2024. *EasyOCR*. Version 1.7.2. Tersedia di: <https://github.com/JaidedAI/EasyOCR>.

Kashyap, A., Mittal, M. dan Singh, S., 2026. Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification. *International Journal of Intelligent Systems*, 2026(1), 4241437. Tersedia di: <https://doi.org/10.1155/int/4241437>.

Kim, Y., 2014. Convolutional Neural Networks for Sentence Classification. Dalam: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, pp.1746-1751. Tersedia di: <https://doi.org/10.3115/v1/d14-1181>.

Kumar, J., Ye, P. dan Doermann, D., 2014. Structural similarity for document image classification and retrieval. *Pattern Recognition Letters*, 43, pp.119-126. Tersedia di: <https://doi.org/10.1016/j.patrec.2013.10.030>.

Larson, S., Duwal, S., Vilnrotter, B., Chakkithara, G., Padwal, V. dan Leach, K., 2025. Spurious Cues in RVL-CDIP and Tobacco3482 Document Classification: The Case of ID Codes. Dalam: *Proceedings of the 2025 ACM Symposium on Document Engineering*. ACM, pp.1-4. Tersedia di: <https://doi.org/10.1145/3704268.3748683>.

McNemar, Q., 1947. Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages. *Psychometrika*, 12(2), pp.153-157. Tersedia di: <https://doi.org/10.1007/bf02295996>.

Michail, A., Opitz, J., Wang, Y., Meister, R., Sennrich, R. dan Clematide, S., 2025. Cheap Character Noise for OCR-Robust Multilingual Embeddings. Dalam: *Findings of the Association for Computational Linguistics: ACL 2025*. Association for Computational Linguistics, pp.11705-11716. Tersedia di: <https://doi.org/10.18653/v1/2025.findings-acl.609>.

Mirończuk, M.M., 2026. Document classification pattern recognition via information fusion: A systematic review of multimodal and multiview representation approaches. *Information Fusion*, 132, p.104247. Tersedia di: <https://doi.org/10.1016/j.inffus.2026.104247>.

PaddlePaddle Authors, 2026. *PaddleOCR*. Version 3.7.0. Tersedia di: <https://github.com/PaddlePaddle/PaddleOCR>.

patrickaudriaz, 2026. *Tobacco3482 Dataset (JPG)*. Kaggle. Tersedia di: <https://www.kaggle.com/datasets/patrickaudriaz/tobacco3482jpg> [Diakses 28 September 2026].

QuickSign, 2026. *OCRized Text Dataset (QS-OCR)*, *rilis v1.0*. GitHub. Tersedia di: <https://github.com/QuickSign/ocrized-text-dataset> [Diakses 28 September 2026].

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. dan Chen, L.-C., 2018. MobileNetV2: Inverted Residuals and Linear Bottlenecks. Dalam: *2018*

IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, pp.4510-4520. Tersedia di: <https://doi.org/10.1109/cvpr.2018.00474>.

Shi, B., Bai, X. dan Yao, C., 2017. An End-to-End Trainable Neural Network for Image-Based Sequence Recognition and Its Application to Scene Text Recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(11), pp.2298-2304. Tersedia di: <https://doi.org/10.1109/tpami.2016.2646371>.

Smith, R., 2007. An Overview of the Tesseract OCR Engine. Dalam: *Ninth International Conference on Document Analysis and Recognition (ICDAR 2007) Vol 2*. IEEE, pp.629-633. Tersedia di: <https://doi.org/10.1109/icdar.2007.4376991>.

Speer, R., 2023. *wordfreq*. Version 3.1.1. Tersedia di: <https://github.com/rspeer/wordfreq>.

Zhang, J., Zhang, Q., Wang, B., Ouyang, L., Wen, Z., Li, Y., Chow, K.-H., He, C. dan Zhang, W., 2025. OCR Hinders RAG: Evaluating the Cascading Impact of OCR on Retrieval-Augmented Generation. Dalam: *2025 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, pp.17443-17453. Tersedia di: <https://doi.org/10.1109/iccv51701.2025.01620>.

LAMPIRAN A RIWAYAT PEMILIHAN REFERENSI DAN TANGGAPAN DOSEN

A.1 Pemilihan Jurnal Awal

Jurnal pertama yang dipilih pada Progress 1 adalah Audebert et al. (2020). Ada empat alasan:

1. **Sesuai topik mata kuliah.** Paper ini menggabungkan dua modalitas yang asalnya sama tetapi sifatnya berbeda: tata letak halaman dan isi tulisan.
2. **Datanya terbuka.** Citra Tobacco3482 tersedia di Kaggle, dan teks OCR-nya dirilis penulis sebagai QS-OCR, sehingga modalitas teks tidak perlu dibuat sendiri.
3. **Arsitekturnya ringan.** MobileNetV2 dan FastText dengan CNN 1D dapat dilatih pada GPU laptop 4 GB.
4. **Tidak ada kode resmi.** Repositori QS-OCR hanya berisi skrip OCR, sehingga seluruh arsitektur harus ditulis ulang dari spesifikasi paper. Ini menuntut pemahaman metode, bukan sekadar menjalankan kode orang lain.

A.2 Tanggapan Dosen atas Progress 1

Tabel A.1 Tanggapan dosen pengampu dan tindak lanjutnya

Tanggapan	Tindak lanjut
Alur OCR → teks dengan Tesseract dan FastText sudah dipahami	Dipertahankan sebagai kondisi acuan (QS-OCR × FastText)
Eksplorasi metode OCR: EasyOCR, PaddleOCR, Keras-OCR	Mesin OCR dijadikan variabel penelitian (RM1). Keras-OCR bersyarat, lihat risiko R3
Celah penelitian belum ditentukan	Dirumuskan pada Bab 1 dan Subbab 2.1, didukung hasil studi pendahuluan
Kemungkinan eksplorasi pada embedding	Embedding dijadikan variabel kedua: FastText dan BERT (RM2)
Teks yang dideteksi sebagai objek, untuk tahap selanjutnya	Kotak posisi teks disimpan sejak langkah OCR; rancangannya pada Subbab 4.5
Referensi masih tahun 2019 dan berbentuk arsip; minimal tahun 2025	Referensi utama diganti ke Kashyap, Mittal dan Singh (2026). Audebert dikutip dari versi terbitnya (Springer, 2020) sebagai baseline yang telah direplikasi

Sumber: Catatan tanggapan dosen pengampu.

Satu hal perlu dicatat soal referensi. Paper Audebert sebenarnya telah terbit di ECML PKDD 2019 Workshops, Springer CCIS vol. 1167 (2020). Kesalahan ada pada Progress 1, yang mengutip versi arXiv. Namun tahun terbitnya tetap tidak memenuhi syarat, sehingga posisi referensi utama tetap diganti.

A.3 Pencarian Referensi Baru

Pencarian dilakukan melalui Crossref dan Semantic Scholar dengan empat kriteria:

1. terbit di jurnal atau prosiding pada 2025 atau sesudahnya, bukan *preprint*;
2. membahas klasifikasi dokumen multimodal teks–citra, perbandingan mesin OCR, atau ketahanan embedding terhadap derau OCR;
3. metadata (DOI, volume, halaman) dapat diverifikasi;
4. teks lengkapnya dapat dibaca, tidak hanya abstraknya.

Hasilnya dirangkum pada Tabel A.2. Untuk Larson et al. (2025), yang dibaca baru abstraknya, karena unduhan teks lengkapnya belum berhasil.

Tabel A.2 Referensi utama dan pendukung yang terbit tahun 2025–2026

Referensi	Peran dalam penelitian ini
Kashyap, Mittal dan Singh (2026)	Referensi utama: fusion teks–citra terkini pada Tobacco3482
Mirończuk (2026)	Pembingkai celah: meta-analisis 139 studi fusion untuk klasifikasi dokumen
Francis dan Sangeetha (2025)	Perbandingan Tesseract, EasyOCR, PaddleOCR, Keras-OCR, dan mesin lain
Zhang et al. (2025)	Bukti bahwa galat OCR merambat ke tugas lanjutan
Michail et al. (2025)	Ketahanan embedding terhadap derau OCR
Larson et al. (2025)	Jalan pintas kode ID pada Tobacco3482

Sumber: Penelusuran kelompok.

A.4 Mengapa Kashyap et al. sebagai Referensi Utama

Kashyap, Mittal dan Singh (2026) adalah penerus langsung Audebert: keduanya menggabungkan cabang citra dan cabang teks OCR, dan keduanya diuji pada Tobacco3482. Kashyap juga membandingkan hasilnya secara eksplisit dengan Audebert.

Paper ini **tidak direplikasi**. *Fine-tuning*-nya memakan sekitar 63 jam pada GPU 16 GB dengan RVL-CDIP, jauh di luar perangkat yang tersedia. Yang diambil dari paper ini adalah:

- embedding BERT;
- aturan fusion rata-rata logit;
- arah lanjutan yang disebut penulisnya sendiri, yaitu pembobotan modalitas adaptif dan kondisi degradasi OCR.

Celah yang paling menentukan adalah mesin OCR-nya yang tidak disebutkan. Catatan kritis lengkapnya ada pada Lampiran B.

LAMPIRAN B CATATAN KRITIS ATAS KASHYAP ET AL. (2026)

Catatan berikut disusun dari pembacaan teks lengkap Kashyap, Mittal dan Singh (2026).

1. **Angka 92,00% pada Tobacco3482 tidak konsisten dengan protokolnya sendiri.**
   - Model dilatih pada 16 kelas RVL-CDIP. Penulis sendiri menyatakan bahwa kelas Note dan Report hanya ada di Tobacco3482.
   - Kedua kelas itu berisi $201 + 265 = 466$ dokumen, yang tidak mungkin diprediksi benar oleh model 16 kelas RVL-CDIP.
   - Bila seluruh 3.482 dokumen dievaluasi, akurasi maksimum yang mungkin adalah:

     $$\mathrm{OA}_{\text{maks}} = \frac{3482 - 466}{3482} = \frac{3016}{3482} = 0{,}866 \tag{B.1}$$

   - Tabel per kelas paper memang hanya memuat 8 kelas.

   Kemungkinan besar 92% dihitung pada sekitar 3.016 dokumen, padahal tabel dataset paper menyebut 3.482 dokumen dan 10 kelas.
2. **Perbandingan dengan Audebert tidak setara.** Paper menyandingkan 92,00% (dilatih pada ±320.000 dokumen RVL-CDIP) dengan 87,8% Audebert (dilatih pada 800 dokumen Tobacco3482), tanpa menyebut perbedaan protokol itu.
3. **Potensi tumpang tindih data tidak dibahas.** RVL-CDIP dan Tobacco3482 sama-sama diambil dari arsip industri tembakau yang sama. Hal ini belum kami verifikasi, karena verifikasinya membutuhkan RVL-CDIP.
4. **Satu kali run**, tanpa simpangan baku dan tanpa uji statistik. Metrik Tobacco3482 dilaporkan dalam bentuk *weighted*, bukan macro.
5. **Mesin OCR tidak disebutkan**, sehingga cabang teksnya tidak dapat direproduksi, dan keunggulan BERT tidak dapat dipisahkan dari efek mesin OCR.

Catatan ini tidak mengurangi nilai paper tersebut sebagai acuan arsitektur. Catatan ini menjelaskan mengapa angka penelitian ini tidak dibandingkan langsung dengan angka Kashyap, dan mengapa mesin OCR dijadikan variabel.

LAMPIRAN C HASIL LENGKAP STUDI PENDAHULUAN

Tabel C.1 menyajikan F1 per kelas hasil replikasi kelompok (K), yaitu rata-rata tiga seed, berdampingan dengan Tabel 3 Audebert et al. (2020) (P).

Selisih terbesar ada pada kelas Resume untuk model fusion: 0,803 berbanding 0,96. Selisih inilah yang menjadi petunjuk pertama bahwa cabang teks tidak terpakai, karena model teks saja mencapai 0,969 pada kelas yang sama.

Tabel C.1 F1 per kelas: replikasi kelompok (K) dan paper (P)

	Teks		**Citra**		**Fusion**		**Oracle**	
Kelas	K	P	K	P	K	P	K	P
Advertisement	0,537	0,60	0,902	0,94	0,894	0,93	0,930	0,94
Email	0,953	0,96	0,955	0,96	0,961	0,98	0,983	0,99
Form	0,718	0,76	0,804	0,85	0,848	0,88	0,902	0,94
Letter	0,671	0,71	0,805	0,83	0,835	0,86	0,898	0,92
Memo	0,758	0,79	0,844	0,90	0,879	0,90	0,920	0,93
News	0,709	0,67	0,890	0,89	0,883	0,90	0,938	0,93
Note	0,621	0,62	0,771	0,83	0,780	0,85	0,876	0,89
Report	0,495	0,43	0,527	0,61	0,638	0,71	0,735	0,81
Resume	0,969	0,97	0,784	0,80	0,803	0,96	0,951	0,97
Scientific	0,587	0,57	0,554	0,62	0,583	0,68	0,718	0,79
Macro F1	0,702	0,71	0,784	0,82	0,811	0,86	0,885	0,91
OA	0,727	0,738	0,809	0,845	0,834	0,878	0,898	0,921

Sumber: Eksekusi kelompok; kolom P dari Audebert et al. (2020).

Selain model di atas, studi pendahuluan juga menjalankan tiga uji lanjutan, semuanya pada seed 42:

1. fusion konkatenasi tanpa *early stopping*: OA 0,8304, macro F1 0,8108;
2. diagnostik fitur cabang teks, tanpa pelatihan;
3. fusion yang diperbaiki: OA 0,8110, macro F1 0,8108.

Ketiganya diringkas pada Subbab 3.2.