

Klasifikasi Dokumen Multimodal: Penggabungan Fitur Teks Hasil OCR dan Citra Dokumen

Proposal Tugas Akhir — Analisis dan Pemrosesan Data Multimodal

Ramadhani Al-Qadri · 4 Oktober 2026

1. Problem statement

Klasifikasi dokumen hasil pindai secara alami bermodalitas ganda. Satu dokumen membawa informasi di dua lapis: **tata letaknya** (posisi blok, kerapatan tulisan, tabel, tanda tangan) dan **isi tekstualnya** (kata kunci seperti “Dear Sir”, “Abstract”, “Curriculum Vitae”). Pendekatan unimodal memakai salah satu saja, sehingga langit-langitnya bisa diprediksi: model berbasis citra kebingungan pada dua kelas yang tata letaknya mirip tapi isinya berbeda, model berbasis teks gagal saat OCR-nya buruk atau dokumennya nyaris tanpa teks.

Proyek ini mereplikasi dan memperluas Audebert *et al.* [1] di atas dataset Tobacco3482, menjawab tiga pertanyaan:

- P1.** Seberapa besar keuntungan penggabungan di atas baseline unimodal terbaik, dan berapa bagian dari potensi teoretisnya yang berhasil dipanen?
- P2.** Strategi penggabungan mana yang bekerja — konkatenasi atau penjumlahan berbobot — dan apakah temuan negatif paper terhadap penjumlahan dapat direproduksi?
- P3.** Apakah model gabungan benar-benar *memakai* kedua modalitas, atau hanya tampak lebih baik karena satu cabang mendominasi?

P3 bukan bagian dari paper asli dan merupakan kontribusi tambahan proyek ini: paper hanya melaporkan akurasi agregat, yang secara prinsip tidak dapat membedakan model yang benar-benar multimodal dari model yang diam-diam unimodal.

2. Modalitas yang digunakan

Citra dokumen. Citra grayscale satu halaman penuh, diubah ke 384×384 tanpa *padding* (rasio aspek di-*warp*); resolusi jauh di atas 224 standar karena tulisan perlu tetap terbaca sebagai tekstur. Diproses dengan MobileNetV2 [4] berbobot awal ImageNet — dipilih bukan karena paling akurat, melainkan paling murah secara komputasi.

Teks hasil OCR. Diekstraksi dengan Tesseract 4.0 (mesin LSTM, `--oem 1 --psm 3 -l eng`), tanpa praproses citra maupun pascaproses teks: salah eja dibiarkan apa adanya, karena justru ketahanan terhadap derau OCR inilah yang diuji. Tiap kata dipetakan ke vektor FastText 300 dimensi [5]; *subword n-gram*-nya dipilih karena mampu memberi vektor pada kata yang rusak akibat OCR dan karena itu tidak ada di kosakata mana pun. Sekuens kata diproses CNN 1D ber-*filter* multi-lebar bergaya Kim [6]. Kedua cabang menghasilkan vektor fitur 128 dimensi.

3. Dataset kandidat: sumber dan lisensi

Dataset	Sumber	Lisensi / status hak
Tobacco3482-jpg (3.482 citra, 10 kelas)	Kaggle patrick-audriaz/tobacco3482jpg	Kolom lisensi Kaggle: “Other (specified in description)”; deskripsinya hanya menyatakan “All rights belong to their respective owners” dan merujuk Kumar <i>et al.</i> [2]. Tidak ada lisensi baku.
QS-OCR-Small (3.482 .txt)	GitHub QuickSign/ocrized-text-dataset, Releases tag v1.0	Apache-2.0 (lisensi repositori, terverifikasi lewat GitHub API). Teksnya turunan Tobacco3482, sehingga syarat hak sumber hulu tetap berlaku.
RVL-CDIP + QS-OCR-Large	Harley <i>et al.</i> [3]	Tidak dipakai: ~400.000 dokumen, di luar anggaran waktu dan penyimpanan untuk lingkup satu mata kuliah.

Dua konsekuensi yang sudah diputuskan: pemakaian dibatasi pada konteks akademik non-komersial, konsisten dengan asal dokumen (arsip litigasi industri tembakau yang dipublikasikan untuk kepentingan publik); dan tidak ada berkas dataset yang didistribusikan lewat repositori proyek — direktori `data/` di-*gitignore*, notebook mengunduh langsung dari sumber aslinya.

Satu limitasi dinyatakan di awal: citra berasal dari versi JPG hasil *re-encode*, sedangkan teks QS-OCR di-OCR dari TIF asli. Sumber kedua modalitas karena itu **tidak identik**. Ini akan dilaporkan sebagai limitasi, bukan diperlakukan sebagai *bug*.

4. Metode fusion yang direncanakan

Penggabungan dilakukan di tingkat fitur (*late fusion*): kedua cabang dilatih sampai konvergen sebagai pengklasifikasi mandiri, lapisan klasifikasinya dipotong, lalu fiturnya digabungkan dan dilatih bersama *end-to-end*. Dua strategi diuji berdampingan:

F1. Konkatenasi. $[v_{\text{teks}}; v_{\text{citra}}]$ menjadi vektor 256 dimensi, masuk MLP dua lapis tersembunyi berlebar 2048 dengan *dropout* 0,5. Tidak mengandaikan apa pun tentang hubungan kedua ruang fitur; tugas menemukannya diserahkan ke MLP.

F2. Penjumlahan berbobot (paper menyebutnya *adaptive averaging*). $w_t v_{\text{teks}} + w_i v_{\text{citra}}$ menjadi vektor 128 dimensi. Mengandaikan kedua ruang fitur dapat *disejajarkan* — dimensi ke- i vektor teks harus bermakna sebanding dengan dimensi ke- i vektor citra.

Paper melaporkan F2 jatuh di bawah baseline citra murni, tetapi **tanpa angka, tanpa jumlah *run*, dan tanpa menjelaskan apa yang membuat penjumlahan itu “adaptif”**. Karena itu F2 diuji sendiri dengan mekanisme yang dicatat eksplisit sebagai asumsi: satu skalar terlatih per cabang, dilewatkan *softmax* sehingga $w_t + w_i = 1$, diinisialisasi seimbang 0,5 — bacaan yang paling cocok dengan frasa “*adaptive averaging*”. Bila hasilnya juga negatif, itu dilaporkan sebagai satu titik data untuk mekanisme yang *kami* pilih, bukan sebagai konfirmasi klaim paper secara umum.

5. Metrik evaluasi

Metrik	Alasan pemilihan
<i>Overall accuracy</i> (OA)	Metrik utama paper; perlu agar perbandingan langsung dengan angka yang dilaporkan menjadi mungkin.
Macro F1	Kelasnya timpang ($\sim 5:1$ terbesar berbanding terkecil). OA sendirian didominasi kelas besar, jadi macro F1 dilaporkan <i>berdampingan</i> , tidak menggantikan.
F1 per kelas + <i>confusion matrix</i>	Keuntungan fusion diperkirakan tidak merata; kelas mana yang membaik justru yang menunjukkan modalitas mana menyumbang apa.
<i>Oracle</i> (batas atas)	“Benar bila cabang teks atau citra benar”. Memungkinkan keuntungan fusion dinyatakan sebagai persentase potensi yang dipanen, bukan selisih mentah.
<i>Missing-modality test</i>	Penurunan akurasi saat satu modalitas dinolkan pada inferensi. Metrik yang menjawab P3 , dan satu-satunya yang dapat membedakan fusion sejati dari dominasi satu cabang.
Ablasi degradasi bertingkat	Rotasi, <i>blur</i> , derau, kompresi JPEG pada citra; penghapusan kata dan penyuntikan salah eja pada teks. Menguji klaim ketahanan yang tidak diuji paper.

Seluruh eksperimen dijalankan pada **3 *split* acak terstratifikasi** (seed 42/43/44, masing-masing 800 dokumen latih mengikuti protokol paper) dan dilaporkan sebagai rata-rata $\pm$ simpangan baku — tanpa simpangan antar-*seed*, selisih beberapa persepuluh persen tidak dapat dibedakan dari derau. Target replikasi adalah angka paper: OA 0,738 (teks), 0,845 (citra), 0,878 (fusion).

6. Kelayakan dalam sisa waktu semester

Komputasi memakai RTX 3050 *laptop* 4 GB VRAM; *batch* 40 dari paper dipertahankan lewat akumulasi gradien dengan *micro-batch* 8 ditambah *mixed precision*, dengan estimasi 12–18 jam untuk satu kali jalan pipeline penuh. Penyimpanan yang dibutuhkan: 3,29 GB citra, 2,5 MB teks, dan model FastText `cc.en.300.bin` sekitar 7 GB di disk (~ 15 GB RAM saat dimuat). Alur kerjanya dua mesin — kode ditulis dan diuji di satu mesin, dataset dan pelatihan dijalankan di mesin ber-CUDA — sehingga seluruh unduhan dan konfigurasi harus terjadi *di dalam* notebook, tanpa langkah terminal.

Risiko utamanya model fusion gagal melampaui baseline citra. Mitigasinya: tiga baseline unimodal, *oracle*, dan seluruh ablasi tetap merupakan hasil yang dapat dilaporkan. Temuan negatif yang terdokumentasi rapi lebih berguna daripada angka positif yang tidak bisa dijelaskan. Perlu dicatat bahwa seluruh arsitektur ditulis ulang dari spesifikasi di paper: repositori QuickSign hanya berisi *script* OCR, tidak ada kode model, sehingga tidak ada implementasi acuan yang dapat disalin.

References

- [1] N. Audebert, C. Herold, K. Slimani, C. Vidal, “Multimodal deep networks for text and image-based document classification,” arXiv:1907.06370, 2019.
- [2] J. Kumar, P. Ye, D. Doermann, “Structural similarity for document image classification and retrieval,” *Pattern Recognition Letters*, 2014.
- [3] A. W. Harley, A. Ufkes, K. G. Derpanis, “Evaluation of deep convolutional nets for document image classification and retrieval,” *ICDAR*, 2015.
- [4] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L.-C. Chen, “MobileNetV2: Inverted residuals and linear bottlenecks,” *CVPR*, 2018.
- [5] P. Bojanowski, E. Grave, A. Joulin, T. Mikolov, “Enriching word vectors with subword information,” *TACL*, 2017.
- [6] Y. Kim, “Convolutional neural networks for sentence classification,” *EMNLP*, 2014.