**ANALISIS & PEMROSESAN DATA MULTIMODAL**

# Review Paper: Klasifikasi Dokumen Multimodal Teks OCR dan Citra

**Audebert et al. (2020) dan Kashyap et al. (2026)**


Disusun oleh:

| | | |
|---|---|---|
| Yulian Anggreaif Rudamaga | : | 256150100011001 |
| Zalzabila Rani | : | 256150100011008 |
| Ramadhani Al-Qadri | : | 256150100011010 |

Dosen Pengampu:
Dr. Eng. Fitra Abdurrachman Bachtiar, S.T., M.Eng.

**PROGRAM STUDI MAGISTER ILMU KOMPUTER**
**DEPARTEMEN TEKNIK INFORMATIKA**
**FAKULTAS ILMU KOMPUTER**
**UNIVERSITAS BRAWIJAYA**

# 1 Pendahuluan

Laporan ini mereview dua paper tentang klasifikasi citra dokumen yang memadukan dua modalitas: citra halaman dan teks hasil OCR. Paper pertama adalah dasar replikasi proyek pada Fase 1, sedangkan paper kedua adalah referensi utama Fase 2. Identitas keduanya ada pada Tabel 1.

**Tabel 1 Identitas paper yang direview**

| | **Paper 1** | **Paper 2** |
|---|---|---|
| Judul | Multimodal Deep Networks for Text and Image-Based Document Classification | Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification |
| Penulis | Audebert, Herold, Slimani, Vidal (Quicksign, Prancis) | Kashyap, Mittal, Singh (Central University of Punjab, India) |
| Venue | ECML PKDD 2019 Workshops, CCIS 1167, Springer, hlm. 427–443 | International Journal of Intelligent Systems (Wiley), artikel 4241437, open access |
| Tahun | 2020 (workshop 2019) | 2026 (diterima 13 Juli 2026) |
| DOI | 10.1007/978-3-030-43823-4_35 | 10.1155/int/4241437 |
| Sitasi | Audebert et al. (2020) | Kashyap, Mittal dan Singh (2026) |

Setiap paper dibahas dengan sembilan poin wajib: (1) latar belakang dan permasalahan, (2) dataset, (3) modalitas, (4) pipeline keseluruhan, (5) model per unimodal, (6) metode fusi, (7) metrik evaluasi, (8) hasil keseluruhan beserta hasil per unimodal, dan (9) *future work*. Kami menambahkan empat poin yang menurut kami perlu untuk review yang utuh: (10) kontribusi utama, (11) detail pelatihan dan lingkungan eksperimen, (12) kelebihan, dan (13) catatan kritis (kelemahan, inkonsistensi, ancaman validitas). Bagian 4 membandingkan kedua paper, dan Bagian 5 menjelaskan apa yang kami ambil untuk proyek.

# 2 Paper 1: Audebert et al. (2020)

## 2.1 Latar Belakang dan Permasalahan

Banyak proses administrasi (pembukaan rekening, pajak, verifikasi identitas) kini menerima dokumen yang dipindai atau difoto pengguna. Dokumen ini tidak punya lapisan teks, sehingga pengecekan dan pengarsipannya masih dikerjakan operator manusia. Langkah pertama yang perlu diotomasi adalah mengenali jenis dokumen.

Masalah yang diangkat: klasifikasi berbasis tampilan visual saja cukup untuk kelas yang kasar (paspor vs. data bank), tetapi tidak cukup untuk kelas yang halus. Dua formulir pajak bisa berbagi tata letak dan logo yang sama, sedangkan isinya berbeda. Informasi pembedanya ada di teks, padahal teks itu tidak tersedia dalam bentuk digital dan harus diambil lewat OCR yang hasilnya berderau. Pertanyaan penelitiannya: apakah teks OCR yang berderau tetap bisa menaikkan akurasi klasifikasi citra dokumen jika digabung dengan fitur visual, dengan biaya komputasi yang tetap rendah?

## 2.2 Dataset

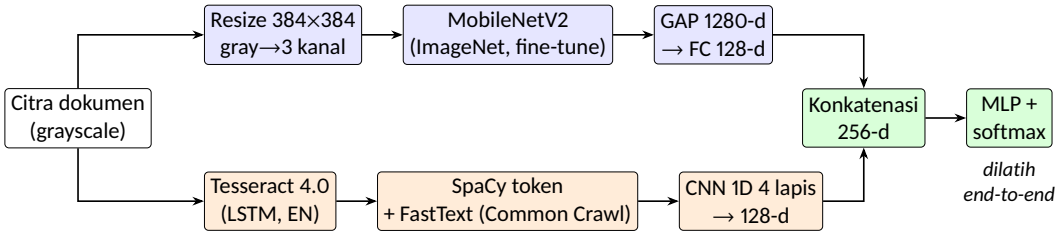
- **Tobacco3482** (Kumar, Ye dan Doermann, 2014): 3.482 dokumen hitam-putih, 10 kelas (*advertisement*, *email*, *form*, *letter*, *memo*, *news*, *note*, *report*, *resume*, *scientific*). Protokol: 800 dokumen untuk latih, sisanya untuk uji; hasil dirata-rata dari 3 kali percobaan.
- **RVL-CDIP** (Harley, Ufkes dan Derpanis, 2015): 400.000 dokumen grayscale, 16 kelas, 25.000 per kelas. Pembagian standar 320.000 latih, 40.000 validasi, 40.000 uji.
- **QS-OCR**: teks hasil Tesseract untuk kedua dataset di atas, dirilis penulis di GitHub `Quicksign/ocrized-text-dataset`. Dataset inilah yang kami pakai sebagai modalitas teks (QS-OCR-Small untuk Tobacco3482).

## 2.3 Modalitas

Dua modalitas yang keduanya berasal dari satu citra halaman: (a) **citra** grayscale halaman dokumen, dan (b) **teks** yang diekstraksi dari citra yang sama dengan Tesseract OCR. Teks bukan modalitas yang independen, melainkan turunan dari citra, sehingga kualitasnya dibatasi oleh kualitas OCR. Tata letak (posisi kata) tidak dipakai.

## 2.4 Pipeline Keseluruhan

Gambar 1 merangkum pipeline. Citra diproses oleh MobileNetV2, teks OCR diubah menjadi barisan vektor kata FastText lalu diproses CNN 1D. Kedua vektor fitur 128 dimensi digabung (konkatenasi) dan diklasifikasi oleh MLP. Seluruh jaringan dapat dilatih *end-to-end*.




**Gambar 1 Pipeline Audebert et al. (digambar ulang dari Gambar 1 dan Bagian 3–4 paper)**

## 2.5 Model per Unimodal

**Citra.** MobileNetV2 dipilih karena ringan (sekitar setara VGG-16 dalam akurasi, tetapi jauh lebih cepat). Citra di-*resize* ke $384 \times 384$ (rasio aspek dikorbankan), kanal grayscale diduplikasi tiga kali agar bobot ImageNet bisa dipakai, lalu jaringan di-*fine-tune*. Augmentasi (artefak JPEG, saturasi, kontras) tidak membantu, sehingga tidak dipakai.

**Teks.** Tesseract 4.0 (mesin LSTM, bahasa Inggris, segmentasi halaman penuh). Penulis menunjukkan derau OCR: rata-rata 136 kata (≥4 huruf) per dokumen, hanya 118 ada di kosakata GloVe dan 114 di kamus Enchant; sekitar 26 % korpus tidak ada di kamus bahasa Inggris. Karena itu dipilih embedding berbasis subkata, **FastText** (Common Crawl), yang tetap memberi vektor masuk akal untuk kata salah eja. Tokenisasi memakai SpaCy. Dua klasifikator dibandingkan:

- MLP atas embedding dokumen (rata-rata berbobot ala Arora + PCA): 2048 neuron per lapis, ReLU, Dropout, BatchNorm, lapis akhir 128-d;
- **CNN 1D** atas barisan kata (dipilih): 4 lapis, kernel 12, 512 kanal, ReLU, max-pooling stride 2, lalu max-pooling sepanjang waktu, Dropout, dan FC. Input dipotong/di-*padding* ke 500 kata.

## 2.6 Metode Fusi

Fusi tingkat fitur (*intermediate/feature-level*). Vektor teks 128-d (lapis sebelum softmax CNN 1D) dan vektor citra 1280-d hasil *global average pooling* yang diproyeksikan ke 128-d oleh FC, lalu **dikonkatenasi** dan diumpankan ke MLP. Penulis juga mencoba *adaptive averaging* (penjumlahan fitur); pada eksperimen awal cara ini kalah dari model citra saja, dan penulis menduga ruang fitur teks dan citra tidak bisa diselaraskan tanpa merusak daya pembedanya.

## 2.7 Metrik Evaluasi

- *Overall accuracy* (OA);
- F1 seimbang antarkelas (*class-balanced* F1, yaitu macro-F1) dan F1 per kelas untuk Tobacco3482;
- **Oracle**: akurasi jika selalu dipilih prediksi yang benar dari salah satu model unimodal, sebagai batas atas teoretis fusi;
- Waktu proses (latensi per dokumen di CPU dan GPU).

## 2.8 Hasil Keseluruhan

Tabel 2 dan 3 menyalin hasil paper. Pada kedua dataset pola hasilnya sama: teks paling lemah, citra lebih kuat, fusi terbaik. Fusi menaikkan OA Tobacco3482 sebesar 3,3 poin di atas model citra (dari batas atas oracle 7,6 poin), dan RVL-CDIP sebesar 1,5 poin. Pada F1 per kelas, fusi hampir selalu menyamai atau melebihi unimodal terbaik; penurunan kecil hanya pada *advertisement* (0,93 vs. 0,94). Kelas yang paling diuntungkan teks adalah *resume* (teks 0,97 vs. citra 0,80).

**Tabel 2 Hasil Audebert et al. pada Tobacco3482 (Tabel 3 paper): OA (%), macro-F1, dan F1 per kelas**

| **Model** | **OA** | **F1** | Adv | Email | Form | Letter | Memo | News | Note | Report | Res | Sci |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| CNNs (Harley) | 79,9 | – | – | | | | | | | | | |
| Teks | 73,8 | 0,71 | 0,60 | 0,96 | 0,76 | 0,71 | 0,79 | 0,67 | 0,62 | 0,43 | 0,97 | 0,57 |
| Citra | 84,5 | 0,82 | 0,94 | 0,96 | 0,85 | 0,83 | 0,90 | 0,89 | 0,83 | 0,61 | 0,80 | 0,62 |
| **Fusi** | **87,8** | **0,86** | 0,93 | 0,98 | 0,88 | 0,86 | 0,90 | 0,90 | 0,85 | 0,71 | 0,96 | 0,68 |
| Oracle | 92,1 | 0,91 | 0,94 | 0,99 | 0,94 | 0,92 | 0,93 | 0,93 | 0,89 | 0,81 | 0,97 | 0,79 |

**Tabel 3 Hasil Audebert et al. pada RVL-CDIP (Tabel 2 paper): OA (%)**

| **Citra** | **Teks** | **Fusi** | CNNs (Harley) | VGG-16 (Afzal) | AlexNet+SPP (Tensmeyer) |
|---|---|---|---|---|---|
| 89,1 | 74,6 | **90,6** | 89,8 | 90,97 | 90,94 |

Eksperimen pendahuluan pada Tobacco3482 (Tabel 1 paper): MLP dokumen 70,8 % / F1 0,69, CNN 1D 73,9 % / 0,71; MobileNetV2 84,5 % / 0,82, dengan augmentasi 83,9 % / 0,82.

**Waktu proses.** Di CPU Intel i7-8550U, Tesseract butuh ≈910 ms per halaman, inferensi model fusi ≈360 ms (130 ms teks, 230 ms citra), total ≈1,3 detik. Di GPU Titan X model fusi berjalan 110 ms. Sebagai pembanding, Xception butuh 630 ms dan LSTM setara butuh beberapa detik. Artinya, hambatan utama ada di OCR, bukan di jaringan.

## 2.9 Future Work

- Uji pada data dunia nyata (foto ponsel, rotasi, pencahayaan beragam); augmentasi terutama rotasi menjadi wajib di sana.
- Praproses tata letak/segmentasi halaman (mis. dhSegment) untuk menormalkan orientasi dan memotong dokumen sebelum klasifikasi.
- Koreksi ejaan parsial pasca-OCR (SymSpell) yang dikombinasikan dengan NER SpaCy agar nama diri, singkatan, dan kode tidak ikut "dikoreksi".
- Embedding yang khusus domain, berbasis karakter, atau tahan derau OCR.
- Mengganti ekstraktor fitur (CNN lain, model NLP subkata yang dapat di-*fine-tune*), karena arsitekturnya modular.

## 2.10 Kontribusi Utama

(a) baseline multimodal yang pragmatis dari komponen siap pakai (MobileNetV2 + FastText) yang dapat dilatih *end-to-end*; (b) bukti bahwa teks OCR berderau tetap menambah akurasi pada dataset kecil maupun besar; (c) rilis dataset teks QS-OCR untuk Tobacco3482 dan RVL-CDIP; (d) analisis latensi yang menunjukkan sistem layak untuk aplikasi hampir *real-time* di CPU.

## 2.11 Detail Pelatihan dan Lingkungan

TensorFlow 1.12 (Keras), GPU NVIDIA Titan X. Semua model dioptimasi dengan SGD momentum 0,9, laju belajar 0,01, *batch* 40; teks 100 epoch, citra dan fusi 200 epoch. Hiperparameter disetel manual pada subset Tobacco3482 lalu dikunci untuk semua eksperimen.

## 2.12 Kelebihan

- Desain sederhana dan terukur: tiap komponen dipilih dengan eksperimen pendahuluan (MLP vs. CNN 1D, dengan/tanpa augmentasi, konkatenasi vs. penjumlahan).
- Melaporkan oracle, sehingga besar kenaikan fusi dapat dibaca relatif terhadap batas atasnya, bukan hanya relatif terhadap baseline.
- Melaporkan F1 per kelas untuk ketiga model, sehingga komplementaritas modalitas terlihat jelas (mis. *resume* sangat terbantu teks).
- Analisis derau OCR yang kuantitatif (persentase kata di luar kosakata) dan pengukuran latensi yang memasukkan OCR.
- Data teks dirilis terbuka sehingga hasilnya dapat direplikasi.

## 2.13 Catatan Kritis

- **Variansi tidak dilaporkan.** Tobacco3482 dirata-rata dari 3 kali percobaan tetapi tanpa simpangan baku, sehingga tidak terlihat apakah kenaikan 3,3 poin lebih besar dari variasi antar-*split*. Tidak ada uji signifikansi untuk klaim kenaikan "signifikan".
- **Protokol Tobacco3482 kurang rinci.** Disebut "k-fold dengan 800 dokumen latih", tetapi cara memilih 800 dokumen (acak/stratifikasi, berapa per kelas) dan ada tidaknya set validasi tidak dijelaskan.
- **Inkonsistensi kecil**: OA teks 73,9 % di Tabel 1 vs. 73,8 % di Tabel 3.
- **RVL-CDIP hanya OA**; F1 dan hasil per kelas tidak dilaporkan.
- **Fusi tunggal.** Hanya konkatenasi yang dilaporkan penuh; tidak ada perbandingan dengan *late fusion* (rata-rata probabilitas), padahal oracle menunjukkan masih ada celah 4,3 poin.
- **OCR tidak divariasikan.** Hanya Tesseract dengan satu konfigurasi; pengaruh mesin OCR terhadap hasil fusi tidak diuji. Ini celah yang diisi Fase 2 proyek kami.
- Fusi diklaim dilatih *end-to-end*, tetapi FastText tidak di-*fine-tune*, sehingga cabang teks hanya melatih CNN 1D di atas embedding beku.

# 3 Paper 2: Kashyap et al. (2026)

## 3.1 Latar Belakang dan Permasalahan

Volume dokumen digital terus naik dan klasifikasinya perlu diotomasi. Penulis mengidentifikasi tiga masalah: (a) pendekatan unimodal tidak tangguh: tampilan visual dokumen sekelas bisa berbeda dan dokumen beda kelas bisa mirip, sementara pendekatan teks rentan terhadap kata *out-of-vocabulary* (OOV) akibat OCR buruk dan mengabaikan struktur halaman; (b) model besar *vision-language* (LayoutLMv3, DocFormer, DocLLM) akurat tetapi berat sehingga sulit dipasang di perangkat *edge*, ponsel, atau IoMT; (c) fusi awal/menengah rentan terhadap propagasi galat antarmodal jika teks OCR berderau. Celah yang diangkat: literatur fokus memaksimalkan akurasi dengan arsitektur yang makin kompleks, dan jarang membahas *trade-off* akurasi–efisiensi–sumber daya. Penulis menawarkan dua kerangka terpisah agar praktisi bisa memilih sesuai kebutuhan: satu mengejar akurasi, satu mengejar efisiensi.

## 3.2 Dataset

**Tabel 4 Dataset Kashyap et al. (Tabel 2 paper)**

| Dataset | Jenis | Total | Latih | Val | Uji | Kelas |
|---|---|---|---|---|---|---|
| RVL-CDIP | sekunder | 399.743 | 319.754 | 39.995 | 39.995 | 16 |
| Tobacco3482 | sekunder | 3.482 | – | – | 3.482 | 10 |
| RealDoc-16 | primer | 160 | – | – | 160 | 16 |

Semua model dilatih *hanya* pada RVL-CDIP. Tobacco3482 dipakai *seluruhnya* sebagai set uji (bukan protokol 800 latih yang lazim) untuk menguji generalisasi pada kondisi tidak seimbang dan sumber daya rendah. RealDoc-16 adalah dataset buatan penulis (10 dokumen per kelas, taksonomi kelas RVL-CDIP) untuk menguji generalisasi lintas domain; data ini hanya tersedia atas permintaan.

## 3.3 Modalitas

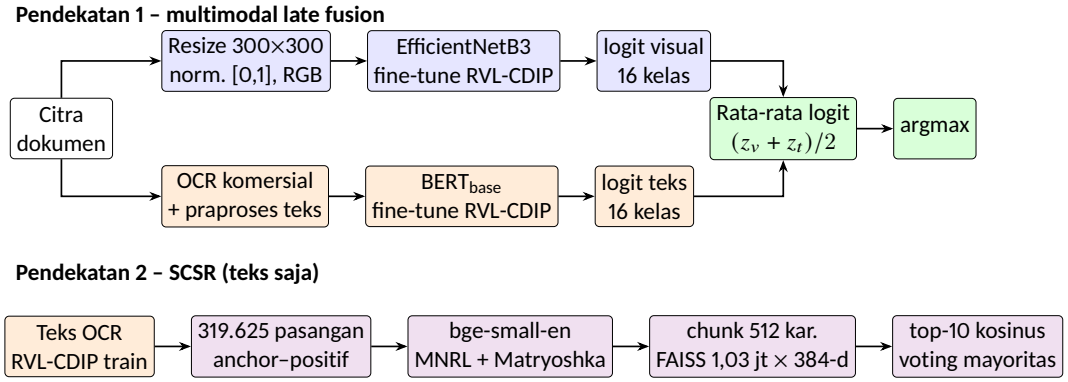
Sama dengan Paper 1: **citra** halaman dan **teks** hasil OCR dari citra yang sama. Pendekatan 1 memakai keduanya; pendekatan 2 (SCSR) hanya memakai teks. Tata letak juga tidak dipakai secara eksplisit.

## 3.4 Pipeline Keseluruhan

Gambar 2 menunjukkan dua pipeline yang berdiri sendiri.

- **Pendekatan 1 – multimodal late fusion.** Dua aliran dilatih terpisah: EfficientNetB3 untuk citra dan $\text{BERT}_{\text{base}}$ untuk teks OCR, keduanya di-*fine-tune* pada RVL-CDIP. Logit kedua aliran dirata-rata, lalu argmax.
- **Pendekatan 2 – SCSR** (*supervised contrastive semantic retrieval*). Model embedding bge-small-en di-*fine-tune* secara kontrastif terawasi dengan pasangan anchor–positif sekelas. Teks latih dipotong menjadi *chunk*, di-embed, dan disimpan di indeks FAISS beserta labelnya. Dokumen uji di-embed, 10

*chunk* paling mirip diambil, dan labelnya ditentukan oleh voting mayoritas (pada dasarnya $k$-NN dengan $k = 10$ di ruang embedding hasil pelatihan kontrastif).




**Gambar 2 Dua pipeline Kashyap et al. (digambar ulang dari Gambar 1 dan 3 paper)**

## 3.5 Model per Unimodal

**Citra – EfficientNetB3.** Input $300 \times 300$, piksel dinormalkan ke $[0, 1]$, grayscale diubah ke RGB. Keluaran 1536-d → Dropout → Dense 16 kelas. Pelatihan: 319.754 citra RVL-CDIP, 10 epoch, *batch* 16, Adam lr $10^{-3}$, *categorical cross-entropy*; ≈22,5 jam.

**Teks – BERT$_{base}$.** OCR memakai *mesin OCR komersial* yang tidak disebut namanya. Praproses teks: huruf kecil, tokenisasi, penyatuan spasi, serta penghapusan angka, *stopword*, karakter khusus, dan tanda baca. Tokenisasi WordPiece diklaim mengatasi OOV. Pelatihan: 10 epoch, *batch* 16, Adam lr $5 \times 10^{-5}$ (adaptif), dropout 0,3; ≈41 jam.

**Teks – SCSR (bge-small-en).** Model embedding 384-d (33,3 juta parameter), dilatih 4 epoch, *batch* 16 dengan akumulasi gradien 16, AdamW lr $2 \times 10^{-5}$, *cosine schedule*, *warmup* 10 %. Loss: *Multiple Negatives Ranking Loss* (MNRL) dibungkus *Matryoshka loss*. Teks dipotong per 512 karakter dengan *overlap* 50 karakter, menghasilkan indeks FAISS berisi 1.030.531 vektor.

## 3.6 Metode Fusi

**Late fusion (decision-level)** berupa *unweighted average ensembling*: $\hat{y} = \arg\max_c \frac{1}{2}(z_v + z_t)_c$, dengan $z_v$ dan $z_t$ logit aliran citra dan teks sebelum softmax. Tidak ada parameter fusi yang dilatih, dan bobot kedua modalitas sama. Penulis memilih late fusion agar ekstraksi fitur terpisah dari fusi, modular, dan galat satu modalitas tidak merambat ke modalitas lain. SCSR tidak memakai fusi (unimodal teks).

## 3.7 Metrik Evaluasi

- RVL-CDIP dan RealDoc-16: akurasi serta presisi, recall, dan F1 *macro-average*;
- Tobacco3482 (tidak seimbang): akurasi serta presisi, recall, dan F1 *weighted-average*;
- akurasi per kelas (Tobacco3482, RealDoc-16);
- efisiensi: jumlah parameter, total waktu inferensi, latensi per dokumen, *throughput*;
- analisis kualitatif: UMAP ruang fitur, Grad-CAM (citra), *integrated gradients* (token teks), dan matriks konfusi (lampiran).

## 3.8 Hasil Keseluruhan

Tabel 5 menyalin Tabel 4 paper. Pada pendekatan 1, kedua unimodal hampir setara di RVL-CDIP (teks 89,19 vs. citra 89,13), dan late fusion menaikkan akurasi sekitar 3,9 poin ke 93,06 %. Di Tobacco3482, teks (90,28) sedikit di atas citra (89,05), dan fusi mencapai 92,00 %. SCSR lebih rendah (80,76 % dan 87,89 %) tetapi dianggap kompetitif untuk ukurannya. UMAP menunjukkan komplementaritas: citra memisahkan kelas yang khas secara visual (*handwritten*, *advertisement*), teks memisahkan kelas yang kaya isi (*memo*, *scientific publication*).

**Tabel 5 Hasil Kashyap et al. dibanding studi multimodal sebelumnya (Tabel 4 paper), dalam %. T = teks, V = citra, T+V = fusi. F1/Rec/Prec: macro untuk RVL-CDIP, weighted untuk Tobacco3482.**

| Studi | Mod. | RVL-CDIP | | | | Tobacco3482 | | | |
|---|---|---|---|---|---|---|---|---|---|
| | | Acc | F1 | Rec | Prec | Acc | F1 | Rec | Prec |
| Audebert (2019) | T | 74,6 | – | – | – | 73,8 | – | – | – |
| | V | 89,1 | – | – | – | 84,5 | – | – | – |
| | T+V | 90,6 | – | – | – | 87,8 | – | – | – |
| Zingaro (2021) | T | – | – | – | – | 67,8 | – | – | – |
| | V | – | – | – | – | 88,0 | – | – | – |
| | T+V | 92,7 | – | – | – | 90,5 | – | – | – |
| Dauphinee/Tyler (2019) | T | 82,23 | – | – | – | – | – | – | – |
| | V | 90,24 | – | – | – | – | – | – | – |
| | T+V | 93,03 | – | – | – | – | – | – | – |
| Kashyap: late fusion | T (BERT) | 89,19 | 89,57 | 89,65 | 90,19 | 90,28 | 92,62 | 90,28 | 97,28 |
| | V (EffNetB3) | 89,13 | 89,12 | 89,15 | 89,23 | 89,05 | 91,58 | 89,05 | 96,15 |
| | **T+V** | **93,06** | 93,06 | 93,17 | 93,06 | **92,00** | 94,02 | 92,00 | 98,23 |
| Kashyap: SCSR | T | 80,76 | 84,00 | 81,00 | 84,00 | 87,89 | 90,00 | 88,00 | 95,00 |

**Tabel 6 Akurasi per kelas pada Tobacco3482 (%), Tabel 5 paper (hanya 8 dari 10 kelas dilaporkan)**

| Model | Mod. | Letter | Form | Email | Adv | Sci-pub | News | Resume | Memo |
|---|---|---|---|---|---|---|---|---|---|
| Kashyap: late fusion | T | 96,25 | 96,67 | 99,00 | 96,30 | 89,09 | 96,72 | 100,0 | 98,55 |
| | V | 98,21 | 96,29 | 99,50 | 97,69 | 80,37 | 89,19 | 98,32 | 97,87 |
| | T+V | 98,41 | 97,73 | 99,50 | 98,17 | 88,39 | 96,79 | 100,0 | 99,68 |
| Kashyap: SCSR | T | 94,90 | 87,90 | 98,80 | 79,60 | 73,50 | 87,20 | 100,0 | 91,00 |

**Efisiensi (Tabel 6–7 paper).** SCSR (33,3 juta parameter) lebih akurat di Tobacco3482 daripada AlexNet-ELM (62 juta, 83,24 %) dan cabang teks Zingaro (1,8 juta, 67,8 %). Latensi per dokumen: late fusion 0,184 s (5,42 dok/s), SCSR 0,157 s (6,36 dok/s); total waktu inferensi 555,27 s vs. 547,19 s.

**RealDoc-16 (Tabel 8 paper).** Hanya enam kelas yang dilaporkan, akurasi (fusi / SCSR): *letter* 100/90, *news article* 100/80, *memo* 72,73/63,60, *form* 70/70, *resume* 70/80, *scientific publication* 70/90. Akurasi keseluruhan RealDoc-16 tidak dilaporkan.

### 3.9 Future Work

- Kerangka representasi yang lebih tangguh untuk dokumen **multibahasa** pada kondisi sumber daya rendah dan degradasi OCR berat.
- *Parameter-efficient fine-tuning* (PEFT) untuk menekan memori pelatihan.
- Mengganti rata-rata tak berbobot dengan **pembobotan modalitas adaptif** atau fusi berbasis keyakinan (*confidence-aware*), termasuk memakai model fondasi multimodal.
- Menambahkan embedding citra ringan ke basis data retrieval SCSR untuk mengatasi kemiripan antarkelas pada RVL-CDIP.

### 3.10 Kontribusi Utama

(a) kerangka late fusion dua aliran (EfficientNetB3 + BERT) yang modular; (b) SCSR, yang menggabungkan pembelajaran kontrastif terawasi dengan retrieval semantik sebagai pengklasifikasi tanpa lapis klasifikasi padat; (c) dataset primer RealDoc-16 untuk uji lintas domain; (d) analisis interpretabilitas (Grad-CAM, integrated gradients) yang memperlihatkan koreksi galat ganda oleh fusi.

### 3.11 Detail Pelatihan dan Lingkungan

Ubuntu 22.04, Intel Xeon E5-2620 v3 (12 inti), RAM 125,7 GiB, NVIDIA RTX A4000 16 GB, CUDA 10.1, TensorFlow/Keras, Python 3.12.4. Hiperparameter tiap model sudah dirinci pada subbagian model di atas.

### 3.12 Kelebihan

- Terbit di jurnal bereputasi tahun 2026 dan *open access*; memenuhi syarat referensi utama proyek.
- Membahas *trade-off* akurasi–efisiensi secara eksplisit dan menawarkan dua titik operasi.
- Evaluasi pada tiga dataset termasuk data primer di luar distribusi pelatihan.
- Melaporkan presisi, recall, F1, dan hasil per kelas untuk setiap unimodal, serta analisis kualitatif (UMAP, Grad-CAM, integrated gradients, matriks konfusi).

- Late fusion sederhana dan mudah direplikasi; unimodal dapat dilatih dan diganti secara terpisah.

### 3.13 Catatan Kritis

Poin-poin berikut kami temukan saat memeriksa angka dan protokol paper.

- **OCR tidak disebutkan.** Hanya disebut "mesin OCR komersial". Karena kedua pendekatan bergantung pada teks, tidak disebutkannya nama OCR menghalangi replikasi dan membuat perbandingan dengan Audebert (Tesseract) tidak setara.
- **Pemetaan kelas Tobacco3482 tidak dijelaskan.** Model dilatih untuk 16 kelas RVL-CDIP, padahal Tobacco3482 punya kelas *note* dan *report* yang tidak ada di RVL-CDIP (13,4 % data). Tanpa pemetaan, akurasi maksimal hanya ≈86,6 %, tetapi dilaporkan 92 %. Tabel per kelas juga hanya memuat 8 kelas.
- **Potensi kebocoran data.** Tobacco3482 dan RVL-CDIP sama-sama diambil dari arsip Truth Tobacco Industry Documents. Paper tidak menyebut apakah dokumen Tobacco3482 yang juga ada di set latih RVL-CDIP sudah dibuang.
- **Perbandingan tidak setara protokol.** Audebert melatih pada 800 dokumen Tobacco3482; Kashyap melatih pada ∼320 ribu dokumen RVL-CDIP lalu menguji pada seluruh Tobacco3482. Klaim "mengungguli studi sebelumnya" di Tobacco3482 perlu dibaca dengan catatan ini.
- **Angka metrik yang tidak konsisten.** (i) Macro-F1 SCSR di RVL-CDIP 84,00 padahal macro-precision 84,00 dan macro-recall 81,00. Karena F1 per kelas ≤ rata-rata P dan R per kelas, macro-F1 seharusnya ≤ 82,5. (ii) Pada set uji yang seimbang, macro-recall sama dengan akurasi, tetapi dilaporkan 89,65 vs. 89,19 (teks). (iii) Weighted-precision Tobacco3482 (96–98 %) jauh di atas recall (89–92 %). Ini wajar bila banyak prediksi jatuh ke kelas RVL-CDIP yang tidak ada di Tobacco3482 (dukungan nol sehingga tidak ikut dibobot), sehingga presisi tampak tinggi secara semu.
- **RealDoc-16 tidak konsisten.** Tabel 2 menyebut 160 dokumen, teks menyebut 120. Dengan 10 dokumen per kelas, akurasi *memo* 72,73 % (= 8/11) dan 63,60 % (= 7/11) tidak mungkin. Hanya 6 dari 16 kelas yang dilaporkan dan tidak ada akurasi total. Jumlah data latih juga berbeda: 319.625 (Algoritma) vs. 319.754 (Tabel 2).
- **Angka Audebert dikutip keliru.** Tabel 5 paper mencantumkan akurasi per kelas Audebert (mis. *letter* fusi 93,2), sedangkan Audebert hanya melaporkan F1 per kelas (*letter* fusi 0,86) dan nilai-nilai tersebut tidak ditemukan di paper aslinya. Kolom citra Audebert juga ditulis "–", padahal F1 per kelas citra dilaporkan.
- **Klaim efisiensi SCSR lemah.** SCSR disebut "tidak bergantung pada DL", padahal bge-small-en adalah transformer 33 juta parameter. Latensinya hanya ∼15 % lebih cepat (0,157 vs. 0,184 s), latensi OCR tidak dihitung, dan indeks FAISS 1,03 juta × 384 float32 berukuran ≈1,6 GB, yang berat untuk perangkat *edge*. Selain itu, 555,27 s / 0,184 s ≈ 3.018 dokumen, tidak cocok dengan 547,19 s / 0,157 s ≈ 3.485 dokumen jika keduanya diuji pada set yang sama.

- **Fusi tidak diablasi.** Hanya rata-rata tak berbobot yang diuji; tidak ada pembanding fusi berbobot, *product rule*, atau fusi fitur, dan tidak ada oracle. Teks menyebut rata-rata logit, sedangkan Algoritma 3 menyebut probabilitas dan prediksi.
- **Tanpa variansi dan uji statistik**: hasil satu kali jalan tanpa seed, selang kepercayaan, atau uji signifikansi.
- Hal kecil: tabel menulis tahun "2025" untuk paper 2026; CUDA 10.1 tidak lazim dipasangkan dengan Python 3.12 dan TensorFlow versi baru; nama "Tyler et al." dan "Dauphinee et al." dipakai bergantian untuk rujukan yang sama.

## 4 Perbandingan Kedua Paper

**Tabel 7 Perbandingan ringkas Audebert et al. (2020) dan Kashyap et al. (2026)**

| Aspek | Audebert et al. (2020) | Kashyap et al. (2026) |
|---|---|---|
| Fokus | Baseline multimodal ringan | Akurasi (fusi) dan efisiensi (SCSR) |
| Dataset | Tobacco3482 (800 latih), RVL-CDIP | Latih RVL-CDIP; uji RVL-CDIP, Tobacco3482 penuh, RealDoc-16 |
| OCR | Tesseract 4.0, dirilis (QS-OCR) | OCR komersial, tidak disebut |
| Model citra | MobileNetV2, 384×384 | EfficientNetB3, 300×300 |
| Model teks | FastText (beku) + CNN 1D | $\text{BERT}_{\text{base}}$ (fine-tune); bge-small-en (SCSR) |
| Fusi | Fitur (konkatenasi 128+128) + MLP, end-to-end | Keputusan (rata-rata logit tak berbobot) |
| Metrik | OA, macro-F1, F1/kelas, oracle, latensi | Acc, P/R/F1 macro/weighted, acc/kelas, parameter, latensi |
| Unimodal terkuat | Citra jauh di atas teks | Teks ≈ citra (teks sedikit unggul) |
| Fusi Tobacco3482 | 87,8 % (+3,3 dari citra) | 92,00 % (+1,72 dari teks) |
| Fusi RVL-CDIP | 90,6 % (+1,5 dari citra) | 93,06 % (+3,87 dari teks) |
| Reproduktibilitas | Tinggi: data teks terbuka, hiperparameter lengkap | Sedang: OCR anonim, RealDoc-16 tertutup, angka tidak konsisten |

Ada tiga perbedaan penting. Pertama, **kualitas cabang teks menentukan nilai fusi**. Pada Audebert, teks tertinggal 10–15 poin dari citra, sedangkan pada Kashyap teks setara atau sedikit lebih baik dari citra. Kenaikan ini datang dari dua hal yang tidak dipisahkan di Kashyap: OCR yang berbeda dan model teks yang lebih kuat (BERT vs. FastText + CNN). Kedua, **titik fusi**: Audebert menggabungkan fitur dan melatih fusi, sedangkan Kashyap merata-rata keputusan tanpa pelatihan. Ketiga, **protokol Tobacco3482** berbeda (latih 800 vs. *transfer* dari RVL-CDIP), sehingga angka Tobacco3482 keduanya tidak bisa dibandingkan langsung.

## 5 Relevansi untuk Proyek

Fase 2 proyek kami menjadikan **mesin OCR** dan **model embedding** sebagai variabel. Dari review ini:

- Kedua paper tidak memisahkan pengaruh OCR dari pengaruh model teks. Audebert memakai satu OCR, Kashyap memakai OCR anonim sekaligus mengganti model teks. Eksperimen faktorial OCR $\times$ embedding pada proyek kami mengisi celah ini secara langsung.
- Late fusion Kashyap (rata-rata logit) murah dan dapat ditambahkan sebagai pembanding fusi konkatenasi Audebert, bersama oracle sebagai batas atas.
- Pelajaran metodologis yang kami terapkan: laporkan rerata $\pm$ simpangan baku lintas seed, gunakan macro-F1 untuk data tidak seimbang, nyatakan protokol split dan mesin OCR secara eksplisit, serta jangan membandingkan angka antar-protokol yang berbeda.

## 6 Kesimpulan

Audebert et al. memberi baseline multimodal yang sederhana, transparan, dan dapat direplikasi. Kekuatannya adalah analisis derau OCR, oracle, dan F1 per kelas; kelemahannya adalah satu konfigurasi OCR dan tidak ada variansi. Kashyap et al. memperbarui komponen (EfficientNetB3, BERT) dan menunjukkan bahwa late fusion sederhana sudah memberi akurasi tinggi, serta menawarkan alternatif retrieval yang ringan. Namun paper ini memiliki sejumlah masalah pelaporan: OCR anonim, pemetaan kelas Tobacco3482 yang tidak jelas, beberapa angka metrik yang tidak konsisten secara matematis, dan kutipan hasil Audebert yang tidak cocok dengan sumbernya. Angka dari paper kedua sebaiknya dipakai sebagai acuan arah, bukan target yang harus dicapai persis.

## Daftar Referensi


Audebert, N., Herold, C., Slimani, K. dan Vidal, C., 2020. Multimodal Deep Networks for Text and Image-Based Document Classification. Dalam: *Machine Learning and Knowledge Discovery in Databases: ECML PKDD 2019 Workshops*. Ed. by P. Cellier dan K. Driessens. Vol. 1167. Communications in Computer and Information Science. Cham: Springer, pp.427-443. Tersedia di: <https://doi.org/10.1007/978-3-030-43823-4_35>.

Harley, A.W., Ufkes, A. dan Derpanis, K.G., 2015. Evaluation of Deep Convolutional Nets for Document Image Classification and Retrieval. Dalam: *2015 13th International Conference on Document Analysis and Recognition (ICDAR)*, pp.991-995. Tersedia di: <https://doi.org/10.1109/ICDAR.2015.7333910>.

Kashyap, A., Mittal, M. dan Singh, S., 2026. Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification. *International Journal of Intelligent Systems*, 2026, p.4241437. Tersedia di: <https://doi.org/10.1155/int/4241437>.

Kumar, J., Ye, P. dan Doermann, D., 2014. Structural Similarity for Document Image Classification and Retrieval. *Pattern Recognition Letters*, 43, pp.119-126. Tersedia di: <https://doi.org/10.1016/j.patrec.2013.10.030>.