ANALISIS & PEMROSESAN DATA MULTIMODAL

Review Paper: Klasifikasi Dokumen Multimodal Teks OCR dan Citra

Audebert (2020), Kanchi (2022), dan Kashyap (2026)

Disusun oleh:

Yulian Anggreaif Rudamaga	:	256150100011001
Zalzabila Rani	:	256150100011008
Ramadhani Al-Qadri	:	256150100011010

Dosen Pengampu:
Dr. Eng. Fitra Abdurrachman Bachtiar, S.T., M.Eng.

PROGRAM STUDI MAGISTER ILMU KOMPUTER
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA

1 Pendahuluan

Laporan ini mereview tiga paper tentang klasifikasi citra dokumen yang memadukan dua modalitas: citra halaman dan teks hasil OCR. Paper pertama adalah dasar replikasi proyek pada Fase 1, paper kedua adalah referensi utama Fase 2, dan paper ketiga adalah pembanding untuk skenario data sedikit (Tobacco3482 tanpa RVL-CDIP). Identitas ketiganya ada pada Tabel 1.

Tabel 1 Identitas paper yang direview

	Paper 1	**Paper 2**	**Paper 3**
Judul	Multimodal Deep Networks for Text and Image-Based Document Classification	Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification	EmmDocClassifier: Efficient Multimodal Document Image Classifier for Scarce Data
Penulis	Audebert, Herold, Slimani, Vidal (Quicksign, Prancis)	Kashyap, Mittal, Singh (Central University of Punjab, India)	Kanchi, Pagani, Mokayed, Liwicki, Stricker, Afzal (TU Kaiserslautern, DFKI, Luleå)
Venue	ECML PKDD 2019 Workshops, CCIS 1167, Springer, hlm. 427–443	International Journal of Intelligent Systems (Wiley), artikel 4241437, open access	Applied Sciences (MDPI) 12(3), artikel 1457, open access
Tahun	2020 (workshop 2019)	2026 (diterima 13 Juli 2026)	2022 (terbit 29 Januari 2022)
DOI	10.1007/978-3-030-43823-4_35	10.1155/int/4241437	10.3390/app12031457
Sitasi	Audebert et al. (2020)	Kashyap, Mittal dan Singh (2026)	Kanchi et al. (2022)

Setiap paper dibahas dengan sembilan poin wajib: (1) latar belakang dan permasalahan, (2) dataset, (3) modalitas, (4) pipeline keseluruhan, (5) model per unimodal, (6) metode fusi, (7) metrik evaluasi, (8) hasil keseluruhan beserta hasil per unimodal, dan (9) *future work*. Kami menambahkan empat poin yang menurut kami perlu untuk review yang utuh: (10) kontribusi utama, (11) detail pelatihan dan lingkungan eksperimen, (12) kelebihan, dan (13) catatan kritis (kelemahan, inkonsistensi, ancaman validitas). Bagian 5 membandingkan ketiga paper, dan Bagian 6 menjelaskan apa yang kami ambil untuk proyek.

2 Paper 1: Audebert et al. (2020)

2.1 Latar Belakang dan Permasalahan

Banyak proses administrasi (pembukaan rekening, pajak, verifikasi identitas) kini menerima dokumen yang dipindai atau difoto pengguna. Dokumen ini tidak punya lapisan teks, sehingga pengecekan dan pengarsipannya masih dikerjakan operator manusia. Langkah pertama yang perlu diotomasi adalah mengenali jenis dokumen.

Masalah yang diangkat: klasifikasi berbasis tampilan visual saja cukup untuk kelas yang kasar (paspor vs. data bank), tetapi tidak cukup untuk kelas yang halus. Dua formulir pajak bisa berbagi tata letak dan logo yang sama, sedangkan isinya berbeda. Informasi pembedanya ada di teks, padahal teks itu tidak tersedia dalam

bentuk digital dan harus diambil lewat OCR yang hasilnya berderau. Pertanyaan penelitiannya: apakah teks OCR yang berderau tetap bisa menaikkan akurasi klasifikasi citra dokumen jika digabung dengan fitur visual, dengan biaya komputasi yang tetap rendah?

2.2 Dataset

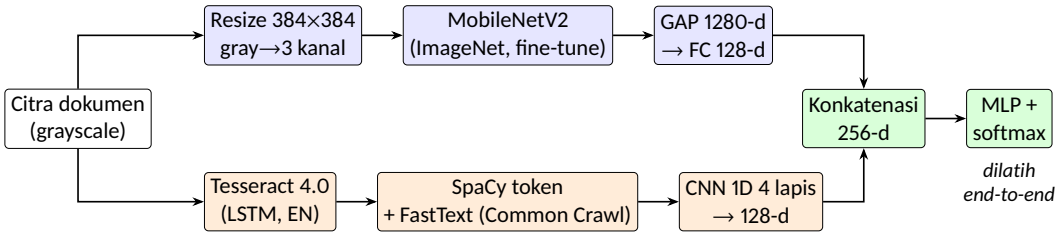
- **Tobacco3482** (Kumar, Ye dan Doermann, 2014): 3.482 dokumen hitam-putih, 10 kelas (*advertisement*, *email*, *form*, *letter*, *memo*, *news*, *note*, *report*, *resume*, *scientific*). Protokol: 800 dokumen untuk latih, sisanya untuk uji; hasil dirata-rata dari 3 kali percobaan.
- **RVL-CDIP** (Harley, Ufkes dan Derpanis, 2015): 400.000 dokumen grayscale, 16 kelas, 25.000 per kelas. Pembagian standar 320.000 latih, 40.000 validasi, 40.000 uji.
- **QS-OCR**: teks hasil Tesseract untuk kedua dataset di atas, dirilis penulis di GitHub `Quicksign/ocrized-text-dataset`. Dataset inilah yang kami pakai sebagai modalitas teks (QS-OCR-Small untuk Tobacco3482).

2.3 Modalitas

Dua modalitas yang keduanya berasal dari satu citra halaman: (a) **citra** grayscale halaman dokumen, dan (b) **teks** yang diekstraksi dari citra yang sama dengan Tesseract OCR. Teks bukan modalitas yang independen, melainkan turunan dari citra, sehingga kualitasnya dibatasi oleh kualitas OCR. Tata letak (posisi kata) tidak dipakai.

2.4 Pipeline Keseluruhan

Gambar 1 merangkum pipeline. Citra diproses oleh MobileNetV2, teks OCR diubah menjadi barisan vektor kata FastText lalu diproses CNN 1D. Kedua vektor fitur 128 dimensi digabung (konkatenasi) dan diklasifikasi oleh MLP. Seluruh jaringan dapat dilatih *end-to-end*.



Gambar 1 Pipeline Audebert et al. (digambar ulang dari Gambar 1 dan Bagian 3–4 paper)

2.5 Model per Unimodal

Citra. MobileNetV2 dipilih karena ringan (sekitar setara VGG-16 dalam akurasi, tetapi jauh lebih cepat). Citra di-*resize* ke 384×384 (rasio aspek dikorbankan), kanal

grayscale diduplikasi tiga kali agar bobot ImageNet bisa dipakai, lalu jaringan di-*fine-tune*. Augmentasi (artefak JPEG, saturasi, kontras) tidak membantu, sehingga tidak dipakai.

Teks. Tesseract 4.0 (mesin LSTM, bahasa Inggris, segmentasi halaman penuh). Penulis menunjukkan derau OCR: rata-rata 136 kata ($\geq$4 huruf) per dokumen, hanya 118 ada di kosakata GloVe dan 114 di kamus Enchant; sekitar 26 % korpus tidak ada di kamus bahasa Inggris. Karena itu dipilih embedding berbasis subkata, **FastText** (Common Crawl), yang tetap memberi vektor masuk akal untuk kata salah eja. Tokenisasi memakai SpaCy. Dua klasifikator dibandingkan:

- MLP atas embedding dokumen (rata-rata berbobot ala Arora + PCA): 2048 neuron per lapis, ReLU, Dropout, BatchNorm, lapis akhir 128-d;
- **CNN 1D** atas barisan kata (dipilih): 4 lapis, kernel 12, 512 kanal, ReLU, max-pooling stride 2, lalu max-pooling sepanjang waktu, Dropout, dan FC. Input dipotong/di-*padding* ke 500 kata.

2.6 Metode Fusi

Fusi tingkat fitur (*intermediate/feature-level*). Vektor teks 128-d (lapis sebelum softmax CNN 1D) dan vektor citra 1280-d hasil *global average pooling* yang diproyeksikan ke 128-d oleh FC, lalu **dikonkatenasi** dan diumpankan ke MLP. Penulis juga mencoba *adaptive averaging* (penjumlahan fitur); pada eksperimen awal cara ini kalah dari model citra saja, dan penulis menduga ruang fitur teks dan citra tidak bisa diselaraskan tanpa merusak daya pembedanya.

2.7 Metrik Evaluasi

- *Overall accuracy* (OA);
- F1 seimbang antarkelas (*class-balanced* F1, yaitu macro-F1) dan F1 per kelas untuk Tobacco3482;
- **Oracle**: akurasi jika selalu dipilih prediksi yang benar dari salah satu model unimodal, sebagai batas atas teoretis fusi;
- Waktu proses (latensi per dokumen di CPU dan GPU).

2.8 Hasil Keseluruhan

Tabel 2 dan 3 menyalin hasil paper. Pada kedua dataset pola hasilnya sama: teks paling lemah, citra lebih kuat, fusi terbaik. Fusi menaikkan OA Tobacco3482 sebesar 3,3 poin di atas model citra (dari batas atas oracle 7,6 poin), dan RVL-CDIP sebesar 1,5 poin. Pada F1 per kelas, fusi hampir selalu menyamai atau melebihi unimodal terbaik; penurunan kecil hanya pada *advertisement* (0,93 vs. 0,94). Kelas yang paling diuntungkan teks adalah *resume* (teks 0,97 vs. citra 0,80).

Tabel 2 Hasil Audebert et al. pada Tobacco3482 (Tabel 3 paper): OA (%), macro-F1, dan F1 per kelas

Model	**OA**	**F1**	Adv	Email	Form	Letter	Memo	News	Note	Report	Res	Sci
CNNs (Harley)	79,9	–	–									
Teks	73,8	0,71	0,60	0,96	0,76	0,71	0,79	0,67	0,62	0,43	0,97	0,57
Citra	84,5	0,82	0,94	0,96	0,85	0,83	0,90	0,89	0,83	0,61	0,80	0,62
Fusi	**87,8**	**0,86**	0,93	0,98	0,88	0,86	0,90	0,90	0,85	0,71	0,96	0,68
Oracle	92,1	0,91	0,94	0,99	0,94	0,92	0,93	0,93	0,89	0,81	0,97	0,79

Tabel 3 Hasil Audebert et al. pada RVL-CDIP (Tabel 2 paper): OA (%)

Citra	**Teks**	**Fusi**	CNNs (Harley)	VGG-16 (Afzal)	AlexNet+SPP (Tensmeyer)
89,1	74,6	**90,6**	89,8	90,97	90,94

Eksperimen pendahuluan pada Tobacco3482 (Tabel 1 paper): MLP dokumen 70,8 % / F1 0,69, CNN 1D 73,9 % / 0,71; MobileNetV2 84,5 % / 0,82, dengan augmentasi 83,9 % / 0,82.

Waktu proses. Di CPU Intel i7-8550U, Tesseract butuh ≈910 ms per halaman, inferensi model fusi ≈360 ms (130 ms teks, 230 ms citra), total ≈1,3 detik. Di GPU Titan X model fusi berjalan 110 ms. Sebagai pembanding, Xception butuh 630 ms dan LSTM setara butuh beberapa detik. Artinya, hambatan utama ada di OCR, bukan di jaringan.

2.9 Future Work

- Uji pada data dunia nyata (foto ponsel, rotasi, pencahayaan beragam); augmentasi terutama rotasi menjadi wajib di sana.
- Praproses tata letak/segmentasi halaman (mis. dhSegment) untuk menormalkan orientasi dan memotong dokumen sebelum klasifikasi.
- Koreksi ejaan parsial pasca-OCR (SymSpell) yang dikombinasikan dengan NER SpaCy agar nama diri, singkatan, dan kode tidak ikut "dikoreksi".
- Embedding yang khusus domain, berbasis karakter, atau tahan derau OCR.
- Mengganti ekstraktor fitur (CNN lain, model NLP subkata yang dapat di-*fine-tune*), karena arsitekturnya modular.

2.10 Kontribusi Utama

(a) baseline multimodal yang pragmatis dari komponen siap pakai (MobileNetV2 + FastText) yang dapat dilatih *end-to-end*; (b) bukti bahwa teks OCR berderau tetap menambah akurasi pada dataset kecil maupun besar; (c) rilis dataset teks QS-OCR untuk Tobacco3482 dan RVL-CDIP; (d) analisis latensi yang menunjukkan sistem layak untuk aplikasi hampir *real-time* di CPU.

2.11 Detail Pelatihan dan Lingkungan

TensorFlow 1.12 (Keras), GPU NVIDIA Titan X. Semua model dioptimasi dengan SGD momentum 0,9, laju belajar 0,01, *batch* 40; teks 100 epoch, citra dan fusi 200 epoch. Hiperparameter disetel manual pada subset Tobacco3482 lalu dikunci untuk semua eksperimen.

2.12 Kelebihan

- Desain sederhana dan terukur: tiap komponen dipilih dengan eksperimen pendahuluan (MLP vs. CNN 1D, dengan/tanpa augmentasi, konkatenasi vs. penjumlahan).
- Melaporkan oracle, sehingga besar kenaikan fusi dapat dibaca relatif terhadap batas atasnya, bukan hanya relatif terhadap baseline.
- Melaporkan F1 per kelas untuk ketiga model, sehingga komplementaritas modalitas terlihat jelas (mis. *resume* sangat terbantu teks).
- Analisis derau OCR yang kuantitatif (persentase kata di luar kosakata) dan pengukuran latensi yang memasukkan OCR.
- Data teks dirilis terbuka sehingga hasilnya dapat direplikasi.

2.13 Catatan Kritis

- **Variansi tidak dilaporkan.** Tobacco3482 dirata-rata dari 3 kali percobaan tetapi tanpa simpangan baku, sehingga tidak terlihat apakah kenaikan 3,3 poin lebih besar dari variasi antar-*split*. Tidak ada uji signifikansi untuk klaim kenaikan "signifikan".
- **Protokol Tobacco3482 kurang rinci.** Disebut "k-fold dengan 800 dokumen latih", tetapi cara memilih 800 dokumen (acak/stratifikasi, berapa per kelas) dan ada tidaknya set validasi tidak dijelaskan.
- **Inkonsistensi kecil**: OA teks 73,9 % di Tabel 1 vs. 73,8 % di Tabel 3.
- **RVL-CDIP hanya OA**; F1 dan hasil per kelas tidak dilaporkan.
- **Fusi tunggal.** Hanya konkatenasi yang dilaporkan penuh; tidak ada perbandingan dengan *late fusion* (rata-rata probabilitas), padahal oracle menunjukkan masih ada celah 4,3 poin.
- **OCR tidak divariasikan.** Hanya Tesseract dengan satu konfigurasi; pengaruh mesin OCR terhadap hasil fusi tidak diuji. Ini celah yang diisi Fase 2 proyek kami.
- Fusi diklaim dilatih *end-to-end*, tetapi FastText tidak di-*fine-tune*, sehingga cabang teks hanya melatih CNN 1D di atas embedding beku.

3 Paper 2: Kashyap et al. (2026)

3.1 Latar Belakang dan Permasalahan

Volume dokumen digital terus naik dan klasifikasinya perlu diotomasi. Penulis mengidentifikasi tiga masalah: (a) pendekatan unimodal tidak tangguh: tampilan visual dokumen sekelas bisa berbeda dan dokumen beda kelas bisa mirip, sementara pendekatan teks rentan terhadap kata *out-of-vocabulary* (OOV) akibat OCR buruk dan mengabaikan struktur halaman; (b) model besar *vision-language* (LayoutLMv3, DocFormer, DocLLM) akurat tetapi berat sehingga sulit dipasang di perangkat *edge*, ponsel, atau IoMT; (c) fusi awal/menengah rentan terhadap propagasi galat antarmodal jika teks OCR berderau. Celah yang diangkat: literatur fokus memaksimalkan akurasi dengan arsitektur yang makin kompleks, dan jarang membahas *trade-off* akurasi–efisiensi–sumber daya. Penulis menawarkan dua kerangka terpisah agar praktisi bisa memilih sesuai kebutuhan: satu mengejar akurasi, satu mengejar efisiensi.

3.2 Dataset

Tabel 4 Dataset Kashyap et al. (Tabel 2 paper)

Dataset	Jenis	Total	Latih	Val	Uji	Kelas
RVL-CDIP	sekunder	399.743	319.754	39.995	39.995	16
Tobacco3482	sekunder	3.482	–	–	3.482	10
RealDoc-16	primer	160	–	–	160	16

Semua model dilatih *hanya* pada RVL-CDIP. Tobacco3482 dipakai *seluruhnya* sebagai set uji (bukan protokol 800 latih yang lazim) untuk menguji generalisasi pada kondisi tidak seimbang dan sumber daya rendah. RealDoc-16 adalah dataset buatan penulis (10 dokumen per kelas, taksonomi kelas RVL-CDIP) untuk menguji generalisasi lintas domain; data ini hanya tersedia atas permintaan.

3.3 Modalitas

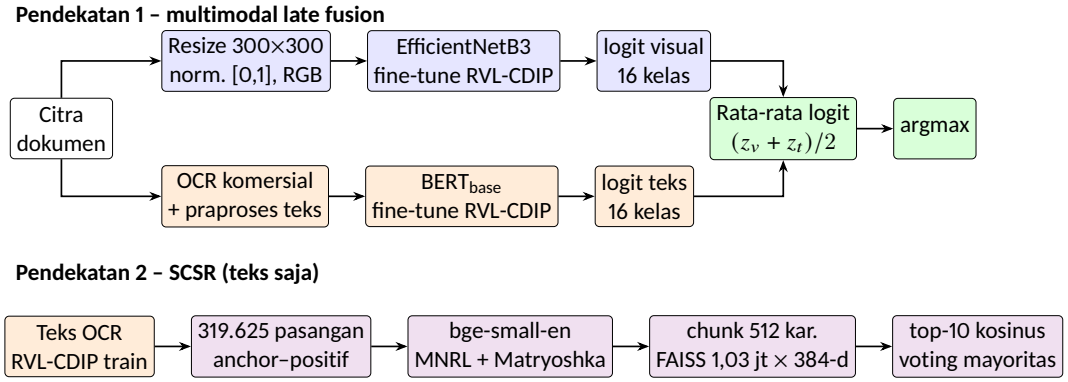
Sama dengan Paper 1: **citra** halaman dan **teks** hasil OCR dari citra yang sama. Pendekatan 1 memakai keduanya; pendekatan 2 (SCSR) hanya memakai teks. Tata letak juga tidak dipakai secara eksplisit.

3.4 Pipeline Keseluruhan

Gambar 2 menunjukkan dua pipeline yang berdiri sendiri.

- **Pendekatan 1 – multimodal late fusion.** Dua aliran dilatih terpisah: EfficientNetB3 untuk citra dan $\text{BERT}_{\text{base}}$ untuk teks OCR, keduanya di-*fine-tune* pada RVL-CDIP. Logit kedua aliran dirata-rata, lalu argmax.
- **Pendekatan 2 – SCSR** (*supervised contrastive semantic retrieval*). Model embedding bge-small-en di-*fine-tune* secara kontrastif terawasi dengan pasangan anchor–positif sekelas. Teks latih dipotong menjadi *chunk*, di-embed, dan disimpan di indeks FAISS beserta labelnya. Dokumen uji di-embed, 10

chunk paling mirip diambil, dan labelnya ditentukan oleh voting mayoritas (pada dasarnya k-NN dengan $k = 10$ di ruang embedding hasil pelatihan kontrastif).



Gambar 2 Dua pipeline Kashyap et al. (digambar ulang dari Gambar 1 dan 3 paper)

3.5 Model per Unimodal

Citra – EfficientNetB3. Input 300×300, piksel dinormalkan ke $[0, 1]$, grayscale diubah ke RGB. Keluaran 1536-d → Dropout → Dense 16 kelas. Pelatihan: 319.754 citra RVL-CDIP, 10 epoch, *batch* 16, Adam lr 10^{-3}, *categorical cross-entropy*; ≈22,5 jam.

Teks – BERT$_{base}$. OCR memakai *mesin OCR komersial* yang tidak disebut namanya. Praproses teks: huruf kecil, tokenisasi, penyatuan spasi, serta penghapusan angka, *stopword*, karakter khusus, dan tanda baca. Tokenisasi WordPiece diklaim mengatasi OOV. Pelatihan: 10 epoch, *batch* 16, Adam lr 5×10^{-5} (adaptif), dropout 0,3; ≈41 jam.

Teks – SCSR (bge-small-en). Model embedding 384-d (33,3 juta parameter), dilatih 4 epoch, *batch* 16 dengan akumulasi gradien 16, AdamW lr 2×10^{-5}, *cosine schedule*, *warmup* 10 %. Loss: *Multiple Negatives Ranking Loss* (MNRL) dibungkus *Matryoshka loss*. Teks dipotong per 512 karakter dengan *overlap* 50 karakter, menghasilkan indeks FAISS berisi 1.030.531 vektor.

3.6 Metode Fusi

Late fusion (decision-level) berupa *unweighted average ensembling*: $\hat{y} = \arg\max_c \frac{1}{2}(z_v + z_t)_c$, dengan z_v dan z_t logit aliran citra dan teks sebelum softmax. Tidak ada parameter fusi yang dilatih, dan bobot kedua modalitas sama. Penulis memilih late fusion agar ekstraksi fitur terpisah dari fusi, modular, dan galat satu modalitas tidak merambat ke modalitas lain. SCSR tidak memakai fusi (unimodal teks).

3.7 Metrik Evaluasi

- RVL-CDIP dan RealDoc-16: akurasi serta presisi, recall, dan F1 *macro-average*;
- Tobacco3482 (tidak seimbang): akurasi serta presisi, recall, dan F1 *weighted-average*;
- akurasi per kelas (Tobacco3482, RealDoc-16);
- efisiensi: jumlah parameter, total waktu inferensi, latensi per dokumen, *throughput*;
- analisis kualitatif: UMAP ruang fitur, Grad-CAM (citra), *integrated gradients* (token teks), dan matriks konfusi (lampiran).

3.8 Hasil Keseluruhan

Tabel 5 menyalin Tabel 4 paper. Pada pendekatan 1, kedua unimodal hampir setara di RVL-CDIP (teks 89,19 vs. citra 89,13), dan late fusion menaikkan akurasi sekitar 3,9 poin ke 93,06 %. Di Tobacco3482, teks (90,28) sedikit di atas citra (89,05), dan fusi mencapai 92,00 %. SCSR lebih rendah (80,76 % dan 87,89 %) tetapi dianggap kompetitif untuk ukurannya. UMAP menunjukkan komplementaritas: citra memisahkan kelas yang khas secara visual (*handwritten*, *advertisement*), teks memisahkan kelas yang kaya isi (*memo*, *scientific publication*).

Tabel 5 Hasil Kashyap et al. dibanding studi multimodal sebelumnya (Tabel 4 paper), dalam %. T = teks, V = citra, T+V = fusi. F1/Rec/Prec: macro untuk RVL-CDIP, weighted untuk Tobacco3482.

Studi	Mod.	RVL-CDIP				Tobacco3482			
		Acc	F1	Rec	Prec	Acc	F1	Rec	Prec
Audebert (2019)	T	74,6	–	–	–	73,8	–	–	–
	V	89,1	–	–	–	84,5	–	–	–
	T+V	90,6	–	–	–	87,8	–	–	–
Zingaro (2021)	T	–	–	–	–	67,8	–	–	–
	V	–	–	–	–	88,0	–	–	–
	T+V	92,7	–	–	–	90,5	–	–	–
Dauphinee/Tyler (2019)	T	82,23	–	–	–	–	–	–	–
	V	90,24	–	–	–	–	–	–	–
	T+V	93,03	–	–	–	–	–	–	–
Kashyap: late fusion	T (BERT)	89,19	89,57	89,65	90,19	90,28	92,62	90,28	97,28
	V (EffNetB3)	89,13	89,12	89,15	89,23	89,05	91,58	89,05	96,15
	T+V	**93,06**	93,06	93,17	93,06	**92,00**	94,02	92,00	98,23
Kashyap: SCSR	T	80,76	84,00	81,00	84,00	87,89	90,00	88,00	95,00

Tabel 6 Akurasi per kelas pada Tobacco3482 (%), Tabel 5 paper (hanya 8 dari 10 kelas dilaporkan)

Model	Mod.	Letter	Form	Email	Adv	Sci-pub	News	Resume	Memo
Kashyap: late fusion	T	96,25	96,67	99,00	96,30	89,09	96,72	100,0	98,55
	V	98,21	96,29	99,50	97,69	80,37	89,19	98,32	97,87
	T+V	98,41	97,73	99,50	98,17	88,39	96,79	100,0	99,68
Kashyap: SCSR	T	94,90	87,90	98,80	79,60	73,50	87,20	100,0	91,00

Efisiensi (Tabel 6–7 paper). SCSR (33,3 juta parameter) lebih akurat di Tobacco3482 daripada AlexNet-ELM (62 juta, 83,24 %) dan cabang teks Zingaro (1,8 juta, 67,8 %). Latensi per dokumen: late fusion 0,184 s (5,42 dok/s), SCSR 0,157 s (6,36 dok/s); total waktu inferensi 555,27 s vs. 547,19 s.

RealDoc-16 (Tabel 8 paper). Hanya enam kelas yang dilaporkan, akurasi (fusi / SCSR): *letter* 100/90, *news article* 100/80, *memo* 72,73/63,60, *form* 70/70, *resume* 70/80, *scientific publication* 70/90. Akurasi keseluruhan RealDoc-16 tidak dilaporkan.

3.9 Future Work

- Kerangka representasi yang lebih tangguh untuk dokumen **multibahasa** pada kondisi sumber daya rendah dan degradasi OCR berat.
- *Parameter-efficient fine-tuning* (PEFT) untuk menekan memori pelatihan.
- Mengganti rata-rata tak berbobot dengan **pembobotan modalitas adaptif** atau fusi berbasis keyakinan (*confidence-aware*), termasuk memakai model fondasi multimodal.
- Menambahkan embedding citra ringan ke basis data retrieval SCSR untuk mengatasi kemiripan antarkelas pada RVL-CDIP.

3.10 Kontribusi Utama

(a) kerangka late fusion dua aliran (EfficientNetB3 + BERT) yang modular; (b) SCSR, yang menggabungkan pembelajaran kontrastif terawasi dengan retrieval semantik sebagai pengklasifikasi tanpa lapis klasifikasi padat; (c) dataset primer RealDoc-16 untuk uji lintas domain; (d) analisis interpretabilitas (Grad-CAM, integrated gradients) yang memperlihatkan koreksi galat ganda oleh fusi.

3.11 Detail Pelatihan dan Lingkungan

Ubuntu 22.04, Intel Xeon E5-2620 v3 (12 inti), RAM 125,7 GiB, NVIDIA RTX A4000 16 GB, CUDA 10.1, TensorFlow/Keras, Python 3.12.4. Hiperparameter tiap model sudah dirinci pada subbagian model di atas.

3.12 Kelebihan

- Terbit di jurnal bereputasi tahun 2026 dan *open access*; memenuhi syarat referensi utama proyek.
- Membahas *trade-off* akurasi–efisiensi secara eksplisit dan menawarkan dua titik operasi.
- Evaluasi pada tiga dataset termasuk data primer di luar distribusi pelatihan.
- Melaporkan presisi, recall, F1, dan hasil per kelas untuk setiap unimodal, serta analisis kualitatif (UMAP, Grad-CAM, integrated gradients, matriks konfusi).

- Late fusion sederhana dan mudah direplikasi; unimodal dapat dilatih dan diganti secara terpisah.

3.13 Catatan Kritis

Poin-poin berikut kami temukan saat memeriksa angka dan protokol paper.

- **OCR tidak disebutkan.** Hanya disebut "mesin OCR komersial". Karena kedua pendekatan bergantung pada teks, tidak disebutkannya nama OCR menghalangi replikasi dan membuat perbandingan dengan Audebert (Tesseract) tidak setara.
- **Pemetaan kelas Tobacco3482 tidak dijelaskan.** Model dilatih untuk 16 kelas RVL-CDIP, padahal Tobacco3482 punya kelas *note* dan *report* yang tidak ada di RVL-CDIP (13,4 % data). Tanpa pemetaan, akurasi maksimal hanya ≈86,6 %, tetapi dilaporkan 92 %. Tabel per kelas juga hanya memuat 8 kelas.
- **Potensi kebocoran data.** Tobacco3482 dan RVL-CDIP sama-sama diambil dari arsip Truth Tobacco Industry Documents. Paper tidak menyebut apakah dokumen Tobacco3482 yang juga ada di set latih RVL-CDIP sudah dibuang.
- **Perbandingan tidak setara protokol.** Audebert melatih pada 800 dokumen Tobacco3482; Kashyap melatih pada ∼320 ribu dokumen RVL-CDIP lalu menguji pada seluruh Tobacco3482. Klaim "mengungguli studi sebelumnya" di Tobacco3482 perlu dibaca dengan catatan ini.
- **Angka metrik yang tidak konsisten.** (i) Macro-F1 SCSR di RVL-CDIP 84,00 padahal macro-precision 84,00 dan macro-recall 81,00. Karena F1 per kelas ≤ rata-rata P dan R per kelas, macro-F1 seharusnya ≤ 82,5. (ii) Pada set uji yang seimbang, macro-recall sama dengan akurasi, tetapi dilaporkan 89,65 vs. 89,19 (teks). (iii) Weighted-precision Tobacco3482 (96–98 %) jauh di atas recall (89–92 %). Ini wajar bila banyak prediksi jatuh ke kelas RVL-CDIP yang tidak ada di Tobacco3482 (dukungan nol sehingga tidak ikut dibobot), sehingga presisi tampak tinggi secara semu.
- **RealDoc-16 tidak konsisten.** Tabel 2 menyebut 160 dokumen, teks menyebut 120. Dengan 10 dokumen per kelas, akurasi *memo* 72,73 % (= 8/11) dan 63,60 % (= 7/11) tidak mungkin. Hanya 6 dari 16 kelas yang dilaporkan dan tidak ada akurasi total. Jumlah data latih juga berbeda: 319.625 (Algoritma) vs. 319.754 (Tabel 2).
- **Angka Audebert dikutip keliru.** Tabel 5 paper mencantumkan akurasi per kelas Audebert (mis. *letter* fusi 93,2), sedangkan Audebert hanya melaporkan F1 per kelas (*letter* fusi 0,86) dan nilai-nilai tersebut tidak ditemukan di paper aslinya. Kolom citra Audebert juga ditulis "–", padahal F1 per kelas citra dilaporkan.
- **Klaim efisiensi SCSR lemah.** SCSR disebut "tidak bergantung pada DL", padahal bge-small-en adalah transformer 33 juta parameter. Latensinya hanya ∼15 % lebih cepat (0,157 vs. 0,184 s), latensi OCR tidak dihitung, dan indeks FAISS 1,03 juta × 384 float32 berukuran ≈1,6 GB, yang berat untuk perangkat *edge*. Selain itu, 555,27 s / 0,184 s ≈ 3.018 dokumen, tidak cocok dengan 547,19 s / 0,157 s ≈ 3.485 dokumen jika keduanya diuji pada set yang sama.

- **Fusi tidak diablasi.** Hanya rata-rata tak berbobot yang diuji; tidak ada pembanding fusi berbobot, *product rule*, atau fusi fitur, dan tidak ada oracle. Teks menyebut rata-rata logit, sedangkan Algoritma 3 menyebut probabilitas dan prediksi.
- **Tanpa variansi dan uji statistik**: hasil satu kali jalan tanpa seed, selang kepercayaan, atau uji signifikansi.
- Hal kecil: tabel menulis tahun "2025" untuk paper 2026; CUDA 10.1 tidak lazim dipasangkan dengan Python 3.12 dan TensorFlow versi baru; nama "Tyler et al." dan "Dauphinee et al." dipakai bergantian untuk rujukan yang sama.

4 Paper 3: Kanchi et al. (2022)

4.1 Latar Belakang dan Permasalahan

Banyak dokumen memiliki struktur visual yang sama tetapi isi teks yang berbeda (*letter*, *memo*, *report*), sehingga model citra saja sulit membedakannya. Pendekatan dua aliran (citra + teks OCR) sudah terbukti lebih akurat, tetapi hampir semuanya bergantung pada *pre-training* di RVL-CDIP (320 ribu citra) dengan model besar (ResNet, InceptionNet, NasNet) yang mahal dilatih. Masalah yang diangkat: bagaimana membangun klasifikator multimodal yang **efisien** dan tetap akurat ketika data latih **sedikit**, yaitu hanya Tobacco3482 tanpa RVL-CDIP.

4.2 Dataset

- **Tobacco3482**: 3.482 citra, 10 kelas, tidak seimbang. Protokol mengacu pada Afzal et al. (2015): partisi acak dengan jumlah sampel latih/uji per kelas antara 20 dan 100, lalu set latih dibagi 80 % latih dan 20 % validasi.
- **RVL-CDIP**: 400 ribu citra, 16 kelas, split standar 320k/40k/40k. Hanya dipakai pada eksperimen pertama (*pre-training* lalu transfer ke Tobacco3482).

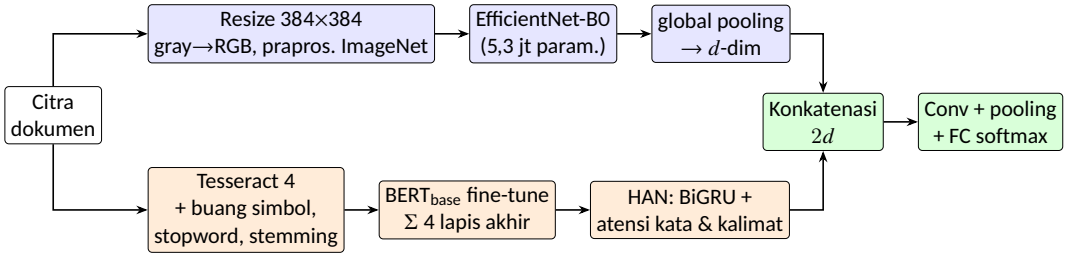
Ada dua eksperimen: (a) ImageNet + RVL-CDIP → Tobacco3482, dan (b) ImageNet saja, dilatih langsung pada Tobacco3482 (fokus utama paper).

4.3 Modalitas

Citra halaman dan teks OCR dari citra yang sama, seperti dua paper sebelumnya. Bedanya, teks diperlakukan secara hierarkis (kata → kalimat → dokumen). Tata letak tidak dipakai.

4.4 Pipeline Keseluruhan

Gambar 3 merangkum EmmDocClassifier. Aliran citra memakai EfficientNet-B0. Aliran teks memakai Tesseract 4, embedding kata kontekstual dari BERT yang di-*fine-tune*, lalu *Hierarchical Attention Network* (HAN). Vektor fitur kedua aliran berdimensi sama, dikonkatenasi, lalu diklasifikasi.



Gambar 3 Pipeline EmmDocClassifier, Kanchi et al. (digambar ulang dari Gambar 2 dan Bagian 3 paper)

4.5 Model per Unimodal

Citra – EfficientNet-B0. Varian terkecil EfficientNet (5,3 juta parameter, top-1 ImageNet 77,1 %), sekitar lima kali lebih ringan dari ResNet-50. Citra 1000×750 di-*resize* ke 384×384, grayscale disalin ke 3 kanal, dan dinormalkan sesuai ImageNet. Fitur di-*global pooling* lalu FC. Pelatihan: Adam lr 10^{-3} ($\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$), 20 epoch dengan jadwal lr 3 epoch 10^{-3}, 4 epoch 10^{-4}, sisanya 10^{-5}; *early stopping* pada akurasi validasi.

Teks – BERT + HAN. OCR memakai Tesseract 4 (LSTM). Praproses: buang simbol dan karakter salah, buang *stopword*, dan *stemming*. $\text{BERT}_{\text{base}}$ di-*fine-tune* pada korpus teks (semua lapis dibekukan kecuali 4 lapis terakhir, $\leq$4 epoch). Setelah itu bobot dibekukan, dan embedding kata diambil dari **jumlah 4 lapis terakhir** (dipilih karena setara dengan konkatenasi tetapi dimensinya lebih kecil). Embedding ini menjadi lapis embedding HAN: BiGRU + atensi di tingkat kata membentuk vektor kalimat, lalu BiGRU + atensi di tingkat kalimat membentuk vektor dokumen. Batas input 25 kalimat dan 10.000 kata per dokumen. Pelatihan HAN: RMSProp lr 10^{-3}, *batch* 100, 20 epoch, *early stopping* dengan kesabaran 4 epoch.

4.6 Metode Fusi

Fusi tingkat fitur. Vektor citra dan teks dibuat berdimensi sama (d), lalu **dikonkatenasi** menjadi $X_{ens} \in \mathbb{R}^{2d}$, diproses oleh lapis konvolusi, *global pooling*, dan FC softmax 10 kelas. Penulis juga mencoba rata-rata fitur (*average assembling*); konkatenasi lebih baik secara empiris. Model gabungan dilatih dengan Adam lr 10^{-3}, 20 epoch, *batch* 100.

4.7 Metrik Evaluasi

- Akurasi pada Tobacco3482 (dan satu angka akurasi RVL-CDIP);
- *relative error reduction* terhadap *state of the art*;
- matriks konfusi (RVL-CDIP; Tobacco3482 dengan dan tanpa *pre-training*);
- latensi inferensi per citra;
- analisis kualitatif contoh benar/salah.

Tidak ada F1, presisi, atau recall.

4.8 Hasil Keseluruhan

Tabel 7 menyalin Tabel 1 paper. Pada eksperimen utama (tanpa RVL-CDIP), citra mencapai 86,0 % dan fusi 90,3 %, naik 0,83 poin dari Ferrando et al. (89,47 %), setara pengurangan galat relatif 7,9 % (perhitungannya konsisten: $(10{,}53 - 9{,}70)/10{,}53$). Dengan *pre-training* RVL-CDIP, citra 94,04 % dan fusi 95,7 %, masih di bawah Asim et al. (95,8 %) dan Bakkali et al. (96,94 %). Model yang dilatih di RVL-CDIP disebut mencapai 95,48 % pada set uji RVL-CDIP. Latensi inferensi maksimal 105 ms per citra (55 ms teks, 50 ms citra), tanpa menghitung OCR.

Tabel 7 Akurasi Tobacco3482 (%), disalin dari Tabel 1 Kanchi et al. (pilihan baris)

Studi	ImageNet + RVL-CDIP		ImageNet saja	
	Citra	Multimodal	Citra	Multimodal
Harley et al. (2015)	89,8	–	79,9	–
Noce et al. (2016)	–	–	–	79,8
Audebert et al. (2019)	–	–	84,5	87,8
Asim et al. (2019)	93,2	95,8	–	–
Bakkali/Souhail et al. (2020)	91,3	96,94	–	–
Ferrando/Javier et al. (2020)	94,04	94,9	85,99	89,47
Kanchi et al. (2022)	94,04	95,7	86,0	**90,3**

Hasil per unimodal. Hanya aliran citra yang dilaporkan dengan angka. **Akurasi aliran teks (BERT + HAN) tidak dilaporkan sama sekali.** Ablasi BERT→FastText hanya disebut "lebih buruk dari Ferrando et al." tanpa angka.

Analisis kesalahan. Kelas *scientific* paling sering salah karena mirip *report* dan *advertisement* serta citranya berderau sehingga OCR gagal. *News*, *note*, dan *scientific* lebih baik dengan *pre-training* RVL-CDIP; kelas lain justru lebih baik tanpa *pre-training*.

4.9 Future Work

- **Co-attention** antara modalitas citra dan teks, menggantikan konkatenasi.
- Mengecilkan ukuran jaringan lebih lanjut agar layak dilatih di perangkat.
- Augmentasi dengan citra sintetis yang menonjolkan fitur khas, terutama untuk kelas *scientific*.

4.10 Kontribusi Utama

(a) aliran teks yang memadukan embedding kontekstual BERT dengan HAN (atensi kata dan kalimat); (b) aliran citra ringan dengan EfficientNet-B0; (c) akurasi tertinggi (90,3 %) untuk Tobacco3482 tanpa *pre-training* RVL-CDIP pada saat terbit.

4.11 Detail Pelatihan dan Lingkungan

NVIDIA V100 32 GB; 3 GPU paralel untuk RVL-CDIP (waktu komputasi turun ≈67 %), 1 GPU untuk Tobacco3482. Hiperparameter tiap aliran sudah dirinci di atas. Framework tidak disebut eksplisit (penggunaan `TimeDistributed` mengisyaratkan Keras).

4.12 Kelebihan

- Skenario data sedikit (Tobacco3482 saja) sangat relevan untuk praktik dan sama dengan lingkup proyek kami.

- Membandingkan dua skenario (dengan dan tanpa RVL-CDIP) secara terpisah, sehingga perbandingan dengan studi lain lebih adil dibanding Kashyap.
- OCR disebut jelas (Tesseract 4), sama dengan Audebert.
- Analisis kesalahan per kelas dengan contoh visual, serta pemilihan strategi embedding BERT (lapis mana yang digabung) dilakukan secara eksperimental.

4.13 Catatan Kritis

- **Hasil unimodal teks tidak ada.** Klaim utama paper adalah aliran teks yang lebih baik (BERT + HAN), tetapi akurasinya tidak pernah dilaporkan, begitu pula hasil ablasi FastText. Kontribusi aliran teks hanya bisa disimpulkan dari selisih fusi dan citra.
- **Angka citra identik dengan Ferrando et al.** 94,04 vs. 94,04 dan 86,0 vs. 85,99. Paper tidak menjelaskan apakah aliran citra dilatih ulang atau mengambil angka/model Ferrando. Jika dilatih ulang, kesamaan sampai dua desimal patut dipertanyakan.
- **"From scratch" menyesatkan.** Abstrak menyebut model dilatih dari nol pada Tobacco3482, padahal EfficientNet memakai bobot ImageNet dan BERT sudah di-*pre-train*. Yang dimaksud sebenarnya adalah "tanpa RVL-CDIP".
- **Protokol tidak jelas.** Deskripsi "100 partisi dengan ukuran latih/uji antara 20 dan 100" ambigu. Tidak disebut ukuran partisi mana yang dilaporkan, berapa kali diulang, atau simpangan bakunya. Protokol ini juga berbeda dari Audebert (800 latih), padahal angka keduanya dibandingkan langsung.
- **Potensi kebocoran.** BERT di-*fine-tune* pada "korpus teks kami" tanpa keterangan apakah dokumen uji ikut di dalamnya. "F1 96,5 untuk token yang sering muncul" juga tidak didefinisikan.
- **Praproses tidak cocok untuk BERT.** *Stemming* dan penghapusan *stopword* merusak konteks kalimat yang justru menjadi kekuatan BERT. Klaim bahwa BERT "memprediksi kata yang hilang" akibat OCR tidak dibuktikan.
- **Klaim efisiensi parsial.** "Ukuran jaringan turun ∼80 %" hanya membandingkan EfficientNet-B0 dengan ResNet-50 dan mengabaikan $\text{BERT}_{\text{base}}$ (110 juta parameter) di aliran teks. Jumlah parameter total dan FLOPs tidak dilaporkan, dan latensi 105 ms tidak menghitung OCR.
- **Metrik minim.** Hanya akurasi, padahal Tobacco3482 tidak seimbang; tidak ada macro-F1. Angka RVL-CDIP 95,48 % muncul dalam satu kalimat tanpa keterangan modalitas dan tanpa tabel pembanding.
- **Detail fusi kurang.** Nilai d tidak disebut, dan tidak jelas bagaimana lapis konvolusi diterapkan pada vektor hasil konkatenasi.
- Reproduktibilitas: tanpa kode dan data (*Data Availability: Not applicable*). Proses review di jurnal relatif singkat (diterima 3 Januari, disetujui 27 Januari 2022).

5 Perbandingan Ketiga Paper

Tabel 8 Perbandingan ringkas ketiga paper

Aspek	Audebert (2020)	Kanchi (2022)	Kashyap (2026)
Fokus	Baseline multimodal ringan	Data sedikit, efisien	Akurasi (fusi) dan efisiensi (SCSR)
Dataset	Tobacco3482 (800 latih), RVL-CDIP	Tobacco3482 (partisi Afzal); RVL-CDIP opsional	Latih RVL-CDIP; uji RVL-CDIP, Tobacco3482 penuh, RealDoc-16
OCR	Tesseract 4.0, dirilis (QS-OCR)	Tesseract 4	Komersial, tidak disebut
Model citra	MobileNetV2, 384×384	EfficientNet-B0, 384×384	EfficientNetB3, 300×300
Model teks	FastText (beku) + CNN 1D	BERT (fine-tune, beku) + HAN	$\text{BERT}_{\text{base}}$ (fine-tune); bge-small-en (SCSR)
Fusi	Fitur: konkatenasi + MLP	Fitur: konkatenasi + conv + FC	Keputusan: rata-rata logit
Metrik	OA, macro-F1, F1/kelas, oracle, latensi	Akurasi, matriks konfusi, latensi	Acc, P/R/F1, acc/kelas, parameter, latensi
Unimodal	Citra $\gg$ teks	Teks tidak dilaporkan	Teks $\approx$ citra
Tobacco3482 tanpa RVL	Citra 84,5; fusi 87,8	Citra 86,0; fusi 90,3	–
Tobacco3482 dengan RVL	–	Citra 94,04; fusi 95,7	Teks 90,28; citra 89,05; fusi 92,00
Fusi RVL-CDIP	90,6	95,48 (modalitas tidak jelas)	93,06
Reproduktibilitas	Tinggi	Rendah–sedang: tanpa kode, protokol ambigu	Sedang: OCR anonim, angka tidak konsisten

Ada empat hal yang terlihat dari perbandingan ini.

1. **Kualitas cabang teks menentukan nilai fusi.** Pada Audebert, teks tertinggal 10–15 poin dari citra. Pada Kashyap, teks setara citra. Kanchi mengklaim teks yang lebih baik tetapi tidak menunjukkan angkanya. Di ketiga paper, perbaikan teks datang bersamaan dengan pergantian model teks (FastText $\rightarrow$ BERT/HAN), sehingga pengaruh OCR tidak pernah diisolasi.
2. **Titik fusi.** Audebert dan Kanchi menggabungkan fitur dan melatih fusinya; Kashyap merata-rata keputusan tanpa pelatihan. Tidak ada satu paper pun yang membandingkan kedua titik fusi pada kondisi yang sama.
3. **Protokol Tobacco3482 berbeda di tiap paper** (800 latih, partisi Afzal, transfer penuh dari RVL-CDIP). Hanya Kanchi yang memisahkan skenario dengan dan tanpa RVL-CDIP; angka antarpaper tidak bisa dibandingkan langsung.
4. **Klaim efisiensi** di Kanchi dan Kashyap sama-sama tidak menghitung OCR dan tidak menghitung seluruh parameter (BERT diabaikan di Kanchi; indeks FAISS diabaikan di Kashyap). Hanya Audebert yang memasukkan waktu OCR.

6 Relevansi untuk Proyek

Fase 2 proyek kami menjadikan **mesin OCR** dan **model embedding** sebagai variabel, dengan data Tobacco3482 saja. Dari review ini:

- Ketiga paper tidak memisahkan pengaruh OCR dari pengaruh model teks. Eksperimen faktorial OCR $\times$ embedding pada proyek kami mengisi celah ini secara langsung.
- Skenario Kanchi (tanpa RVL-CDIP) paling dekat dengan lingkup proyek kami. Angka 90,3 % (fusi) dan 86,0 % (citra) menjadi acuan yang lebih sepadan daripada angka Kashyap yang memakai *pre-training* RVL-CDIP.
- BERT + HAN dari Kanchi dapat menjadi salah satu level variabel embedding, di samping FastText (Audebert) dan BERT/bge (Kashyap).
- Late fusion Kashyap (rata-rata logit) murah dan dapat ditambahkan sebagai pembanding fusi konkatenasi, bersama oracle sebagai batas atas.
- Pelajaran metodologis yang kami terapkan: laporkan **akurasi tiap unimodal** (yang tidak dilakukan Kanchi), rerata $\pm$ simpangan baku lintas seed, macro-F1 untuk data tidak seimbang, serta protokol split dan mesin OCR secara eksplisit.

7 Kesimpulan

Audebert et al. memberi baseline multimodal yang sederhana, transparan, dan dapat direplikasi. Kekuatannya adalah analisis derau OCR, oracle, dan F1 per kelas; kelemahannya adalah satu konfigurasi OCR dan tidak ada variansi. Kanchi et al. menunjukkan bahwa BERT + HAN dengan EfficientNet-B0 bisa mencapai 90,3 % pada Tobacco3482 tanpa RVL-CDIP, tetapi tidak melaporkan hasil aliran teks, protokolnya ambigu, dan klaim efisiensinya mengabaikan BERT. Kashyap et al. memperbarui komponen (EfficientNetB3, BERT) dan menunjukkan bahwa late fusion sederhana sudah memberi akurasi tinggi, serta menawarkan alternatif retrieval yang ringan. Namun paper ini memiliki sejumlah masalah pelaporan: OCR anonim, pemetaan kelas Tobacco3482 yang tidak jelas, beberapa angka metrik yang tidak konsisten secara matematis, dan kutipan hasil Audebert yang tidak cocok dengan sumbernya. Angka dari Kanchi dan Kashyap sebaiknya dipakai sebagai acuan arah, bukan target yang harus dicapai persis.

Daftar Referensi

Audebert, N., Herold, C., Slimani, K. dan Vidal, C., 2020. Multimodal Deep Networks for Text and Image-Based Document Classification. Dalam: *Machine Learning and Knowledge Discovery in Databases: ECML PKDD 2019 Workshops*. Ed. by P. Cellier dan K. Driessens. Vol. 1167. Communications in Computer and Information Science. Cham: Springer, pp.427-443. Tersedia di: <https://doi.org/10.1007/978-3-030-43823-4_35>.

Harley, A.W., Ufkes, A. dan Derpanis, K.G., 2015. Evaluation of Deep Convolutional Nets for Document Image Classification and Retrieval. Dalam: *2015 13th International Conference on Document Analysis and Recognition (ICDAR)*, pp.991-995. Tersedia di: <https://doi.org/10.1109/ICDAR.2015.7333910>.

Kanchi, S., Pagani, A., Mokayed, H., Liwicki, M., Stricker, D. dan Afzal, M.Z., 2022. EmmDocClassifier: Efficient Multimodal Document Image Classifier for Scarce Data. *Applied Sciences*, 12(3), p.1457. Tersedia di: <https://doi.org/10.3390/app12031457>.

Kashyap, A., Mittal, M. dan Singh, S., 2026. Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification. *International Journal of Intelligent Systems*, 2026, p.4241437. Tersedia di: <https://doi.org/10.1155/int/4241437>.

Kumar, J., Ye, P. dan Doermann, D., 2014. Structural Similarity for Document Image Classification and Retrieval. *Pattern Recognition Letters*, 43, pp.119-126. Tersedia di: <https://doi.org/10.1016/j.patrec.2013.10.030>.