Review Paper: Klasifikasi Dokumen Multimodal Teks OCR + Citra

Audebert et al. (2020) • Kashyap et al. (2026)

Yulian Anggreaif Rudamaga, Zalzabila Rani, Ramadhani Al-Qadri

Analisis & Pemrosesan Data Multimodal – Magister Ilmu Komputer, FILKOM UB

Dua paper yang direview

	Paper 1	Paper 2
Judul	Multimodal Deep Networks for Text and Image-Based Document Classification	Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification
Penulis	Audebert, Herold, Slimani, Vidal (Quicksign)	Kashyap, Mittal, Singh (Central Univ. of Punjab)
Venue	ECML PKDD 2019 Workshops, CCIS 1167, Springer 2020	Int. J. Intelligent Systems (Wiley), 2026
DOI	10.1007/978-3-030-43823-4_35	10.1155/int/4241437
Peran	Dasar replikasi Fase 1	Referensi utama Fase 2

Aspek review: 9 poin wajib (latar belakang, dataset, modalitas, pipeline, model unimodal, fusi, metrik, hasil, future work) + 4 tambahan (kontribusi, detail pelatihan, kelebihan, catatan kritis).

Paper 1 – Audebert et al. (2020)

Latar belakang, dataset, modalitas

Masalah

- Dokumen hasil pindai/foto tidak punya lapisan teks; pengenalan jenis dokumen masih manual.
- Visual saja cukup untuk kelas kasar, tidak untuk kelas halus (formulir pajak: tata letak sama, isi beda).
- Pertanyaan: apakah teks OCR yang berderau tetap menambah akurasi jika digabung dengan citra, dengan biaya rendah?

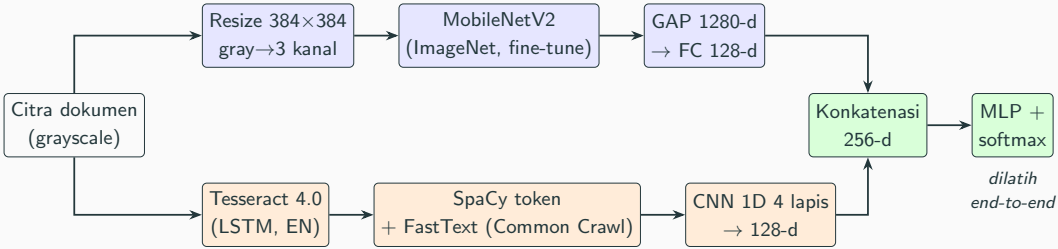
Dataset

- Tobacco3482: 3.482 dok., 10 kelas; 800 latih, sisanya uji; rerata 3 run.
- RVL-CDIP: 400 rb dok., 16 kelas; split 320k/40k/40k.
- QS-OCR: teks Tesseract kedua dataset, dirilis terbuka.

Modalitas

- Citra grayscale halaman + teks OCR dari citra yang sama.
- Teks adalah turunan citra; tata letak tidak dipakai.

Pipeline



- Dua cabang menghasilkan vektor 128-d, lalu dikonkatenasi dan diklasifikasi MLP.
- Seluruh jaringan dilatih end-to-end (FastText tetap beku).

Model unimodal dan fusi

Citra: MobileNetV2

- Ringan; akurasi setara VGG-16, jauh lebih cepat.
- 384×384, grayscale diduplikasi 3 kanal, bobot ImageNet.
- Augmentasi tidak membantu (84,5 vs. 83,9 %).

Teks: FastText + CNN 1D

- Tesseract 4.0 LSTM; ∼26 % kata tidak ada di kamus.
- FastText (subkata) agar kata salah eja tetap punya vektor.
- CNN 1D: 4 lapis, kernel 12, 512 kanal, max-pool waktu; 500 kata.
- MLP embedding dokumen kalah (70,8 vs. 73,9 %).

Fusi: tingkat fitur

- Teks 128-d $\oplus$ citra (GAP 1280 $\rightarrow$ FC 128) $\rightarrow$ MLP.
- Penjumlahan fitur dicoba, tetapi kalah dari citra saja.

Pelatihan

- SGD momentum 0,9; lr 0,01; batch 40.
- Epoch: teks 100, citra 200, fusi 200.
- TensorFlow 1.12, Titan X.

Metrik

- OA, macro-F1, F1/kelas, oracle, latensi.

Hasil

Tobacco3482 (OA %, F1 per kelas)

Model	OA	F1	Adv	Email	Form	Letter	Memo	News	Note	Report	Res	Sci
Teks	73,8	0,71	0,60	0,96	0,76	0,71	0,79	0,67	0,62	0,43	**0,97**	0,57
Citra	84,5	0,82	**0,94**	0,96	0,85	0,83	0,90	0,89	0,83	0,61	0,80	0,62
Fusi	**87,8**	**0,86**	0,93	0,98	0,88	0,86	0,90	0,90	0,85	0,71	0,96	0,68
Oracle	92,1	0,91	0,94	0,99	0,94	0,92	0,93	0,93	0,89	0,81	0,97	0,79

RVL-CDIP (OA %)

Citra	Teks	Fusi
89,1	74,6	**90,6**

- Fusi +3,3 (Tobacco) dan +1,5 (RVL) di atas citra.
- Oracle: batas atas +7,6, jadi masih ada celah 4,3.
- Latensi CPU: OCR 910 ms + model 360 ms $\approx$ 1,3 s; OCR jadi hambatan utama.

Future work, kelebihan, catatan kritis

Future work

- Data dunia nyata (foto, rotasi) + augmentasi.
- Segmentasi tata letak (dhSegment).
- Koreksi ejaan (SymSpell) + NER.
- Embedding tahan derau OCR.

Kelebihan

- Desain sederhana, tiap pilihan diuji.
- Oracle dan F1 per kelas.
- Analisis derau OCR kuantitatif.
- Data teks terbuka sehingga mudah direplikasi.

Catatan kritis

- Tanpa simpangan baku dan uji signifikansi.
- Cara memilih 800 dokumen latih tidak dijelaskan.
- OA teks 73,9 vs. 73,8 (Tabel 1 vs. 3).
- RVL-CDIP hanya OA.
- Satu OCR saja; tidak ada pembanding late fusion.

Paper 2 – Kashyap et al. (2026)

Latar belakang, dataset, modalitas

Masalah

- Unimodal tidak tangguh: visual ambigu, teks OCR penuh OOV.
- VLM besar (LayoutLMv3, DocFormer, DocLLM) terlalu berat untuk edge/IoMT.
- Fusi awal/menengah rentan propagasi galat antarmodal.
- Celah: trade-off akurasi–efisiensi jarang dibahas, sehingga diusulkan dua kerangka terpisah.

Dataset (semua model dilatih di RVL-CDIP)

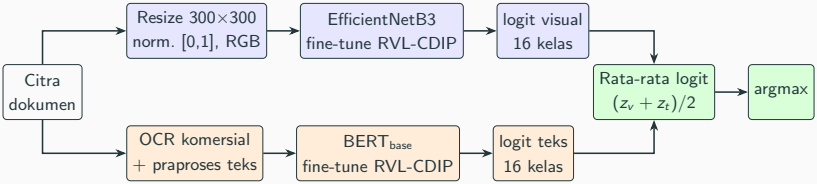
Dataset	Total	Uji	Kelas
RVL-CDIP	399.743	39.995	16
Tobacco3482	3.482	3.482	10
RealDoc-16 (primer)	160	160	16

Modalitas

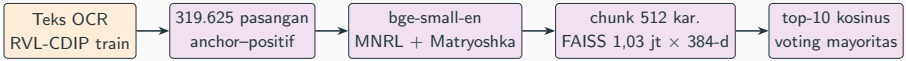
- Fusi: citra + teks OCR.
- SCSR: teks saja.

Pipeline

Pendekatan 1 – multimodal late fusion



Pendekatan 2 – SCSR (teks saja)



- Pendekatan 1 mengejar akurasi: dua aliran dilatih terpisah, lalu logit dirata-rata.
- Pendekatan 2 mengejar efisiensi: pada dasarnya k-NN ($k = 10$) di ruang embedding hasil pelatihan kontrastif.

Model unimodal, fusi, metrik

Citra: EfficientNetB3

- 300×300, RGB, [0,1]; 1536 $\rightarrow$ Dropout $\rightarrow$ 16.
- 10 epoch, batch 16, Adam 10^{-3}; $\approx$22,5 jam.

Teks: $\text{BERT}_{\text{base}}$

- **OCR komersial tanpa nama**; praproses: huruf kecil, buang angka/stopword/tanda baca.
- 10 epoch, batch 16, Adam 5×10^{-5}, dropout 0,3; $\approx$41 jam.

Teks: SCSR (bge-small-en, 33,3 jt param.)

- MNRL + Matryoshka; 4 epoch, AdamW 2×10^{-5}.
- Chunk 512 karakter, FAISS 1,03 jt $\times$ 384-d.

Fusi: late fusion $\quad \hat{y} = \arg\max_c \frac{1}{2}(z_v + z_t)_c$

- Rata-rata logit tak berbobot; tidak ada parameter fusi.

Metrik

- Acc; P/R/F1 *macro* (RVL, RealDoc) dan *weighted* (Tobacco).
- Akurasi per kelas; parameter, latensi, throughput.
- UMAP, Grad-CAM, integrated gradients.

Hasil

		RVL-CDIP (macro)				Tobacco3482 (weighted)			
Studi	Mod.	Acc	F1	Rec	Prec	Acc	F1	Rec	Prec
Audebert (2019)	T / V / T+V	74,6 / 89,1 / 90,6				73,8 / 84,5 / 87,8			
Zingaro (2021)	T+V	92,7				90,5			
Dauphinee (2019)	T+V	93,03				–			
	T (BERT)	89,19	89,57	89,65	90,19	90,28	92,62	90,28	97,28
Kashyap: fusi	V (EffNet)	89,13	89,12	89,15	89,23	89,05	91,58	89,05	96,15
	T+V	**93,06**	93,06	93,17	93,06	**92,00**	94,02	92,00	98,23
Kashyap: SCSR	T	80,76	84,00	81,00	84,00	87,89	90,00	88,00	95,00

- Teks ≈ citra; fusi +3,87 (RVL) dan +1,72 (Tobacco) di atas unimodal terbaik.
- Latensi: fusi 0,184 s/dok, SCSR 0,157 s/dok (OCR tidak dihitung).
- RealDoc-16: hanya 6 dari 16 kelas dilaporkan (mis. letter 100/90, memo 72,73/63,60).

Future work dan kelebihan

Future work

- Dokumen multibahasa dengan OCR yang sangat terdegradasi.
- PEFT untuk menekan memori pelatihan.
- Pembobotan modalitas adaptif / fusi berbasis keyakinan.
- Tambah embedding citra ringan ke indeks SCSR.

Kelebihan

- Jurnal 2026, open access (memenuhi syarat dosen).
- Trade-off akurasi–efisiensi eksplisit.
- Uji di tiga dataset, termasuk data primer.
- P/R/F1 + per kelas untuk tiap unimodal.
- Late fusion mudah direplikasi.

Catatan kritis

- **OCR tidak disebut**, sehingga tidak bisa direplikasi.
- **Pemetaan kelas Tobacco hilang**: *note* + *report* (13,4 %) tidak ada di RVL-CDIP, sehingga tanpa pemetaan akurasi maks. ≈86,6 %, padahal dilaporkan 92 %.
- Potensi kebocoran: Tobacco3482 dan RVL-CDIP dari arsip yang sama; tidak disebut ada deduplikasi.
- Protokol Tobacco berbeda dari Audebert (transfer vs. 800 latih).
- Hanya rata-rata tak berbobot; tidak ada ablasi fusi dan oracle.
- **Angka tidak konsisten**: macro-F1 SCSR 84 $>$ (P 84 + R 81)/2; macro-recall $\neq$ akurasi pada data seimbang.
- RealDoc-16: 160 vs. 120 dokumen; 72,73 % = 8/11 padahal 10/kelas.
- Angka per kelas Audebert di Tabel 5 **tidak ditemukan** di paper asli (yang melaporkan F1, bukan akurasi).
- Klaim "tanpa DL" untuk SCSR padahal transformer 33 jt; indeks FAISS ≈1,6 GB; hemat latensi hanya ∼15 %.
- Tanpa seed, variansi, atau uji signifikansi.

Perbandingan dan relevansi

Perbandingan

Aspek	Audebert (2020)	Kashyap (2026)
OCR	Tesseract 4.0, terbuka	Komersial, anonim
Citra	MobileNetV2	EfficientNetB3
Teks	FastText (beku) + CNN 1D	$\text{BERT}_{\text{base}}$; bge-small (SCSR)
Fusi	Fitur, konkatenasi + MLP	Keputusan, rata-rata logit
Unimodal	Citra $\gg$ teks	Teks $\approx$ citra
Fusi Tobacco	87,8 (+3,3)	92,00 (+1,72)
Fusi RVL	90,6 (+1,5)	93,06 (+3,87)
Protokol Tobacco	800 latih	Transfer dari RVL-CDIP
Replikasi	Tinggi	Sedang

Inti: lompatan kualitas teks di Kashyap berasal dari OCR *dan* model teks yang berubah bersamaan, sehingga keduanya tidak bisa dipisahkan.

Relevansi untuk proyek (Fase 2)

- Kedua paper tidak memisahkan pengaruh **OCR** dari pengaruh **embedding**; eksperimen faktorial OCR $\times$ embedding pada proyek kami mengisi celah ini.
- Late fusion (rata-rata logit) murah, sehingga bisa ditambahkan sebagai pembanding konkatenasi Audebert, bersama oracle sebagai batas atas.
- Praktik yang kami ambil: rerata $\pm$ simpangan baku lintas seed, macro-F1 untuk data tidak seimbang, protokol split dan mesin OCR dinyatakan eksplisit, dan tidak membandingkan angka dari protokol yang berbeda.

Kesimpulan

- **Audebert**: baseline multimodal sederhana dan transparan; kelemahannya satu OCR dan tanpa variansi.
- **Kashyap**: komponen modern dan late fusion sederhana dengan akurasi tinggi, ditambah alternatif retrieval ringan, tetapi pelaporannya punya beberapa masalah (OCR anonim, pemetaan kelas, angka tidak konsisten).
- Angka Kashyap dipakai sebagai *acuan arah*, bukan target yang harus dicapai persis.

Terima kasih