Review Paper: Klasifikasi Dokumen Multimodal Teks OCR + Citra

Audebert et al. (2020) • Kashyap et al. (2026) • Kanchi et al. (2022)

Yulian Anggreaif Rudamaga, Zalzabila Rani, Ramadhani Al-Qadri

Analisis & Pemrosesan Data Multimodal – Magister Ilmu Komputer, FILKOM UB

Tiga paper yang direview

	Paper 1	Paper 2	Paper 3
Judul	Multimodal Deep Networks for Text and Image-Based Document Classification	Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification	EmmDocClassifier: Efficient Multimodal Document Image Classifier for Scarce Data
Penulis	Audebert et al. (Quicksign)	Kashyap et al. (Univ. Punjab)	Kanchi et al. (TU Kaiserslautern, DFKI)
Venue	ECML PKDD 2019 Workshops, CCIS 1167, Springer 2020	Int. J. Intelligent Systems (Wiley), 2026	Applied Sciences (MDPI) 12(3), 2022
DOI	10.1007/978-3-030-43823-4_35	10.1155/int/4241437	10.3390/app12031457
Peran	Dasar replikasi Fase 1	Referensi utama Fase 2	Pembanding data sedikit

Aspek: 9 poin wajib (latar belakang, dataset, modalitas, pipeline, model unimodal, fusi, metrik, hasil, future work) + 4 tambahan (kontribusi, detail pelatihan, kelebihan, catatan kritis). Audebert = 2020 (workshop 2019).

Paper 1 – Audebert et al. (2020)

Latar belakang, dataset, modalitas

Masalah

- Dokumen hasil pindai/foto tidak punya lapisan teks; pengenalan jenis dokumen masih manual.
- Visual saja cukup untuk kelas kasar, tidak untuk kelas halus (formulir pajak: tata letak sama, isi beda).
- Pertanyaan: apakah teks OCR yang berderau tetap menambah akurasi jika digabung dengan citra, dengan biaya rendah?

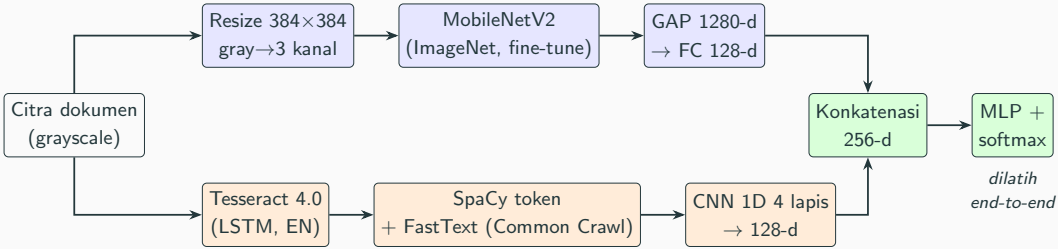
Dataset

- Tobacco3482: 3.482 dok., 10 kelas; 800 latih, sisanya uji; rerata 3 run.
- RVL-CDIP: 400 rb dok., 16 kelas; split 320k/40k/40k.
- QS-OCR: teks Tesseract kedua dataset, dirilis terbuka.

Modalitas

- Citra grayscale halaman + teks OCR dari citra yang sama.
- Teks adalah turunan citra; tata letak tidak dipakai.

Pipeline



- Dua cabang menghasilkan vektor 128-d, lalu dikonkatenasi dan diklasifikasi MLP.
- Seluruh jaringan dilatih end-to-end (FastText tetap beku).

Model unimodal dan fusi

Citra: MobileNetV2

- Ringan; akurasi setara VGG-16, jauh lebih cepat.
- 384×384, grayscale diduplikasi 3 kanal, bobot ImageNet.
- Augmentasi tidak membantu (84,5 vs. 83,9 %).

Teks: FastText + CNN 1D

- Tesseract 4.0 LSTM; ∼26 % kata tidak ada di kamus.
- FastText (subkata) agar kata salah eja tetap punya vektor.
- CNN 1D: 4 lapis, kernel 12, 512 kanal, max-pool waktu; 500 kata.
- MLP embedding dokumen kalah (70,8 vs. 73,9 %).

Fusi: tingkat fitur

- Teks 128-d $\oplus$ citra (GAP 1280 $\rightarrow$ FC 128) $\rightarrow$ MLP.
- Penjumlahan fitur dicoba, tetapi kalah dari citra saja.

Pelatihan

- SGD momentum 0,9; lr 0,01; batch 40.
- Epoch: teks 100, citra 200, fusi 200.
- TensorFlow 1.12, Titan X.

Metrik

- OA, macro-F1, F1/kelas, oracle, latensi.

Hasil

Tobacco3482 (OA %, F1 per kelas)

Model	OA	F1	Adv	Email	Form	Letter	Memo	News	Note	Report	Res	Sci
Teks	73,8	0,71	0,60	0,96	0,76	0,71	0,79	0,67	0,62	0,43	**0,97**	0,57
Citra	84,5	0,82	**0,94**	0,96	0,85	0,83	0,90	0,89	0,83	0,61	0,80	0,62
Fusi	**87,8**	**0,86**	0,93	0,98	0,88	0,86	0,90	0,90	0,85	0,71	0,96	0,68
Oracle	92,1	0,91	0,94	0,99	0,94	0,92	0,93	0,93	0,89	0,81	0,97	0,79

RVL-CDIP (OA %)

Citra	Teks	Fusi
89,1	74,6	**90,6**

- Fusi +3,3 (Tobacco) dan +1,5 (RVL) di atas citra.
- Oracle: batas atas +7,6, jadi masih ada celah 4,3.
- Latensi CPU: OCR 910 ms + model 360 ms $\approx$ 1,3 s; OCR jadi hambatan utama.

Kontribusi, kelebihan, future work

Kontribusi

- Pipeline multimodal ringan dari komponen siap pakai (MobileNetV2 + FastText), dilatih end-to-end.
- Analisis derau OCR: $\sim$26 % kata di luar kamus.
- Bukti teks berderau tetap menaikkan akurasi.
- Rilis dataset teks QS-OCR.

Kelebihan

- Desain sederhana, tiap pilihan diuji.
- Oracle dan F1 per kelas.
- Latensi dihitung termasuk OCR.
- Data teks terbuka sehingga mudah direplikasi.

Future work

- Data dunia nyata (foto, rotasi) + augmentasi.
- Segmentasi tata letak (dhSegment).
- Koreksi ejaan (SymSpell) + NER.
- Embedding tahan derau OCR.

Catatan kritis

- Rerata 3 run tanpa simpangan baku dan uji signifikansi.
- Cara memilih 800 dokumen latih tidak dijelaskan.
- Hiperparameter disetel manual pada “subset Tobacco3482”; tidak jelas terpisah dari data uji.
- OA teks 73,9 vs. 73,8 (Tabel 1 vs. 3).
- RVL-CDIP hanya OA; tanpa F1 atau hasil per kelas.
- Baseline citra di bawah SOTA (89,1 vs. 90,97), sebagian karena tanpa *multi-crop* saat inferensi (diakui penulis).
- Satu OCR saja; tidak ada pembanding late fusion.
- FastText beku, jadi “end-to-end” hanya untuk CNN 1D.

Paper 2 – Kashyap et al. (2026)

Latar belakang, dataset, modalitas

Masalah

- Unimodal tidak tangguh: visual ambigu, teks OCR penuh OOV.
- VLM besar (LayoutLMv3, DocFormer, DocLLM) terlalu berat untuk edge/IoMT.
- Fusi awal/menengah rentan propagasi galat antarmodal.
- Celah: trade-off akurasi–efisiensi jarang dibahas, sehingga diusulkan dua kerangka terpisah.

Dataset (semua model dilatih di RVL-CDIP)

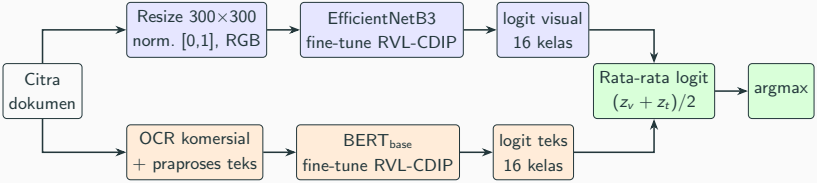
Dataset	Total	Uji	Kelas
RVL-CDIP	399.743	39.995	16
Tobacco3482	3.482	3.482	10
RealDoc-16 (primer)	160	160	16

Modalitas

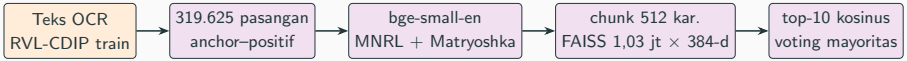
- Fusi: citra + teks OCR.
- SCSR: teks saja.

Pipeline

Pendekatan 1 – multimodal late fusion



Pendekatan 2 – SCSR (teks saja)



- Pendekatan 1 mengejar akurasi: dua aliran dilatih terpisah, lalu logit dirata-rata.
- Pendekatan 2 mengejar efisiensi: pada dasarnya k-NN ($k = 10$) di ruang embedding hasil pelatihan kontrastif.

Model unimodal, fusi, metrik

Citra: EfficientNetB3

- 300×300, RGB, [0,1]; 1536 $\rightarrow$ Dropout $\rightarrow$ 16.
- 10 epoch, batch 16, Adam 10^{-3}; $\approx$22,5 jam.

Teks: $\text{BERT}_{\text{base}}$

- **OCR komersial tanpa nama**; praproses: huruf kecil, buang angka/stopword/tanda baca.
- 10 epoch, batch 16, Adam 5×10^{-5}, dropout 0,3; $\approx$41 jam.

Teks: SCSR (bge-small-en, 33,3 jt param.)

- MNRL + Matryoshka; 4 epoch, AdamW 2×10^{-5}.
- Chunk 512 karakter, FAISS 1,03 jt $\times$ 384-d.

Fusi: late fusion $\quad \hat{y} = \arg\max_c \frac{1}{2}(z_v + z_t)_c$

- Rata-rata logit tak berbobot; tidak ada parameter fusi.

Metrik

- Acc; P/R/F1 *macro* (RVL, RealDoc) dan *weighted* (Tobacco).
- Akurasi per kelas; parameter, latensi, throughput.
- UMAP, Grad-CAM, integrated gradients.

Hasil

		RVL-CDIP (macro)				Tobacco3482 (weighted)			
Studi	Mod.	Acc	F1	Rec	Prec	Acc	F1	Rec	Prec
Audebert (2020)	T / V / T+V	74,6 / 89,1 / 90,6				73,8 / 84,5 / 87,8			
Zingaro (2021)	T+V	92,7				90,5			
Dauphinee (2019)	T+V	93,03				–			
	T (BERT)	89,19	89,57	89,65	90,19	90,28	92,62	90,28	97,28
Kashyap: fusi	V (EffNet)	89,13	89,12	89,15	89,23	89,05	91,58	89,05	96,15
	T+V	**93,06**	93,06	93,17	93,06	**92,00**	94,02	92,00	98,23
Kashyap: SCSR	T	80,76	84,00	81,00	84,00	87,89	90,00	88,00	95,00

- Teks ≈ citra; fusi +3,87 (RVL) dan +1,72 (Tobacco) di atas unimodal terbaik.
- Latensi: fusi 0,184 s/dok, SCSR 0,157 s/dok (OCR tidak dihitung).
- RealDoc-16: hanya 6 dari 16 kelas dilaporkan (mis. letter 100/90, memo 72,73/63,60).

Kontribusi, kelebihan, future work

Kontribusi (versi penulis)

- Late fusion dua aliran yang modular (EfficientNetB3 + BERT).
- SCSR: kontrastif terawasi + retrieval sebagai pengklasifikasi.
- Dataset primer RealDoc-16.
- Analisis Grad-CAM dan integrated gradients.

Kelebihan

- Jurnal 2026, open access (memenuhi syarat dosen).
- Trade-off akurasi–efisiensi eksplisit.
- Uji di tiga dataset, termasuk data primer.
- P/R/F1 + per kelas untuk tiap unimodal.

Future work

- Dokumen multibahasa dengan OCR yang sangat terdegradasi.
- PEFT untuk menekan memori pelatihan.
- Pembobotan modalitas adaptif / fusi berbasis keyakinan.
- Embedding citra ringan di indeks SCSR.

Catatan kritis (1/2): protokol dan perbandingan

- **OCR tidak disebut**, sehingga tidak bisa direplikasi.
- **Pemetaan kelas Tobacco hilang**: *note* + *report* (13,4 %) tidak ada di RVL-CDIP, sehingga tanpa pemetaan akurasi maks. ≈86,6 %, padahal dilaporkan 92 %.
- Precision berbobot Tobacco (98,23) $\gg$ recall (92,00), pola sama di T dan V; konsisten dengan prediksi jatuh ke kelas di luar label Tobacco.
- Potensi kebocoran: Tobacco3482 dan RVL-CDIP dari arsip yang sama; tidak disebut ada deduplikasi.
- **Perbandingan selektif**: Kanchi [77] dan Bakkali [46] dikutip tetapi angkanya (95,7 dan 96,94 di Tobacco; Kanchi 95,48 di RVL) tidak dibandingkan. LayoutLMv3/DocFormer hanya disebut "terlalu berat".
- Protokol Tobacco berbeda dari Audebert (transfer vs. 800 latih).
- Praproses buang angka/stopword/tanda baca sebelum BERT (kritik yang sama dengan Kanchi).
- Hanya rata-rata tak berbobot; tanpa ablasi fusi, oracle, seed, atau uji signifikansi.

Catatan kritis (2/2): angka dan SCSR

- **Angka tidak konsisten**: macro-F1 SCSR 84 $>$ (P 84 + R 81)/2; macro-recall $\neq$ akurasi pada data seimbang.
- RealDoc-16: 160 vs. 120 dokumen; 72,73 % = 8/11 padahal 10/kelas.
- Angka per kelas Audebert di Tabel 5 **tidak ditemukan** di paper asli.
- Tabel latensi: 555,27 s $\times$ 5,42 $\approx$ 3.010 dok. (fusi) vs. 547,19 s $\times$ 6,36 $\approx$ 3.480 dok. (SCSR), jadi jumlah dokumen uji berbeda dan total waktu hampir sama.
- Klaim "tanpa DL" untuk SCSR padahal transformer 33 jt; indeks FAISS $\approx$1,6 GB.
- Syarat ">512 token", tetapi chunk 512 *karakter* ($\sim$100–150 token).
- Dokumen uji di-embed utuh (Algoritma 6), sehingga dokumen panjang terpotong di 512 token.
- Voting top-10 per *chunk*, bukan per dokumen, sehingga condong ke kelas yang teksnya panjang.

Paper 3 – Kanchi et al. (2022)

Latar belakang, dataset, modalitas

Masalah

- Dokumen sering mirip secara visual tetapi berbeda isi (letter, memo, report).
- Model dua aliran yang ada bergantung pada *pre-training* RVL-CDIP (320 rb citra) dan model besar.
- Pertanyaan: bisakah klasifikator multimodal efisien tetap akurat dengan data sedikit (Tobacco3482 saja)?

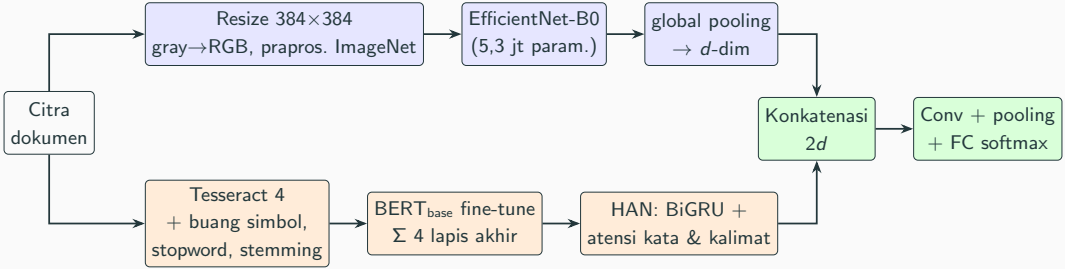
Dataset

- Tobacco3482: 10 kelas; partisi ala Afzal (20–100 sampel/kelas), latih dibagi 80/20.
- RVL-CDIP: hanya untuk eksperimen *pre-training*.
- Dua skenario: ImageNet + RVL-CDIP, dan ImageNet saja (fokus).

Modalitas

- Citra + teks OCR; teks diproses hierarkis (kata $\rightarrow$ kalimat $\rightarrow$ dokumen).

Pipeline EmmDocClassifier



- Fitur citra dan teks berdimensi sama, dikonkatenasi ($2d$), lalu conv + pooling + FC.
- Rata-rata fitur juga dicoba, tetapi konkatenasi lebih baik.

Model unimodal, fusi, metrik

Citra: EfficientNet-B0

- 5,3 jt parameter ($\sim$5$\times$ lebih ringan dari ResNet-50).
- 384$\times$384, gray $\rightarrow$ RGB, bobot ImageNet.
- Adam 10^{-3}, 20 epoch, lr turun bertahap ke 10^{-5}.

Teks: Tesseract 4 + BERT + HAN

- Praproses: buang simbol, stopword, *stemming*.
- $\text{BERT}_{\text{base}}$ fine-tune (4 lapis akhir), lalu dibekukan; embedding = jumlah 4 lapis akhir.
- HAN: BiGRU + atensi kata dan kalimat; 25 kalimat, 10 rb kata.
- RMSProp 10^{-3}, batch 100, 20 epoch.

Fusi: tingkat fitur

$$X_{ens} = [X_{img}; X_{text}] \in \mathbb{R}^{2d}$$

- Adam 10^{-3}, 20 epoch, batch 100.
- NVIDIA V100 32 GB.

Metrik

- Akurasi, *relative error reduction*.
- Matriks konfusi, latensi, contoh benar/salah.
- **Tidak ada F1/presisi/recall.**

Hasil (Tobacco3482, akurasi %)

	ImageNet + RVL		ImageNet saja	
Studi	Citra	Multi	Citra	Multi
Audebert (2020)	–	–	84,5	87,8
Asim (2019)	93,2	95,8	–	–
Bakkali (2020)	91,3	96,94	–	–
Ferrando (2020)	94,04	94,9	85,99	89,47
Kanchi	94,04	95,7	86,0	**90,3**

- Tanpa RVL-CDIP: fusi 90,3 %, +0,83 dari Ferrando (galat relatif −7,9 %, hitungannya konsisten).
- Dengan RVL-CDIP: 95,7 %, masih di bawah Asim dan Bakkali.
- RVL-CDIP: 95,48 % multimodal (matriks konfusi Gbr. 10; tanpa P/R/F1).
- Latensi 105 ms (teks 55 + citra 50), tanpa OCR.
- **Akurasi aliran teks tidak dilaporkan.**
- Kelas tersulit: *scientific* (mirip report/adv., citra berderau).

Kontribusi, kelebihan, future work

Kontribusi

- Aliran teks BERT (embedding kontekstual) + HAN (atensi kata dan kalimat).
- Aliran citra ringan EfficientNet-B0.
- 90,3 % Tobacco3482 tanpa RVL-CDIP (tertinggi saat terbit).

Kelebihan

- Skenario data sedikit = lingkup proyek kami.
- Skenario dengan/tanpa RVL-CDIP dipisah.
- OCR jelas (Tesseract 4).
- Analisis kesalahan per kelas.

Future work

- Co-attention antarmodalitas.
- Jaringan lebih kecil untuk pelatihan di perangkat.
- Augmentasi citra sintetis (kelas scientific).

Catatan kritis

- **Hasil unimodal teks dan ablasi FastText tanpa angka**, padahal aliran teks adalah klaim utama.
- **Angka citra identik dengan Ferrando** (94,04 = 94,04; 86,0 ≈ 85,99), tanpa penjelasan.
- "From scratch" menyesatkan: memakai bobot ImageNet dan BERT pre-trained.
- Protokol partisi ambigu; tidak ada jumlah ulangan atau simpangan baku.
- BERT di-fine-tune pada "korpus kami", sehingga ada potensi kebocoran data uji.
- Stemming + buang stopword sebelum BERT merusak konteks.
- HAN butuh batas kalimat, tetapi cara segmentasi teks OCR tidak dijelaskan.
- Klaim "ukuran turun 80 %" mengabaikan BERT (110 jt param.).
- Latensi 105 ms (V100) ≈ Audebert 110 ms (Titan X); klaim waktu latih tanpa angka.
- Evaluasi strategi embedding (Gbr. 5, "F1 token sering muncul") tidak dijelaskan.
- Hanya akurasi; RVL 95,48 % didukung matriks konfusi, tetapi tanpa P/R/F1 dan tanpa cara transfer 16 → 10 kelas.
- Tanpa kode/data.

Perbandingan dan relevansi

Perbandingan (1/2): desain

Aspek	Audebert (2020)	Kanchi (2022)	Kashyap (2026)
Protokol Tobacco	800 latih, rerata 3 run	Partisi Afzal (20–100/kelas), ulangan tidak disebut	Uji penuh 3.482, tanpa latih di Tobacco
OCR	Tesseract 4.0, terbuka	Tesseract 4	Komersial, anonim
Citra	MobileNetV2	EfficientNet-B0	EfficientNetB3
Teks	FastText + CNN 1D	BERT + HAN	BERT; bge-small (SCSR)
Fusi	Fitur: konkat. + MLP	Fitur: konkat. + conv	Keputusan: rata-rata logit
Parameter	Tidak dilaporkan (ringan)	$\geq$115 jt (B0 + BERT)	Total tidak dilaporkan; SCSR 33,3 jt
Hardware	Titan X	V100	RTX A4000
Kode/data	Data teks OCR saja	Tidak ada	Tidak ada

Perbandingan (2/2): hasil

Aspek	Audebert (2020)	Kanchi (2022)	Kashyap (2026)
Unimodal	Citra $\gg$ teks	Teks tidak dilaporkan	Teks $\approx$ citra
Tobacco tanpa RVL	87,8	90,3	–
Tobacco dengan RVL	–	95,7	92,00
Fusi RVL-CDIP	90,6	95,48 (matriks konfusi)	93,06
Latensi model	110 ms GPU / 360 ms CPU, + OCR 910 ms	105 ms, tanpa OCR	184 / 157 ms, tanpa OCR
Kelas tersulit	scientific (F1 0,68), report (0,71)	scientific (mirip report)	sci-pub (88,39)
Replikasi	Tinggi	Rendah–sedang	Sedang

Inti: di ketiga paper, perbaikan teks datang bersamaan dengan pergantian model teks (dan praproses), sehingga pengaruh OCR tidak pernah diisolasi. Protokol Tobacco3482 berbeda di tiap paper, jadi angkanya tidak bisa dibandingkan langsung.

Keterbatasan bersama

- **Tidak ada modalitas tata letak.** Teks dipakai sebagai urutan kata tanpa posisi; keluarga LayoutLM ditolak karena berat, tetapi fitur tata letak ringan (kotak dari OCR) tidak diuji.
- **Kualitas dataset.** Larson et al. (EACL 2023): derau label RVL-CDIP $\sim$8,1 % (1,6–16,9 % per kelas) dan tumpang tindih latih–uji yang besar. Selisih $<$1 poin di RVL-CDIP sulit ditafsirkan, dan risiko kebocoran Kashyap makin kuat.
- **Kelas tersulit sama**: scientific/report, yang mirip secara visual dan isi, dengan citra berderau sehingga OCR gagal. Batas atasnya ditentukan OCR, bukan arsitektur.
- **Klaim efisiensi** tidak menghitung OCR (kecuali Audebert), dan latensi model ketiganya setara (105–184 ms).
- **Tanpa uji statistik** di ketiga paper.

Relevansi (1/2): keputusan desain Fase 2

- **Protokol**: 800 latih terstratifikasi, sisanya uji, 3 split (seed 42/43/44), tanpa RVL-CDIP. Mengikuti jumlah latih Audebert dengan deviasi tertulis (split acak, bukan k-fold). Pembanding sepadan: Audebert dan Kanchi-tanpa-RVL (dengan catatan protokol); angka Kashyap bukan target.
- **Faktor OCR**: QS-OCR (Tesseract 4, TIF; acuan Fase 1), Tesseract 5 (JPG), EasyOCR 1.7.2, PaddleOCR 3.7.0; Keras-OCR opsional. Daftar mesin perlu konfirmasi dosen.
- **Faktor embedding**: FastText + CNN 1D (Fase 1) vs. $\text{BERT}_{\text{base}}$ fine-tune (512 token); BERT + HAN (Kanchi) sebagai kandidat level ketiga.
- **Praproses**: tanpa buang angka/stopword/tanda baca, supaya efek embedding tidak tercampur.
- **Fusi**: konkatenasi vs. rata-rata logit pada kondisi sama, + oracle + uji missing modality.
- **Evaluasi**: OA, macro-F1, F1/kelas, akurasi tiap unimodal, rerata $\pm$ std 3 seed, McNemar.
- **Tata letak**: kotak posisi teks dari OCR disimpan untuk tahap lanjutan.

Relevansi (2/2): hipotesis kerja

Titik awal Fase 1 (eksekusi nyata): cabang teks Tesseract + FastText + CNN 1D mencapai OA $0{,}7266 \pm 0{,}0059$, tetapi sumbangannya di fusi kecil.

H1 Mesin OCR mengubah akurasi cabang teks secara nyata (McNemar antar-mesin).

H2 BERT memperkecil selisih antar-OCR dibanding FastText (interaksi OCR $\times$ embedding).

H3 Cabang teks yang lebih kuat membuat fusi lebih *memakai* teks (penurunan lebih besar saat teks dihilangkan); rata-rata logit lebih tahan terhadap cabang yang timpang daripada konkatenasi.

Status: belum-dijalankan.

Kesimpulan

- **Audebert**: baseline sederhana dan transparan; kelemahannya satu OCR dan tanpa variansi.
- **Kanchi**: 90,3 % tanpa RVL-CDIP lewat BERT + HAN, tetapi hasil teks tidak dilaporkan, protokol ambigu, dan klaim efisiensi mengabaikan BERT.
- **Kashyap**: late fusion sederhana dengan akurasi tinggi dan alternatif retrieval ringan, tetapi pelaporannya bermasalah (OCR anonim, pemetaan kelas, angka tidak konsisten, perbandingan selektif).
- Ketiganya tidak mengisolasi OCR, tidak memakai tata letak, dan tidak menguji signifikansi. Celah inilah yang diisi Fase 2.

Terima kasih