Review Paper: Klasifikasi Dokumen Multimodal Teks OCR + Citra

Audebert et al. (2020) • Kashyap et al. (2026) • Kanchi et al. (2022)

Yulian Anggreaif Rudamaga, Zalzabila Rani, Ramadhani Al-Qadri

Analisis & Pemrosesan Data Multimodal – Magister Ilmu Komputer, FILKOM UB

Tiga paper yang direview

	Paper 1	Paper 2	Paper 3
Judul	Multimodal Deep Networks for Text and Image-Based Document Classification	Multimodal Fusion and Supervised Contrastive Learning for Robust Document Image Classification	EmmDocClassifier: Efficient Multimodal Document Image Classifier for Scarce Data
Penulis	Audebert et al. (Quicksign)	Kashyap et al. (Univ. Punjab)	Kanchi et al. (TU Kaiserslautern, DFKI)
Venue	ECML PKDD 2019 Workshops, CCIS 1167, Springer 2020	Int. J. Intelligent Systems (Wiley), 2026	Applied Sciences (MDPI) 12(3), 2022
DOI	10.1007/978-3-030-43823-4_35	10.1155/int/4241437	10.3390/app12031457
Peran	Dasar replikasi Fase 1	Referensi utama Fase 2	Pembanding data sedikit

Aspek review: 9 poin wajib (latar belakang, dataset, modalitas, pipeline, model unimodal, fusi, metrik, hasil, future work) + 4 tambahan (kontribusi, detail pelatihan, kelebihan, catatan kritis).

Paper 1 – Audebert et al. (2020)

Latar belakang, dataset, modalitas

Masalah

- Dokumen hasil pindai/foto tidak punya lapisan teks; pengenalan jenis dokumen masih manual.
- Visual saja cukup untuk kelas kasar, tidak untuk kelas halus (formulir pajak: tata letak sama, isi beda).
- Pertanyaan: apakah teks OCR yang berderau tetap menambah akurasi jika digabung dengan citra, dengan biaya rendah?

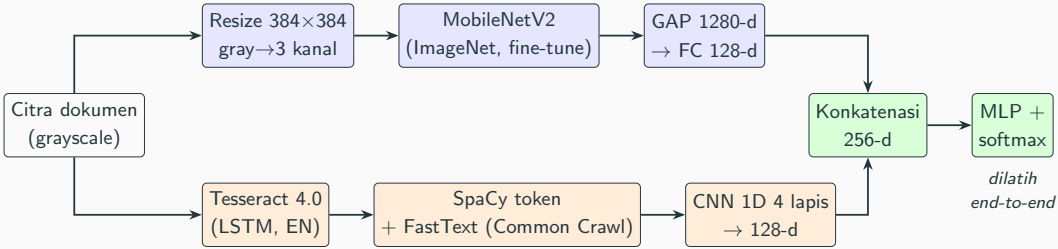
Dataset

- Tobacco3482: 3.482 dok., 10 kelas; 800 latih, sisanya uji; rerata 3 run.
- RVL-CDIP: 400 rb dok., 16 kelas; split 320k/40k/40k.
- QS-OCR: teks Tesseract kedua dataset, dirilis terbuka.

Modalitas

- Citra grayscale halaman + teks OCR dari citra yang sama.
- Teks adalah turunan citra; tata letak tidak dipakai.

Pipeline



- Dua cabang menghasilkan vektor 128-d, lalu dikonkatenasi dan diklasifikasi MLP.
- Seluruh jaringan dilatih end-to-end (FastText tetap beku).

Model unimodal dan fusi

Citra: MobileNetV2

- Ringan; akurasi setara VGG-16, jauh lebih cepat.
- 384×384, grayscale diduplikasi 3 kanal, bobot ImageNet.
- Augmentasi tidak membantu (84,5 vs. 83,9 %).

Teks: FastText + CNN 1D

- Tesseract 4.0 LSTM; ∼26 % kata tidak ada di kamus.
- FastText (subkata) agar kata salah eja tetap punya vektor.
- CNN 1D: 4 lapis, kernel 12, 512 kanal, max-pool waktu; 500 kata.
- MLP embedding dokumen kalah (70,8 vs. 73,9 %).

Fusi: tingkat fitur

- Teks 128-d $\oplus$ citra (GAP 1280 $\rightarrow$ FC 128) $\rightarrow$ MLP.
- Penjumlahan fitur dicoba, tetapi kalah dari citra saja.

Pelatihan

- SGD momentum 0,9; lr 0,01; batch 40.
- Epoch: teks 100, citra 200, fusi 200.
- TensorFlow 1.12, Titan X.

Metrik

- OA, macro-F1, F1/kelas, oracle, latensi.

Hasil

Tobacco3482 (OA %, F1 per kelas)

Model	OA	F1	Adv	Email	Form	Letter	Memo	News	Note	Report	Res	Sci
Teks	73,8	0,71	0,60	0,96	0,76	0,71	0,79	0,67	0,62	0,43	**0,97**	0,57
Citra	84,5	0,82	**0,94**	0,96	0,85	0,83	0,90	0,89	0,83	0,61	0,80	0,62
Fusi	**87,8**	**0,86**	0,93	0,98	0,88	0,86	0,90	0,90	0,85	0,71	0,96	0,68
Oracle	92,1	0,91	0,94	0,99	0,94	0,92	0,93	0,93	0,89	0,81	0,97	0,79

RVL-CDIP (OA %)

Citra	Teks	Fusi
89,1	74,6	**90,6**

- Fusi +3,3 (Tobacco) dan +1,5 (RVL) di atas citra.
- Oracle: batas atas +7,6, jadi masih ada celah 4,3.
- Latensi CPU: OCR 910 ms + model 360 ms $\approx$ 1,3 s; OCR jadi hambatan utama.

Future work, kelebihan, catatan kritis

Future work

- Data dunia nyata (foto, rotasi) + augmentasi.
- Segmentasi tata letak (dhSegment).
- Koreksi ejaan (SymSpell) + NER.
- Embedding tahan derau OCR.

Kelebihan

- Desain sederhana, tiap pilihan diuji.
- Oracle dan F1 per kelas.
- Analisis derau OCR kuantitatif.
- Data teks terbuka sehingga mudah direplikasi.

Catatan kritis

- Tanpa simpangan baku dan uji signifikansi.
- Cara memilih 800 dokumen latih tidak dijelaskan.
- OA teks 73,9 vs. 73,8 (Tabel 1 vs. 3).
- RVL-CDIP hanya OA.
- Satu OCR saja; tidak ada pembanding late fusion.

Paper 2 – Kashyap et al. (2026)

Latar belakang, dataset, modalitas

Masalah

- Unimodal tidak tangguh: visual ambigu, teks OCR penuh OOV.
- VLM besar (LayoutLMv3, DocFormer, DocLLM) terlalu berat untuk edge/IoMT.
- Fusi awal/menengah rentan propagasi galat antarmodal.
- Celah: trade-off akurasi–efisiensi jarang dibahas, sehingga diusulkan dua kerangka terpisah.

Dataset (semua model dilatih di RVL-CDIP)

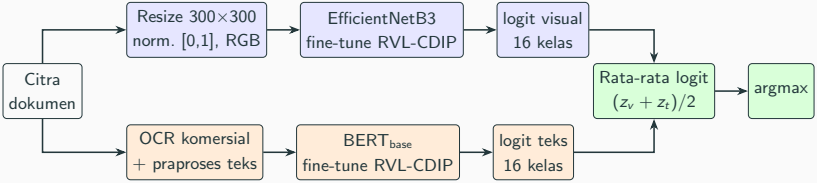
Dataset	Total	Uji	Kelas
RVL-CDIP	399.743	39.995	16
Tobacco3482	3.482	3.482	10
RealDoc-16 (primer)	160	160	16

Modalitas

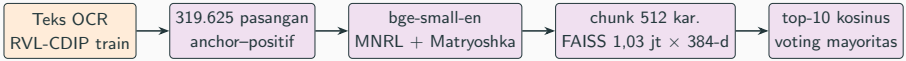
- Fusi: citra + teks OCR.
- SCSR: teks saja.

Pipeline

Pendekatan 1 – multimodal late fusion



Pendekatan 2 – SCSR (teks saja)



- Pendekatan 1 mengejar akurasi: dua aliran dilatih terpisah, lalu logit dirata-rata.
- Pendekatan 2 mengejar efisiensi: pada dasarnya k-NN ($k = 10$) di ruang embedding hasil pelatihan kontrastif.

Model unimodal, fusi, metrik

Citra: EfficientNetB3

- 300×300, RGB, [0,1]; 1536 → Dropout → 16.
- 10 epoch, batch 16, Adam 10^{-3}; ≈22,5 jam.

Teks: $\text{BERT}_{\text{base}}$

- **OCR komersial tanpa nama**; praproses: huruf kecil, buang angka/stopword/tanda baca.
- 10 epoch, batch 16, Adam 5×10^{-5}, dropout 0,3; ≈41 jam.

Teks: SCSR (bge-small-en, 33,3 jt param.)

- MNRL + Matryoshka; 4 epoch, AdamW 2×10^{-5}.
- Chunk 512 karakter, FAISS 1,03 jt × 384-d.

Fusi: late fusion $\hat{y} = \arg\max_c \frac{1}{2}(z_v + z_t)_c$

- Rata-rata logit tak berbobot; tidak ada parameter fusi.

Metrik

- Acc; P/R/F1 *macro* (RVL, RealDoc) dan *weighted* (Tobacco).
- Akurasi per kelas; parameter, latensi, throughput.
- UMAP, Grad-CAM, integrated gradients.

Hasil

		RVL-CDIP (macro)				Tobacco3482 (weighted)			
Studi	Mod.	Acc	F1	Rec	Prec	Acc	F1	Rec	Prec
Audebert (2019)	T / V / T+V	74,6 / 89,1 / 90,6				73,8 / 84,5 / 87,8			
Zingaro (2021)	T+V	92,7				90,5			
Dauphinee (2019)	T+V	93,03				–			
	T (BERT)	89,19	89,57	89,65	90,19	90,28	92,62	90,28	97,28
Kashyap: fusi	V (EffNet)	89,13	89,12	89,15	89,23	89,05	91,58	89,05	96,15
	T+V	**93,06**	93,06	93,17	93,06	**92,00**	94,02	92,00	98,23
Kashyap: SCSR	T	80,76	84,00	81,00	84,00	87,89	90,00	88,00	95,00

- Teks ≈ citra; fusi +3,87 (RVL) dan +1,72 (Tobacco) di atas unimodal terbaik.
- Latensi: fusi 0,184 s/dok, SCSR 0,157 s/dok (OCR tidak dihitung).
- RealDoc-16: hanya 6 dari 16 kelas dilaporkan (mis. letter 100/90, memo 72,73/63,60).

Future work dan kelebihan

Future work

- Dokumen multibahasa dengan OCR yang sangat terdegradasi.
- PEFT untuk menekan memori pelatihan.
- Pembobotan modalitas adaptif / fusi berbasis keyakinan.
- Tambah embedding citra ringan ke indeks SCSR.

Kelebihan

- Jurnal 2026, open access (memenuhi syarat dosen).
- Trade-off akurasi–efisiensi eksplisit.
- Uji di tiga dataset, termasuk data primer.
- P/R/F1 + per kelas untuk tiap unimodal.
- Late fusion mudah direplikasi.

Catatan kritis

- **OCR tidak disebut**, sehingga tidak bisa direplikasi.
- **Pemetaan kelas Tobacco hilang**: *note* + *report* (13,4 %) tidak ada di RVL-CDIP, sehingga tanpa pemetaan akurasi maks. ≈86,6 %, padahal dilaporkan 92 %.
- Potensi kebocoran: Tobacco3482 dan RVL-CDIP dari arsip yang sama; tidak disebut ada deduplikasi.
- Protokol Tobacco berbeda dari Audebert (transfer vs. 800 latih).
- Hanya rata-rata tak berbobot; tidak ada ablasi fusi dan oracle.
- **Angka tidak konsisten**: macro-F1 SCSR 84 $>$ (P 84 + R 81)/2; macro-recall $\neq$ akurasi pada data seimbang.
- RealDoc-16: 160 vs. 120 dokumen; 72,73 % = 8/11 padahal 10/kelas.
- Angka per kelas Audebert di Tabel 5 **tidak ditemukan** di paper asli (yang melaporkan F1, bukan akurasi).
- Klaim "tanpa DL" untuk SCSR padahal transformer 33 jt; indeks FAISS ≈1,6 GB; hemat latensi hanya ∼15 %.
- Tanpa seed, variansi, atau uji signifikansi.

Paper 3 – Kanchi et al. (2022)

Latar belakang, dataset, modalitas

Masalah

- Dokumen sering mirip secara visual tetapi berbeda isi (letter, memo, report).
- Model dua aliran yang ada bergantung pada *pre-training* RVL-CDIP (320 rb citra) dan model besar.
- Pertanyaan: bisakah klasifikator multimodal efisien tetap akurat dengan data sedikit (Tobacco3482 saja)?

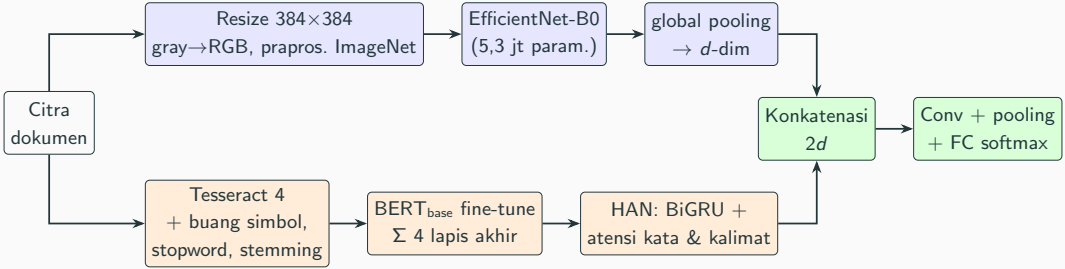
Dataset

- Tobacco3482: 10 kelas; partisi ala Afzal (20–100 sampel/kelas), latih dibagi 80/20.
- RVL-CDIP: hanya untuk eksperimen *pre-training*.
- Dua skenario: ImageNet + RVL-CDIP, dan ImageNet saja (fokus).

Modalitas

- Citra + teks OCR; teks diproses hierarkis (kata $\rightarrow$ kalimat $\rightarrow$ dokumen).

Pipeline EmmDocClassifier



- Fitur citra dan teks berdimensi sama, dikonkatenasi ($2d$), lalu conv + pooling + FC.
- Rata-rata fitur juga dicoba, tetapi konkatenasi lebih baik.

Model unimodal, fusi, metrik

Citra: EfficientNet-B0

- 5,3 jt parameter ($\sim$5$\times$ lebih ringan dari ResNet-50).
- 384$\times$384, gray $\rightarrow$ RGB, bobot ImageNet.
- Adam 10^{-3}, 20 epoch, lr turun bertahap ke 10^{-5}.

Teks: Tesseract 4 + BERT + HAN

- Praproses: buang simbol, stopword, *stemming*.
- $\text{BERT}_{\text{base}}$ fine-tune (4 lapis akhir), lalu dibekukan; embedding = jumlah 4 lapis akhir.
- HAN: BiGRU + atensi kata dan kalimat; 25 kalimat, 10 rb kata.
- RMSProp 10^{-3}, batch 100, 20 epoch.

Fusi: tingkat fitur

$$X_{ens} = [X_{img}; X_{text}] \in \mathbb{R}^{2d}$$

- Adam 10^{-3}, 20 epoch, batch 100.
- NVIDIA V100 32 GB.

Metrik

- Akurasi, *relative error reduction*.
- Matriks konfusi, latensi, contoh benar/salah.
- **Tidak ada F1/presisi/recall.**

Hasil (Tobacco3482, akurasi %)

	ImageNet + RVL		ImageNet saja	
Studi	Citra	Multi	Citra	Multi
Audebert (2019)	–	–	84,5	87,8
Asim (2019)	93,2	95,8	–	–
Bakkali (2020)	91,3	96,94	–	–
Ferrando (2020)	94,04	94,9	85,99	89,47
Kanchi	94,04	95,7	86,0	**90,3**

- Tanpa RVL-CDIP: fusi 90,3 %, +0,83 dari Ferrando (galat relatif −7,9 %, hitungannya konsisten).
- Dengan RVL-CDIP: 95,7 %, masih di bawah Asim dan Bakkali.
- RVL-CDIP: 95,48 % (satu kalimat, tanpa rincian).
- Latensi 105 ms (teks 55 + citra 50), tanpa OCR.
- **Akurasi aliran teks tidak dilaporkan.**
- Kelas tersulit: *scientific* (mirip report/adv., citra berderau).

Future work, kelebihan, catatan kritis

Future work

- Co-attention antarmodalitas.
- Jaringan lebih kecil untuk pelatihan di perangkat.
- Augmentasi citra sintetis (kelas scientific).

Kelebihan

- Skenario data sedikit = lingkup proyek kami.
- Skenario dengan/tanpa RVL-CDIP dipisah.
- OCR jelas (Tesseract 4).

Catatan kritis

- **Hasil unimodal teks dan ablasi FastText tanpa angka**, padahal aliran teks adalah klaim utama.
- **Angka citra identik dengan Ferrando** (94,04 = 94,04; 86,0 ≈ 85,99), tanpa penjelasan.
- "From scratch" menyesatkan: memakai bobot ImageNet dan BERT pre-trained.
- Protokol partisi ambigu; tidak ada jumlah ulangan atau simpangan baku.
- BERT di-fine-tune pada "korpus kami", sehingga ada potensi kebocoran data uji.
- Stemming + buang stopword sebelum BERT merusak konteks.
- Klaim "ukuran turun 80 %" mengabaikan BERT (110 jt param.); OCR tidak dihitung.
- Hanya akurasi pada data tidak seimbang; tanpa kode/data.

Perbandingan dan relevansi

Perbandingan

Aspek	Audebert (2020)	Kanchi (2022)	Kashyap (2026)
OCR	Tesseract 4.0, terbuka	Tesseract 4	Komersial, anonim
Citra	MobileNetV2	EfficientNet-B0	EfficientNetB3
Teks	FastText + CNN 1D	BERT + HAN	BERT; bge-small (SCSR)
Fusi	Fitur: konkat. + MLP	Fitur: konkat. + conv	Keputusan: rata-rata logit
Unimodal	Citra $\gg$ teks	Teks tidak dilaporkan	Teks $\approx$ citra
Tobacco tanpa RVL	87,8	90,3	–
Tobacco dengan RVL	–	95,7	92,00
Fusi RVL	90,6	95,48 (?)	93,06
Replikasi	Tinggi	Rendah–sedang	Sedang

Inti: di ketiga paper, perbaikan teks datang bersamaan dengan pergantian model teks, sehingga pengaruh OCR tidak pernah diisolasi. Protokol Tobacco3482 juga berbeda di tiap paper.

Relevansi untuk proyek (Fase 2)

- Ketiga paper tidak memisahkan pengaruh **OCR** dari pengaruh **embedding**; eksperimen faktorial OCR $\times$ embedding pada proyek kami mengisi celah ini.
- Skenario Kanchi (Tobacco3482 tanpa RVL-CDIP) paling sepadan dengan proyek kami, sehingga 90,3 % / 86,0 % menjadi acuan yang lebih adil daripada angka Kashyap.
- BERT + HAN (Kanchi) bisa menjadi salah satu level variabel embedding, di samping FastText dan BERT/bge.
- Late fusion (rata-rata logit) ditambahkan sebagai pembanding konkatenasi, bersama oracle sebagai batas atas.
- Praktik yang kami ambil: laporkan akurasi tiap unimodal, rerata $\pm$ simpangan baku lintas seed, macro-F1, serta protokol split dan OCR secara eksplisit.

Kesimpulan

- **Audebert**: baseline sederhana dan transparan; kelemahannya satu OCR dan tanpa variansi.
- **Kanchi**: 90,3 % tanpa RVL-CDIP lewat BERT + HAN, tetapi hasil teks tidak dilaporkan, protokol ambigu, dan klaim efisiensi mengabaikan BERT.
- **Kashyap**: late fusion sederhana dengan akurasi tinggi dan alternatif retrieval ringan, tetapi pelaporannya bermasalah (OCR anonim, pemetaan kelas, angka tidak konsisten).
- Angka Kanchi dan Kashyap dipakai sebagai *acuan arah*, bukan target yang harus dicapai persis.

Terima kasih